

STAT3003：统计算法基础

第 1 讲：随机变量的产生

曾靖

目录

学习目标	2
1 随机数与 R 中的随机抽样	2
1.1 伪随机数与随机种子	2
1.2 从有限集合中抽样	2
1.3 R 的常用分布函数	3
1.4 大数定律	4
1.5 中心极限定理	5
2 逆变换法	6
2.1 连续型随机变量	6
2.2 离散型随机变量	7
3 接受—拒绝法	10
4 小结	13

学习目标

本讲讨论计算机如何生成随机变量。学习后应能够：

1. 理解伪随机数、随机种子与可重复性的关系；
2. 熟练使用 R 中 `d`、`p`、`q`、`r` 四类分布函数；
3. 掌握连续型与离散型随机变量的逆变换法；
4. 理解接受—拒绝法的构造、正确性和效率；
5. 用模拟与图形检查生成样本是否接近目标分布。

1 随机数与 R 中的随机抽样

1.1 伪随机数与随机种子

普通计算机通常产生的是**伪随机数**：给定初始状态（种子）后，算法以确定性的方式生成一个看似随机的序列。因此，相同种子、相同程序和相同随机数发生器会得到相同的模拟结果。这一性质是计算实验可复现性的基础。

在 R 中，使用 `set.seed()` 固定随机种子。

```
round(runif(5), 4)
```

```
## [1] 0.3518 0.5218 0.3101 0.2679 0.9992
```

```
round(runif(5), 4)
```

```
## [1] 0.6090 0.8433 0.1286 0.4252 0.0862
```

```
set.seed(5)
```

```
runif(5)
```

```
## [1] 0.2002145 0.6852186 0.9168758 0.2843995 0.1046501
```

```
set.seed(5)
```

```
runif(5)
```

```
## [1] 0.2002145 0.6852186 0.9168758 0.2843995 0.1046501
```

两次输出完全相同。通常应在一段独立模拟开始处设置种子；不要在循环中反复设置种子，否则会破坏样本的随机性。

1.2 从有限集合中抽样

函数 `sample(x, size, replace = FALSE, prob = NULL)` 从有限集合 `x` 中抽取 `size` 个元素。参数 `replace` 决定是否放回，`prob` 可指定非均匀抽样概率。

```
# 有放回抽样：相当于重复进行伯努利试验
```

```
sample(0:1, size = 10, replace = TRUE)
```

```
## [1] 0 0 0 1 0 0 0 0 1 1
```

```
# 无放回简单随机抽样
```

```
set.seed(5)
```

```
sample(1:100, size = 6, replace = FALSE)
```

```
## [1] 66 57 79 75 41 85
```

1.3 R 的常用分布函数

对一个分布，R 通常提供四类函数：

前缀	含义	以指数分布为例
d	密度或概率质量函数	<code>dexp(x, rate)</code>
p	累积分布函数	<code>pexp(x, rate)</code>
q	分位数函数（CDF 的逆）	<code>qexp(u, rate)</code>
r	随机数生成函数	<code>rexp(n, rate)</code>

例如，参数为 $\lambda = 1$ 的指数分布具有密度和分布函数

$$f(x) = e^{-x}, \quad F(x) = 1 - e^{-x}, \quad x > 0.$$


```
x <- seq(0, 8, .05)
```

```
data <- data.frame(x = x, y = dexp(x))
```


```
ggplot(data, aes(x = x, y = y)) + geom_line() +
```

```
  labs(x = "", y = "", title = "Exponential distribution") +
```

```
  theme_bw()
```



```
x <- seq(0, 8, .05)
data <- data.frame(x = x, y = pexp(x))
ggplot(data, aes(x = x, y = y)) + geom_line()+
  labs(x = "", y = "", title = "Exponential distribution")+
  theme_bw()
```




1.4 大数定律

若 $X_1, X_2, \dots$ 独立同分布且 $E(X_i) = \mu$, 则样本均值

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

随着 n 增大收敛到 μ 。下面以标准正态分布为例。

```
N <- 2^c(1:20)
y <- sapply(N, function(n){
  x <- rnorm(n, 0, 1)
  mean(x)
})
data <- data.frame(N = N, mean = y)
ggplot(data, aes(x = log(N), y = mean))+
  geom_point()+ geom_line()+
  geom_abline(intercept = 0, slope = 0, color = '#FF6666')+
  labs(y="")+ theme_bw()
```



红线表示理论均值 $E(X) = 0$ 。图形中的波动不会消失，但样本均值会越来越稳定地围绕该值变化。

1.5 中心极限定理

中心极限定理说明，在适当条件下，标准化的样本均值近似服从正态分布。若 $X_i \sim \text{Unif}(0, 1)$ ，则

$$E(X_i) = \frac{1}{2}, \quad \text{Var}(X_i) = \frac{1}{12},$$

因此，当 n 较大时， $\bar{X}_n$ 近似服从


$$N\left(\frac{1}{2}, \frac{1}{12n}\right).$$

```
iter <- 1000
N <- c(1, 10, 100)
data <- lapply(N, function(n){
  x <- replicate(iter, mean(runif(n)))
  stat <- (x-0.5)*sqrt(n)
})
data_x <- data.frame(x = data[[2]])
ggplot(data_x, aes(x = x))+
  geom_histogram(
    aes(y=after_stat(density)), bins = 40,
```

```

color="darkblue", fill="lightblue"
)+
scale_x_continuous(limits = c(-2, 2))+
geom_density(alpha=.2, fill="#FF6666")+
labs(x = "", y = "", title = "n = 10")+
theme_bw()

```



红色密度曲线展示样本均值标准化后的经验分布；当 $n = 1, 10, 100$ 时，样本量越大，近似通常越好。

2 逆变换法

2.1 连续型随机变量

设连续随机变量 X 的累积分布函数为 F_X 。若 F_X 连续且严格单调，则有两条关键结论：

$$U = F_X(X) \sim \text{Unif}(0, 1), \quad F_X^{-1}(U) \sim X, \quad U \sim \text{Unif}(0, 1).$$

第二个结论给出连续型随机变量的逆变换算法。

算法：连续型逆变换法


1. 求目标分布的 CDF $F_X(x)$ 及其逆函数 $F_X^{-1}(u)$ ；
2. 生成 $U \sim \text{Unif}(0, 1)$ ；
3. 令 $X = F_X^{-1}(U)$ 。

例子 2.1：密度 $f(x) = 3x^2$ 的随机样本。考虑 $0 < x < 1$ 上的密度

$$f_X(x) = 3x^2, \quad F_X(x) = x^3, \quad F_X^{-1}(u) = u^{1/3}.$$

因此，只需将均匀随机数取三次方根即可。

```
u <- runif(1000)
x <- u^(1/3)
data_x <- data.frame(x = x)
ggplot(data_x, aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 20,
    color = "darkblue", fill = "lightblue") +
  stat_function(fun = function(x) 3 * x^2,
    color = "#FF6666", linewidth = 1) +
  labs(x = "", y = "",
    title = expression(f(x) == 3 * x^2)) +
  theme_bw()
```



2.2 离散型随机变量

离散情形中，CDF 是阶梯函数，通常没有普通意义下的反函数。定义广义逆函数

$$F_X^{-1}(u) = \min\{x_i : F_X(x_i) \geq u\}, \quad 0 < u < 1.$$

算法：离散型逆变换法

1. 列出或计算 $F_X(x_i)$;
2. 生成 $U \sim \text{Unif}(0, 1)$;
3. 返回第一个满足 $F_X(x_i) \geq U$ 的取值 x_i 。

例子 2.2：几何分布。令 $X \sim \text{Geom}(p)$ ，其中取值为 $0, 1, 2, \dots$ ，并记 $q = 1 - p$ 。则

$$P(X = x) = q^x p, \quad F_X(x) = 1 - q^{x+1}.$$

由广义逆可得

$$X = \left\lceil \frac{\log(1 - U)}{\log(1 - p)} \right\rceil - 1.$$

```
n <- 1000
p <- 0.25
u <- runif(n)
x <- ceiling(log(1-u)/log(1-p)) - 1
tab <- table(x)
options(width = 40)
round(rbind(tab/n, dgeom(as.numeric(names(tab)), prob = p)), 3)
```

```
##           0      1      2      3      4
## [1,] 0.258 0.175 0.138 0.105 0.074
## [2,] 0.250 0.188 0.141 0.105 0.079
##           5      6      7      8      9
## [1,] 0.067 0.041 0.039 0.036 0.020
## [2,] 0.059 0.044 0.033 0.025 0.019
##          10     11     12     13     14
## [1,] 0.010 0.007 0.010 0.002 0.005
## [2,] 0.014 0.011 0.008 0.006 0.004
##          15     16     17     18     20
## [1,] 0.002 0.002 0.002 0.003 0.001
## [2,] 0.003 0.003 0.002 0.001 0.001
##          22     23     24
## [1,] 0.001 0.001 0.001
## [2,] 0.000 0.000 0.000
```

```
geom22 <- data.frame(
  x = 0:max(x), F = pgeom(0:max(x), prob = p)
)
p22 <- ggplot(data.frame(x = x), aes(x = x)) +
  stat_ecdf(
```




```

aes(color = "Empirical CDF"),
geom = "step", linewidth = 0.8
) +
geom_step(
  data = geom22,
  aes(x = x, y = F, color = "Theoretical CDF"),
  linewidth = 0.8
) +
scale_color_manual(values = c("Empirical CDF" = "darkblue",
                              "Theoretical CDF" = "#FF6666")) +

labs(
  x = "", y = "", color = "",
  title = "Geometric distribution"
) +
theme_bw() + theme(legend.position = "top")
print(p22)

```



补充：泊松分布的递推计算

当分布函数不能方便地显式求逆时，可先递推计算概率和 CDF。对 $X \sim \text{Pois}(\lambda)$,

$$p_0 = e^{-\lambda}, \quad p_{k+1} = \frac{\lambda}{k+1} p_k, \quad F(k+1) = F(k) + p_{k+1}.$$

该递推给出了离散逆变换法所需的 CDF 序列。

3 接受—拒绝法

有时 F_X^{-1} 难以计算，但目标密度 f 容易求值。这时选择一个容易抽样的提议密度 g ，以及常数 $c \geq 1$ ，使得

$$f(x) \leq cg(x), \quad \forall x.$$

每次先从 g 产生候选值 Y ，再以概率

$$\frac{f(Y)}{cg(Y)}$$

接受该候选值。

算法：接受—拒绝法

1. 找到易抽样的 g 和上界常数 c ，使 $f \leq cg$ ；
2. 产生 $Y \sim g$ 及 $U \sim \text{Unif}(0, 1)$ ；
3. 若 $U \leq f(Y)/(cg(Y))$ ，接受并令 $X = Y$ ；否则重复第 2 步。

设一次候选被接受的事件为 A ，则

$$P(A) = \int \frac{f(y)}{cg(y)} g(y) dy = \frac{1}{c}.$$

并且

$$P(Y \leq x | A) = F(x),$$

因此接受后的样本恰好服从目标分布。平均需要 c 次候选才能接受一次，所以应选择尽可能接近 f 的 g 。

例子 3.1: 在 $[0, 1]$ 上生成 $60x^3(1-x)^2$ 。目标密度为

$$f(x) = 60x^3(1-x)^2, \quad 0 \leq x \leq 1.$$

取 $g(x) = 1$ ，即 $Y \sim \text{Unif}(0, 1)$ 。该密度在 $x = 0.6$ 处达到最大值

$$c = f(0.6) = 2.0736.$$

```
n <- 1000
k <- 0
j <- 0
x <- numeric(n)
while(k < n){
```

```

u <- runif(1)
j <- j + 1
y <- runif(1)
if(u < 60*y^3*(1-y)^2/2.074){
  k <- k + 1
  x[k] <- y
}
}
print(sprintf("%d %d %.3f %.3f", k, j, k/j, 1/2.074))


```

```
## [1] "1000 2066 0.484 0.482"
```

```

p31 <- ggplot(data.frame(x = x), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 20,
    color = "darkblue", fill = "lightblue") +
  geom_density(color = "darkblue", linewidth = 0.8) +
  stat_function(fun = function(x) 60 * x^3 * (1 - x)^2,
    color = "#FF6666", linewidth = 1) +
  labs(x = "", y = "",
    title = expression(f(x) == 60 * x^3 * (1 - x)^2)) +
  theme_bw()
print(p31)

```



例子 3.2: 生成 $\Gamma(3/2, 1)$ 随机变量。目标密度为

$$f(x) = \frac{x^{1/2}e^{-x}}{\Gamma(3/2)}, \quad x > 0.$$

取提议分布 $Y \sim \text{Exp}(2/3)$, 即

$$g(y) = \frac{2}{3}e^{-2y/3}.$$

可验证

$$\frac{f(x)}{g(x)} \leq c = \frac{3\sqrt{3}}{\sqrt{2\pi e}} \approx 1.257,$$

所以接受概率为


$$\frac{f(y)}{cg(y)} = \sqrt{\frac{2e}{3}} y^{1/2} e^{-y/3}.$$

```
n <- 1000
k <- 0
j <- 0
x <- numeric(n)
while(k < n){
  u <- runif(1)
  j <- j + 1
  y <- rexp(1, 2/3)
  if(u < sqrt(2*exp(1)/3) * sqrt(y) * exp(-y/3)){
    k <- k + 1
    x[k] <- y
  }
}
print(sprintf("%d %d %.3f %.3f", k, j, k/j, 1/1.257))
```

```
## [1] "1000 1228 0.814 0.796"
```

```
p32 <- ggplot(data.frame(x = x), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
    color = "darkblue", fill = "lightblue") +
  geom_density(color = "darkblue", linewidth = 0.8) +
  stat_function(
    fun = dgamma, args = list(shape = 3 / 2, rate = 1),
    color = "#FF6666", linewidth = 1) +
  coord_cartesian(xlim = c(0, 10)) +
  labs(x = "", y = "", title = expression(Gamma(3/2, 1))) +
```

```
theme_bw()  
print(p32)
```



4 小结

方法	适用情形	核心步骤	主要代价
直接调用 R 分布函数	常见分布	使用 <code>r*</code> 函数	最简单、最高效
逆变换法	F^{-1} 可求或 CDF 可表	$X = F^{-1}(U)$	需要求逆或搜索 CDF
接受—拒绝法	密度易求、逆函数难求	从 g 产生候选后接受或拒绝	平均每个样本需要 c 个候选