

# STAT3003：统计算法基础\*

## 第 5 讲：蒙特卡洛方法（3）

曾靖

2026 年 9 月 1 日

### 目录

|                          |           |
|--------------------------|-----------|
| 学习目标                     | 2         |
| <b>1 蒙特卡罗方法的方差缩减</b>     | <b>2</b>  |
| 1.1 增大样本数 . . . . .      | 2         |
| 1.2 对偶变量法：一元情况 . . . . . | 2         |
| 1.3 对偶变量法：多元情况 . . . . . | 3         |
| 1.4 控制变量法 . . . . .      | 5         |
| 1.5 重要抽样法 . . . . .      | 6         |
| 1.6 重要抽样法 . . . . .      | 7         |
| 1.7 分层抽样法 . . . . .      | 9         |
| 1.8 解释 . . . . .         | 11        |
| <b>2 小结</b>              | <b>11</b> |

## 学习目标

学习后应能够：

- 理解并掌握“蒙特卡罗方法的方差缩减”的核心思想与计算方法。

## 1 蒙特卡罗方法的方差缩减

### 1.1 增大样本数

- 一般地，对于参数  $\theta$  的 Monte Carlo 估计步骤如下：
  - 对于第  $j$  次 Monte Carlo 试验，得到估计量  $\hat{\theta}^{(j)}$ ;
  - 重复上述过程  $m$  次，得到  $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(m)}$ ;
  - Monte Carlo 估计量  $\hat{\theta} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}^{(j)}$ .

估计量的方差

$$\text{Var}(\hat{\theta}) = \frac{1}{m} \text{Var}(\hat{\theta}^{(j)}).$$

- 最简单的方差缩减方法即为增大试验次数  $m$ 。然而这种方法的计算代价很大：如果要把  $\hat{\theta}$  的标准差缩小 100 倍，试验次数  $m$  则要增加  $100^2 = 10,000$  倍。

### 1.2 对偶变量法：一元情况

- 我们考虑  $\theta = E(h(X))$ ，这里  $X \in \mathbb{R}$ 。令  $x_1, \dots, x_m$  为与  $X$  同分布的 i.i.d. 样本，则  $\theta$  的 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m h(x_i).$$

- 考虑两个随机变量  $X_1, X_2 \sim X$ ，则平均值  $(h(X_1) + h(X_2))/2$  的方差为

$$\begin{aligned} & \text{Var} \left( \frac{h(X_1) + h(X_2)}{2} \right) \\ &= \frac{1}{4} (\text{Var}(h(X_1)) + \text{Var}(h(X_2)) + 2\text{Cov}(h(X_1), h(X_2))). \end{aligned}$$

- 若  $h(X_1)$  和  $h(X_2)$  具有负相关性，则平均值  $\frac{h(X_1) + h(X_2)}{2}$  可以被降低。

*Theorem 1.* 设  $g(x)$  为单调函数， $U \sim \text{Unif}(0, 1)$ ，则  $\text{Cov}(g(U), g(1-U)) \leq 0$ 。

- 记随机变量  $X$  的 CDF 为  $F(x)$ ，生成  $U \sim \text{Unif}(0, 1)$ ，则随机变量  $F^{-1}(U), F^{-1}(1-U) \sim X$ 。
- 根据 Theorem 1，如果  $h$  为单调函数，则  $h(F^{-1}(U))$  和  $h(F^{-1}(1-U))$  同分布于  $h(X)$  且具有负相关性
- 因此，只要生成一个样本  $U$ ，我们就可以构造出两个与  $h(X)$  同分布且负相关的样本。
- 更一般地，我们有如下定理：

**Theorem 2.** 设  $f(x), g(x)$  同单调增或同单调减, 则对于任何随机变量  $X$  我们有  $\text{Cov}(f(X), g(X)) \geq 0$ .

### 1.3 对偶变量法：多元情况

- 接下来我们考虑参数  $\theta = E(h(X_1, \dots, X_n))$ 。

**Definition 1:** 如果对于所有  $j = 1, \dots, n$ , 我们有  $x_j \leq y_j$ , 则记  $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$ 。

**Definition 2:** 如果对于  $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$  我们有  $g(x_1, \dots, x_n) \leq g(y_1, \dots, y_n)$ , 则称  $n$  元函数  $g = g(x_1, \dots, x_n)$  称为单调增。类似可定义单调减的  $n$  元函数。如果  $n$  元函数是单调增的或单调减的, 则称该函数为单调的。

**Theorem 3.** 设  $f, g$  为关于  $(x_1, \dots, x_n)$  的同单调递增或递减函数, 对任何多元随机变量  $(X_1, \dots, X_n)$  且  $X_j$  之间相互独立, 我们有  $\text{Cov}(f(X_1, \dots, X_n), g(X_1, \dots, X_n)) \geq 0$ 。

- 根据 Theorem 3, 取  $f(x_1, \dots, x_n) = -g(1 - x_1, \dots, 1 - x_n)$ , 我们有如下推论。

**Corollary 1.** 设  $g(x_1, \dots, x_n)$  为关于  $(x_1, \dots, x_n)$  的单调函数,  $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$  且  $U_i$  间相互独立, 则  $\text{Cov}(g(U_1, \dots, U_n), g(1 - U_1, \dots, 1 - U_n)) \leq 0$ 。

- 记每个随机变量  $X_i$  的 CDF 为  $F_i(x)$ ,  $i = 1, \dots, n$ , 如果  $h(x_1, \dots, x_n)$  为单调函数, 则  $h(F_1^{-1}(u_1), \dots, F_n^{-1}(u_n))$  也是单调函数。
- 生成  $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$  且  $U_i$  间相互独立。随机变量  $h(F_1^{-1}(U_1), \dots, F_n^{-1}(U_n))$  和  $h(F_1^{-1}(1 - U_1), \dots, F_n^{-1}(1 - U_n))$  同分布于  $h(X_1, \dots, X_n)$  并且两者存在负相关关系。
- 对于目标参数  $\theta = E(h(X_1, \dots, X_n))$ , 假设  $h$  是单调的, 利用对偶变量法得到 Monte Carlo 估计
  - 独立生成  $n$  个均匀分布变量  $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$ ;
  - 构造随机变量  $Y_j = h(F_1^{-1}(U_1), \dots, F_n^{-1}(U_n))$ ;
  - 构造对偶变量  $Y_j^+ = h(F_1^{-1}(1 - U_1), \dots, F_n^{-1}(1 - U_n))$ , 则  $Y_j, Y_j^+ \sim h(X_1, \dots, X_n)$  且  $Y_j, Y_j^+$  负相关;
  - 重复上述步骤  $m/2$  次, 构造对偶 Monte Carlo 估计量

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^{m/2} (Y_j + Y_j^+).$$

结论:

- 对偶 Monte Carlo 估计量仍是  $\theta$  的无偏估计
- 只要保证  $U_1, \dots, U_n$  相互独立, 并且  $h$  单调, 则根据 Theorem 2 可知对偶 Monte Carlo 估计量方差会得到缩减。
- 相比于仅单 Monte Carlo 估计  $\hat{\theta} = \frac{1}{m} \sum_{j=1}^m Y_j$ , 对偶 Monte Carlo 估计只需要重复  $m/2$  次模拟实验, 就可以得到更有效率 (方差更小) 的估计量。

特例:

- 如果  $X_i, i = 1, \dots, n$ , 服从正态分布, 我们不需要借助均匀分布变量, 利用正态分布的对称性直接构造对偶变量。
- 假设  $X_i \sim N(\mu_i, \sigma^2), i = 1, \dots, n$ ,  $h$  是单调函数。令  $Z_i = 2\mu_i - X_i$ , 则可证明  $Y_j = h(X_1, \dots, X_n)$  与  $Y_j^+ = h(Z_1, \dots, Z_n)$  同分布于  $h(X_1, \dots, X_n)$  且负相关。
- 对偶 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^{m/2} (Y_j + Y_j^+).$$

### 例 1.1 积分估计

*Question:* 利用对偶方法估计积分

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

令  $\theta = E[xe^{-(xU)^2/2}]$ , 这里  $U \sim \text{Unif}(0, 1)$ 。如果  $x > 0$ ,  $\Phi(x) = 0.5 + \theta/\sqrt{2\pi}$ ; 如果  $x < 0$ ,  $\Phi(x) = 1 - \Phi(-x)$ 。则问题转化为估计参数  $\theta$ 。

```
MC.Phi <- function(x, m = 10000, antithetic = TRUE){
  u <- runif(m/2)
  if (!antithetic) v <- runif(m/2)
  else v <- 1 - u
  u <- c(u, v)
  cdf <- numeric(length(x))
  for (i in 1:length(x)) {
    g <- x[i] * exp(-(u * x[i])^2 / 2)
    cdf[i] <- mean(g) / sqrt(2 * pi) + 0.5
  }
  cdf
}
```

```
x <- seq(.1, 2.5, length=5)
Phi <- pnorm(x)
MC1 <- MC.Phi(x, antithetic = FALSE) # 非对偶法
MC2 <- MC.Phi(x) # 对偶法
print(round(rbind(x, MC1, MC2, Phi), 5))
```

```
##          [,1]      [,2]      [,3]      [,4]      [,5]
## x    0.10000 0.70000 1.30000 1.90000 2.50000
## MC1 0.53983 0.75795 0.90293 0.97116 0.99439
## MC2 0.53983 0.75804 0.90323 0.97131 0.99378
## Phi 0.53983 0.75804 0.90320 0.97128 0.99379
```

*Question:* 通过 Monte Carlo 来估计非对偶估计和对偶估计的方差。

思考: 有哪些 Monte Carlo 估计方法?

```

m <- 1000
MC1 <- MC2 <- numeric(m)
x <- 1.95
for (i in 1:m) {
  MC1[i] <- MC.Phi(x, m = 1000, antithetic = FALSE)
  MC2[i] <- MC.Phi(x, m = 1000)
}
print(var(MC1))

## [1] 5.186911e-05

print(var(MC2))

## [1] 2.040312e-07

print(var(MC2)/var(MC1))

## [1] 0.003933578

```

## 1.4 控制变量法

- 我们考虑参数  $\theta = E(g(X))$  的情况，这里  $X$  是一元变量。如果我们已知关于  $X$  的另一个函数  $f(X)$  的期望  $\mu = E(f(X))$ ，那么构造新的变量

$$Y = g(X) + c(f(X) - \mu).$$

构造变量  $Y$  是  $\theta$  的无偏估计，这里称  $f(X)$  为  $g(X)$  的控制变量。

- 构造变量  $Y$  的方差为

$$\text{Var}(Y) = \text{Var}(g(X)) + c^2 \text{Var}(f(X)) + 2c \text{Cov}(g(X), f(X)).$$

- 通过选取恰当的控制变量  $f(X)$  和  $c$ ，我们可以从样本  $\{x_1, \dots, x_n\}$  中得到一系列新的构造变量样本  $\{y_1, \dots, y_n\}$ 。参数估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m y_i = \frac{1}{m} \sum_{i=1}^m \{g(x_i) + c(f(x_i) - \mu)\}.$$

- 取

$$c = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))},$$

可以得到构造变量  $Y$  的方差最小，为

$$\text{Var}(Y) = \text{Var}(g(X)) - \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}(f(X))}.$$

- 因此，方差缩减比为

$$\begin{aligned} \frac{\text{Var}(g(X)) - \text{Var}(Y)}{\text{Var}(g(X))} &= \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}(g(X))\text{Var}(f(X))} \\ &= \text{Corr}^2(g(X), f(X)). \end{aligned}$$

- 通过增大  $f(X)$  和  $g(X)$  的相关性, 可以降低构造变量  $Y$  的方差。
- 缺陷: 需要计算  $E(f(X))$ ,  $\text{Cov}(g(X), f(X))$  和  $\text{Var}(f(X))$ , 往往需要额外的 Monte Carlo 模拟来进行估计; 并且,  $\mu$  往往需要已知, 否则也需要额外的模拟来估计。
- 因此, 在选择  $f(X)$  时, 我们希望  $f(X)$  和  $g(X)$  尽量相似, 并且  $E(f(X))$ ,  $\text{Cov}(g(X), f(X))$  和  $\text{Var}(f(X))$  尽量好计算。

### 例 1.2

*Question:* 利用控制变量方法估计积分

$$\theta = \int_0^1 e^u du.$$

- 该问题等价于估计参数  $\theta = E(g(U)) = E(e^U)$ , 这里函数  $g(x) = e^x$ ,  $U \sim \text{Unif}(0, 1)$ 。
- 为了增大相关性, 变量  $g(U)$  的一个自然的控制变量为  $f(U) = U$ 。因此,

$$\begin{aligned} E(f(U)) &= 0.5, \quad \text{Var}(f(U)) = 1/12, \\ \text{Cov}(g(U), f(U)) &= 1 - (1/2)(e - 1). \end{aligned}$$

- 接着可以计算

$$c = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))} = -12 - 6(e - 1).$$

- 构造变量为

$$Y = e^U + c(U - 0.5)$$

```
m <- 10000
a <- - 12 + 6 * (exp(1) - 1)
U <- runif(m)
T1 <- exp(U)
T2 <- exp(U) + a * (U - 1/2) ## 控制变量方法
mean(T1)

## [1] 1.710791

mean(T2)

## [1] 1.719018

(var(T1) - var(T2)) / var(T1)

## [1] 0.9838001
```

## 1.5 重要抽样法

- 对于积分  $\theta = \int_A g(x)dx$  的简单 Monte Carlo 估计如下:

$$\hat{\theta} = \frac{|A|}{m} \sum_{i=1}^m g(u_i), \quad u_i \sim \text{Unif}(A),$$

- 该方法会有如下三点问题:

1. 这种方法无法应用到无限区间  $A$  上;
2. 当存在很多  $g(u) \approx 0$  的区域时, 会造成很多样本的浪费;
3. 当函数  $g(u)$  在区间  $A$  上不平稳时,  $g(u)$  的方差会很大。

## 1.6 重要抽样法

- 为了解决如上问题, 针对  $g(u)$  的不同取值, 赋予其不同的权重, 使得在  $|g(u)|$  大的地方赋小权重, 在  $|g(u)|$  小的地方赋大权重, 从而提高样本利用率并且降低方差。这种方法叫做重要抽样法 (Importance Sampling)。

– 在简单 Monte Carlo 抽样中, 权重都为  $1/m$ 。

- 假设随机变量  $X$  的密度函数为  $f(x)$ , 且支撑在  $A$  上。我们把问题转化为估计

$$\theta = \int_A g(x)dx = \int_A \frac{g(x)}{f(x)} f(x)dx = E[g(X)/f(X)].$$

其中, 函数  $f(x)$  被称为重要函数。这里,  $1/f(X)$  可以看作权重。

- 重要抽样估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m \frac{g(x_i)}{f(x_i)}, \quad x_1, \dots, x_m \sim X.$$

- 从赋权重的角度来说, 我们希望  $f(x)$  与  $g(x)$  足够相似, 这样在  $|g(x)|$  比较小的地方权重  $1/f(x)$  会比较大, 在  $|g(x)|$  比较大的地方权重  $1/f(x)$  会比较小, 从而减小 Monte Carlo 估计的方差。
- 另一方面, 我们可以计算  $g(X)/f(X)$  的方差为

$$\begin{aligned} \text{Var} \left( \frac{g(X)}{f(X)} \right) &= E \left( \frac{g(X)^2}{f(X)^2} \right) - E^2 \left( \frac{g(X)}{f(X)} \right) \\ &= \int_A \frac{g^2(x)}{f(x)} dx - \theta^2. \end{aligned}$$

当取  $f(x) = \frac{|g(x)|}{\int_A |g(x)| dx}$  时方差最小。

- 为了使 Monte Carlo 估计  $\hat{\theta}$  的方差或者  $g(X)/f(X)$  的方差保持在较低的水平, 我们需要选取足够接近  $g(x)$  的重要函数  $f(x)$ 。

### 例 1.4

Question: 利用不同的重要函数估计积分

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx.$$

考虑如下重要函数:

1. (简单抽要)  $f_1(x) = 1, 0 < x < 1;$

2. (指数分布)  $f_2(x) = e^{-x}, 0 < x < \infty$ ;
3. (Cauchy 分布)  $f_3(x) = \frac{1}{\pi(1+x^2)}, -\infty < x < \infty$ ;
4.  $f_4(x) = e^{-x}(1 - e^{-1})^{-1}, 0 < x < 1$ ;
5.  $f_5(x) = \frac{4}{\pi(1+x^2)}, 0 < x < 1$ .

```

m <- 10000
theta.hat <- se <- numeric(5)
g <- function(x) {
  exp(-x - log(1+x^2)) * (x > 0) * (x < 1)
}

x <- runif(m) #using f1
fg <- g(x)
theta.hat[1] <- mean(fg)
se[1] <- sd(fg)

x <- rexp(m, 1) #using f2
fg <- g(x) / exp(-x)
theta.hat[2] <- mean(fg)
se[2] <- sd(fg)

x <- rcauchy(m) #using f3
i <- c(which(x > 1), which(x < 0))
x[i] <- 2 #to catch overflow errors in g(x)
fg <- g(x) / dcauchy(x)
theta.hat[3] <- mean(fg)
se[3] <- sd(fg)

u <- runif(m) #f4, inverse transform method
x <- -log(1 - u * (1 - exp(-1)))
fg <- g(x) / (exp(-x) / (1 - exp(-1)))
theta.hat[4] <- mean(fg)
se[4] <- sd(fg)

u <- runif(m) #f5, inverse transform method
x <- tan(pi * u / 4)
fg <- g(x) / (4 / ((1 + x^2) * pi))
theta.hat[5] <- mean(fg)
se[5] <- sd(fg)

```



```
options(width = 60)
rbind(theta.hat, se)

##           [,1]      [,2]      [,3]      [,4]
## theta.hat 0.5280149 0.5249207 0.5153658 0.52348606
## se        0.2451720 0.4188943 0.9448084 0.09676422
##           [,5]
## theta.hat 0.5229014
## se        0.1410423
```

结论:

- 对于函数  $f_2(x)$  和  $f_3(x)$ , 由于支撑集远比  $[0, 1]$  大, 从而会导致大量样本  $g(x_i)/f(x_i)I([0, 1])$  为 0, 进而导致方差  $\text{Var}[g(X)/f(X)]$  过大。
- 函数  $f_4(x)$  和  $f_5(x)$  则由于和函数  $g(x) = \frac{e^{-x}}{1+x^2}$  分别共享了分子与分母, 因此形状更为接近, 从而缩减了方差  $\text{Var}[g(X)/f(X)]$ 。

## 1.7 分层抽样法

我们总是可以把一个积分拆分成在不同不相交区间上的积分之和。以积分

$$\theta = \int_0^1 \frac{e^{-x}}{1+x^2} dx$$

为例, 该积分可以写成如下形式

$$\begin{aligned} \theta &= \frac{1}{4} \left( 4 \int_0^{1/4} \frac{e^{-x}}{1+x^2} dx + 4 \int_{1/4}^{1/2} \frac{e^{-x}}{1+x^2} dx \right. \\ &\quad \left. + 4 \int_{1/2}^{3/4} \frac{e^{-x}}{1+x^2} dx + 4 \int_{3/4}^1 \frac{e^{-x}}{1+x^2} dx \right) \\ &= \frac{1}{4} (\theta_1 + \theta_2 + \theta_3 + \theta_4). \end{aligned}$$

- 如果分层抽样来分别估计  $\theta_1, \theta_2, \theta_3, \theta_4$ , 则

$$\begin{aligned} \theta_1 &= E(g(U^{(1)})), \quad U^{(1)} \sim \text{Unif}(0, 1/4), \\ \theta_2 &= E(g(U^{(2)})), \quad U^{(2)} \sim \text{Unif}(1/4, 1/2), \\ \theta_3 &= E(g(U^{(3)})), \quad U^{(3)} \sim \text{Unif}(1/2, 3/4), \\ \theta_4 &= E(g(U^{(4)})), \quad U^{(4)} \sim \text{Unif}(3/4, 1). \end{aligned}$$

对于每层, 生成  $m' = m/4$  个样本:

$$\begin{aligned} U_i^{(1)} &\sim \text{Unif}(0, 1/4), \quad U_i^{(2)} \sim \text{Unif}(1/4, 1/2), \\ U_i^{(3)} &\sim \text{Unif}(1/2, 3/4), \quad U_i^{(4)} \sim \text{Unif}(3/4, 1), \end{aligned}$$

这里  $i = 1, \dots, m'$ .

- 相应的 Monte Carlo 估计量为

$$\begin{aligned}\hat{\theta}_1 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(1)}), & \hat{\theta}_2 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(2)}), \\ \hat{\theta}_3 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(3)}), & \hat{\theta}_4 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(4)}).\end{aligned}$$

- 通过分层抽样得到的  $\theta$  的估计量为  $\hat{\theta}' = \frac{1}{4} \sum_{k=1}^4 \hat{\theta}_k$ .
- 如果直接估计  $\theta$ , 则  $\theta = E(g(U))$ , 这里  $U \sim \text{Unif}(0, 1)$ ,  $g(x) = e^{-x}/(1+x^2)$ 。则 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m g(U_i), \quad U_i \sim \text{Unif}(0, 1), \quad i = 1, \dots, m.$$

- 比较两种 Monte Carlo 估计量的期望和方差

– 期望:

$$E(\hat{\theta}) = \theta, \quad E(\hat{\theta}') = \frac{1}{4} \sum_{k=1}^4 E(\hat{\theta}^{(k)}) = \frac{1}{4} \sum_{k=1}^4 \theta_k = \theta.$$

– 方差:

$$\text{Var}(\hat{\theta}) = \frac{1}{m} \text{Var}(g(U_i)), \quad \text{Var}(\hat{\theta}') = \frac{1}{16} \sum_{k=1}^4 \text{Var}(\hat{\theta}_k),$$

由于对于每个  $k$ ,

$$\text{Var}(\hat{\theta}_k) = \frac{4}{m} \text{Var}(g(U_i^{(k)})),$$

则

$$\text{Var}(\hat{\theta}') = \frac{1}{4m} \sum_{k=1}^4 \text{Var}(g(U_i^{(k)})).$$

- 由于我们进行了分层抽样, 相比于  $U_i$ ,  $U_i^{(k)}$  是在更小的区间 (层) 上进行抽样, 则  $\text{Var}(g(U_i^{(k)})) \leq \text{Var}(g(U_i))$ , 因此

$$\text{Var}(\hat{\theta}') \leq \frac{1}{4m} \sum_{k=1}^4 \text{Var}(g(U_i)) = \text{Var}(\hat{\theta}).$$

- 通过这个直观的例子, 我们可以看出通过将积分分割成多个区间上的小积分, 并进行分层抽样对每个小积分做 Monte Carlo 估计, 可以降低 Monte Carlo 估计量的方差。

```
n <- 500 # sample size
m <- 1000 # number of Monte Carlo
T2 <- numeric(4)
estimates <- matrix(0, m, 2)
g <- function(x) {exp(-x - log(1+x^2))}
for (i in 1:m) {
  estimates[i, 1] <- mean(g(runif(n)))
  T2[1] <- mean(g(runif(n/4, 0, .25)))
}
```

```
T2[2] <- mean(g(runif(n/4, .25, .5)))
T2[3] <- mean(g(runif(n/4, .5, .75)))
T2[4] <- mean(g(runif(n/4, .75, 1)))
estimates[i, 2] <- mean(T2)
}
apply(estimates, 2, mean)

## [1] 0.5249950 0.5247453

apply(estimates, 2, var)

## [1] 1.249068e-04 8.032615e-06
```

## 1.8 解释

- 本质上分层抽样就是把参数  $\theta = E(g(X))$  写成  $\theta = E\{E(g(X) | I)\}$ , 再进行两步 Monte Carlo 估计。
  - 第一步: 在每一层 ( $I = k$ ) 中, 给出  $E(g(X) | I = k)$  的 Monte Carlo 估计;
  - 第二步: 将  $E(g(X) | I)$  记为  $h(I)$ , 则  $\theta = E(h(I))$ , 给出  $E(h(I))$  的 Monte Carlo 估计。
- 如下定理给出更严谨的解释 (证明见《统计计算使用 R》5.7 节):

*Theorem 4.* 考虑参数  $\theta = E(g(X))$  的 Monte Carlo 估计。记  $\hat{\theta}^m$  为基于  $m$  个独立同分布样本的简单 Monte Carlo 估计量,  $\hat{\theta}_k$  为第  $k$  层参数  $\theta_k = E(X | I = k)$  的 Monte Carlo 估计量, 这里  $k = 1, \dots, K$ 。假设每层估计样本量相等, 即  $m_k = m/K$ 。记分层估计量为  $\hat{\theta}^s = \frac{1}{K} \sum_{k=1}^K \hat{\theta}_k$ 。则

$$\text{Var}(\hat{\theta}^s) \leq \text{Var}(\hat{\theta}^m).$$

- 回顾混合模型的知识, 我们可以将均匀分布变量  $U \sim \text{Unif}(0, 1)$  写成一个混合模型, 即

$$U \sim \frac{1}{4}U^{(1)} + \frac{1}{4}U^{(2)} + \frac{1}{4}U^{(3)} + \frac{1}{4}U^{(4)},$$

这里  $U^{(1)} \sim \text{Unif}(0, \frac{1}{4})$ ,  $U^{(2)} \sim \text{Unif}(\frac{1}{4}, \frac{1}{2})$ ,  $U^{(3)} \sim \text{Unif}(\frac{1}{2}, \frac{3}{4})$ ,  $U^{(4)} \sim \text{Unif}(\frac{3}{4}, 1)$ 。记潜变量  $I$  为在  $\{1, 2, 3, 4\}$  上的均匀分布, 指示  $U$  具体服从那个分布, 即如果  $I = k$ , 则  $U \sim U^{(k)}$ 。根据  $U$  的混合模型, 我们知道

$$\begin{aligned} U | (I = 1) &\sim \text{Unif}(0, 1/4), & U | (I = 2) &\sim \text{Unif}(1/4, 1/2), \\ U | (I = 3) &\sim \text{Unif}(1/2, 3/4), & U | (I = 4) &\sim \text{Unif}(3/4, 1). \end{aligned}$$

- 根据 Theorem 4 可知  $\hat{\theta}'$  的方差比  $\hat{\theta}$  小。

## 2 小结

本讲的主要内容包括:

- 蒙特卡罗方法的方差缩减。