

STAT3003: 统计算法基础

蒙特卡洛方法 (3)

曾靖

中国科学技术大学管理学院

大纲

1. 方差缩减

本节内容来自于《统计计算使用 R 》第 5 章,《统计方法》3.3 小节

1 蒙特卡罗方法的方差缩减

1.1 增大样本数

- 一般地，对于参数 θ 的 Monte Carlo 估计步骤如下：
 - 对于第 j 次 Monte Carlo 试验，得到估计量 $\hat{\theta}^{(j)}$;
 - 重复上述过程 m 次，得到 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(m)}$;
 - Monte Carlo 估计量 $\hat{\theta} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}^{(j)}$.

估计量的方差

$$\text{Var}(\hat{\theta}) = \frac{1}{m} \text{Var}(\hat{\theta}^{(j)}).$$

- 最简单的方差缩减方法即为增大试验次数 m 。然而这种方法的计算代价很大：如果要把 $\hat{\theta}$ 的标准差缩小 100 倍，试验次数 m 则要增加 $100^2 = 10,000$ 倍。

1.2 对偶变量法：一元情况

- 我们考虑 $\theta = E(h(X))$ ，这里 $X \in \mathbb{R}$ 。令 $x_1, \dots, x_m$ 为与 X 同分布的 i.i.d. 样本，则 θ 的 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m h(x_i).$$

- 考虑两个随机变量 $X_1, X_2 \sim X$ ，则平均值 $(h(X_1) + h(X_2))/2$ 的方差为

$$\begin{aligned} & \text{Var} \left(\frac{h(X_1) + h(X_2)}{2} \right) \\ &= \frac{1}{4} (\text{Var}(h(X_1)) + \text{Var}(h(X_2)) + 2\text{Cov}(h(X_1), h(X_2))). \end{aligned}$$

- 若 $h(X_1)$ 和 $h(X_2)$ 具有负相关性，则平均值 $\frac{h(X_1) + h(X_2)}{2}$ 可以被降低。

Theorem 1. 设 $g(x)$ 为单调函数, $U \sim \text{Unif}(0, 1)$, 则 $\text{Cov}(g(U), g(1 - U)) \leq 0$.

- 记随机变量 X 的 CDF 为 $F(x)$, 生成 $U \sim \text{Unif}(0, 1)$, 则随机变量 $F^{-1}(U), F^{-1}(1 - U) \sim X$ 。
- 根据 Theorem 1, 如果 h 为单调函数, 则 $h(F^{-1}(U))$ 和 $h(F^{-1}(1 - U))$ 同分布于 $h(X)$ 且具有负相关性
- 因此, 只要生成一个样本 U , 我们就可以构造出两个与 $h(X)$ 同分布且负相关的样本。

- 更一般地，我们有如下定理：

Theorem 2. 设 $f(x), g(x)$ 同单调增或同单调减, 则对于任何随机变量 X 我们有 $\text{Cov}(f(X), g(X)) \geq 0$.

1.2 对偶变量法：多元情况

- 接下来我们考虑参数 $\theta = E(h(X_1, \dots, X_n))$ 。

Definition 1: 如果对于所有 $j = 1, \dots, n$, 我们有 $x_j \leq y_j$, 则记 $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$ 。

Definition 2: 如果对于 $(x_1, \dots, x_n) \leq (y_1, \dots, y_n)$ 我们有 $g(x_1, \dots, x_n) \leq g(y_1, \dots, y_n)$, 则称 n 元函数 $g = g(x_1, \dots, x_n)$ 称为单调增。类似可定义单调减的 n 元函数。如果 n 元函数是单调增的或单调减的, 则称该函数为单调的。

Theorem 3. 设 f, g 为关于 $(x_1, \dots, x_n)$ 的同单调递增或递减函数, 对任何多元随机变量 $(X_1, \dots, X_n)$ 且 X_j 之间相互独立, 我们有 $\text{Cov}(f(X_1, \dots, X_n), g(X_1, \dots, X_n)) \geq 0$.

- 根据 Theorem 3, 取 $f(x_1, \dots, x_n) = -g(1 - x_1, \dots, 1 - x_n)$, 我们有如下推论。

Corollary 1. 设 $g(x_1, \dots, x_n)$ 为关于 $(x_1, \dots, x_n)$ 的单调函数, $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$ 且 U_i 间相互独立, 则 $\text{Cov}(g(U_1, \dots, U_n), g(1 - U_1, \dots, 1 - U_n)) \leq 0$.

- 记每个随机变量 X_i 的 CDF 为 $F_i(x), i = 1, \dots, n$, 如果 $h(x_1, \dots, x_n)$ 为单调函数, 则 $h(F_1^{-1}(u_1), \dots, F_n^{-1}(u_n))$ 也是单调函数。
- 生成 $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$ 且 U_i 间相互独立。随机变量 $h(F_1^{-1}(U_1), \dots, F_n^{-1}(U_n))$ 和 $h(F_1^{-1}(1 - U_1), \dots, F_n^{-1}(1 - U_n))$ 同分布于 $h(X_1, \dots, X_n)$ 并且两者存在负相关关系。

- 对于目标参数 $\theta = E(h(X_1, \dots, X_n))$, 假设 h 是单调的, 利用对偶变量法得到 Monte Carlo 估计
 - 独立生成 n 个均匀分布变量 $U_i \sim \text{Unif}(0, 1), i = 1, \dots, n$;
 - 构造随机变量 $Y_j = h(F_1^{-1}(U_1), \dots, F_n^{-1}(U_n))$;
 - 构造对偶变量 $Y_j^+ = h(F_1^{-1}(1 - U_1), \dots, F_n^{-1}(1 - U_n))$, 则 $Y_j, Y_j^+ \sim h(X_1, \dots, X_n)$ 且 Y_j, Y_j^+ 负相关;
 - 重复上述步骤 $m/2$ 次, 构造对偶 Monte Carlo 估计量

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^{m/2} (Y_j + Y_j^+).$$

结论:

- 对偶 Monte Carlo 估计量仍是 θ 的无偏估计
- 只要保证 $U_1, \dots, U_n$ 相互独立, 并且 h 单调, 则根据 Theorem 2 可知对偶 Monte Carlo 估计量方差会得到缩减。
- 相比于仅单 Monte Carlo 估计 $\hat{\theta} = \frac{1}{m} \sum_{j=1}^m Y_j$, 对偶 Monte Carlo 估计只需要重复 $m/2$ 次模拟实验, 就可以得到更有效率 (方差更小) 的估计量。

特例：

- 如果 $X_i, i = 1, \dots, n$, 服从正态分布，我们不需要借助均匀分布变量，利用正态分布的对称性直接构造对偶变量。
- 假设 $X_i \sim N(\mu_i, \sigma^2), i = 1, \dots, n$, h 是单调函数。令 $Z_i = 2\mu_i - X_i$ ，则可证明 $Y_j = h(X_1, \dots, X_n)$ 与 $Y_j^+ = h(Z_1, \dots, Z_n)$ 同分布于 $h(X_1, \dots, X_n)$ 且负相关。
- 对偶 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^{m/2} (Y_j + Y_j^+).$$

例 1.1 积分估计

Question: 利用对偶方法估计积分

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

令 $\theta = E[xe^{-(xU)^2/2}]$, 这里 $U \sim \text{Unif}(0, 1)$ 。如果 $x > 0$, $\Phi(x) = 0.5 + \theta/\sqrt{2\pi}$; 如果 $x < 0$, $\Phi(x) = 1 - \Phi(-x)$ 。则问题转化为估计参数 θ 。

```
MC.Phi <- function(x, m = 10000, antithetic = TRUE){  
  u <- runif(m/2)  
  if (!antithetic) v <- runif(m/2)  
  else v <- 1 - u  
  u <- c(u, v)  
  cdf <- numeric(length(x))  
  for (i in 1:length(x)) {  
    g <- x[i] * exp(-(u * x[i])^2 / 2)  
    cdf[i] <- mean(g) / sqrt(2 * pi) + 0.5  
  }  
  cdf  
}
```



```
x <- seq(.1, 2.5, length=5)
Phi <- pnorm(x)
MC1 <- MC.Phi(x, antithetic = FALSE) # 非对偶法
MC2 <- MC.Phi(x) # 对偶法
print(round(rbind(x, MC1, MC2, Phi), 5))
```

	[,1]	[,2]	[,3]	[,4]	[,5]
## x	0.10000	0.70000	1.30000	1.90000	2.50000
## MC1	0.53983	0.75795	0.90293	0.97116	0.99439
## MC2	0.53983	0.75804	0.90323	0.97131	0.99378
## Phi	0.53983	0.75804	0.90320	0.97128	0.99379

Question: 通过 *Monte Carlo* 来估计非对偶估计和对偶估计的方差。

思考：有哪些 Monte Carlo 估计方法？

```
m <- 1000
MC1 <- MC2 <- numeric(m)
x <- 1.95
for (i in 1:m) {
  MC1[i] <- MC.Phi(x, m = 1000, antithetic = FALSE)
  MC2[i] <- MC.Phi(x, m = 1000)
}
print(var(MC1))
```

```
## [1] 5.186911e-05
```

```
print(var(MC2))
```

```
## [1] 2.040312e-07
```

```
print(var(MC2)/var(MC1))
```

```
## [1] 0.003933578
```

1.3 控制变量法

- 我们考虑参数 $\theta = E(g(X))$ 的情况，这里 X 是一元变量。如果我们已知关于 X 的另一个函数 $f(X)$ 的期望 $\mu = E(f(X))$ ，那么构造新的变量

$$Y = g(X) + c(f(X) - \mu).$$

构造变量 Y 是 θ 的无偏估计，这里称 $f(X)$ 为 $g(X)$ 的控制变量。

- 构造变量 Y 的方差为

$$\text{Var}(Y) = \text{Var}(g(X)) + c^2 \text{Var}(f(X)) + 2c \text{Cov}(g(X), f(X)).$$

- 通过选取恰当的控制变量 $f(X)$ 和 c ，我们可以从样本 $\{x_1, \dots, x_n\}$ 中得到一系列新的构造变量样本 $\{y_1, \dots, y_n\}$ 。参数估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m y_i = \frac{1}{m} \sum_{i=1}^m \{g(x_i) + c(f(x_i) - \mu)\}.$$

- 取

$$c = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))},$$

可以得到构造变量 Y 的方差最小，为

$$\text{Var}(Y) = \text{Var}(g(X)) - \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}(f(X))}.$$

- 因此，方差缩减比为

$$\begin{aligned}\frac{\text{Var}(g(X)) - \text{Var}(Y)}{\text{Var}(g(X))} &= \frac{\text{Cov}^2(g(X), f(X))}{\text{Var}(g(X))\text{Var}(f(X))} \\ &= \text{Corr}^2(g(X), f(X)).\end{aligned}$$

- 通过增大 $f(X)$ 和 $g(X)$ 的相关性，可以降低构造变量 Y 的方差。
- 缺陷：需要计算 $E(f(X))$, $\text{Cov}(g(X), f(X))$ 和 $\text{Var}(f(X))$ ，往往需要额外的 Monte Carlo 模拟来进行估计；并且， μ 往往需要已知，否则也需要额外的模拟来估计。
- 因此，在选择 $f(X)$ 时，我们希望 $f(X)$ 和 $g(X)$ 尽量相似，并且 $E(f(X))$, $\text{Cov}(g(X), f(X))$ 和 $\text{Var}(f(X))$ 尽量好计算。

例 1.2

Question: 利用控制变量方法估计积分

$$\theta = \int_0^1 e^u du.$$

- 该问题等价于估计参数 $\theta = E(g(U)) = E(e^U)$, 这里函数 $g(x) = e^x, U \sim \text{Unif}(0, 1)$ 。
- 为了增大相关性, 变量 $g(U)$ 的一个自然的控制变量为 $f(U) = U$ 。因此,

$$E(f(U)) = 0.5, \quad \text{Var}(f(U)) = 1/12, \\ \text{Cov}(g(U), f(U)) = 1 - (1/2)(e - 1).$$

- 接着可以计算

$$c = -\frac{\text{Cov}(g(X), f(X))}{\text{Var}(f(X))} = -12 - 6(e - 1).$$

- 构造变量为

$$Y = e^U + c(U - 0.5)$$


```
m <- 10000
a <- - 12 + 6 * (exp(1) - 1)
U <- runif(m)
T1 <- exp(U)
T2 <- exp(U) + a * (U - 1/2) ## 控制变量方法
mean(T1)
```

```
## [1] 1.710791
```

```
mean(T2)
```

```
## [1] 1.719018
```

```
(var(T1) - var(T2)) / var(T1)
```

```
## [1] 0.9838001
```

1.4 重要抽样法

- 对于积分 $\theta = \int_A g(x)dx$ 的简单 Monte Carlo 估计如下：

$$\hat{\theta} = \frac{|A|}{m} \sum_{i=1}^m g(u_i), \quad u_i \sim \text{Unif}(A),$$

- 该方法会有如下三点问题：
 1. 这种方法无法应用到无限区间 A 上；
 2. 当存在很多 $g(u) \approx 0$ 的区域时，会造成很多样本的浪费；
 3. 当函数 $g(u)$ 在区间 A 上不平稳时， $g(u)$ 的方差会很大。

1.4 重要抽样法

- 为了解决如上问题，针对 $g(u)$ 的不同取值，赋予其不同的权重，使得在 $|g(u)|$ 大的地方赋小权重，在 $|g(u)|$ 小的地方赋大权重，从而提高样本利用率并且降低方差。这种方法叫做重要抽样法 (*Importance Sampling*)。
 - 在简单 Monte Carlo 抽样中，权重都为 $1/m$ 。

- 假设随机变量 X 的密度函数为 $f(x)$ ，且支撑在 A 上。我们把问题转化为估计

$$\theta = \int_A g(x)dx = \int_A \frac{g(x)}{f(x)} f(x)dx = E[g(X)/f(X)].$$

其中，函数 $f(x)$ 被称为重要函数。这里， $1/f(X)$ 可以看作权重。

- 重要抽样估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m \frac{g(x_i)}{f(x_i)}, \quad x_1, \dots, x_m \sim X.$$

- 从赋权重的角度来说, 我们希望 $f(x)$ 与 $g(x)$ 足够相似, 这样在 $|g(x)|$ 比较小的地方权重 $1/f(x)$ 会比较大, 在 $|g(x)|$ 比较大的地方权重 $1/f(x)$ 会比较小, 从而减小 Monte Carlo 估计的方差。
- 另一方面, 我们可以计算 $g(X)/f(X)$ 的方差为

$$\begin{aligned}\text{Var} \left(\frac{g(X)}{f(X)} \right) &= E \left(\frac{g(X)^2}{f(X)^2} \right) - E^2 \left(\frac{g(X)}{f(X)} \right) \\ &= \int_A \frac{g^2(x)}{f(x)} dx - \theta^2.\end{aligned}$$

当取 $f(x) = \frac{|g(x)|}{\int_A |g(x)| dx}$ 时方差最小。

- 为了使 Monte Carlo 估计 $\hat{\theta}$ 的方差或者 $g(X)/f(X)$ 的方差保持在较低的水平, 我们需要选取足够接近 $g(x)$ 的重要函数 $f(x)$ 。

例 1.4

Question: 利用不同的重要函数估计积分

$$\int_0^1 \frac{e^{-x}}{1+x^2} dx.$$

考虑如下重要函数：

1. (简单抽要) $f_1(x) = 1, 0 < x < 1$;
2. (指数分布) $f_2(x) = e^{-x}, 0 < x < \infty$;
3. (Cauchy 分布) $f_3(x) = \frac{1}{\pi(1+x^2)}, -\infty < x < \infty$;
4. $f_4(x) = e^{-x}(1 - e^{-1})^{-1}, 0 < x < 1$;
5. $f_5(x) = \frac{4}{\pi(1+x^2)}, 0 < x < 1$.

```
m <- 10000
theta.hat <- se <- numeric(5)
g <- function(x) {
  exp(-x - log(1+x^2)) * (x > 0) * (x < 1)
}
```

```
x <- runif(m) #using f1
fg <- g(x)
theta.hat[1] <- mean(fg)
se[1] <- sd(fg)
```

```
x <- rexp(m, 1) #using f2
fg <- g(x) / exp(-x)
theta.hat[2] <- mean(fg)
se[2] <- sd(fg)
```

```
x <- rcauchy(m) #using f3  
i <- c(which(x > 1), which(x < 0))  
x[i] <- 2 #to catch overflow errors in g(x)  
fg <- g(x) / dcauchy(x)  
theta.hat[3] <- mean(fg)  
se[3] <- sd(fg)
```

```
u <- runif(m) #f4, inverse transform method  
x <- - log(1 - u * (1 - exp(-1)))  
fg <- g(x) / (exp(-x) / (1 - exp(-1)))  
theta.hat[4] <- mean(fg)  
se[4] <- sd(fg)
```

```
u <- runif(m) #f5, inverse transform method  
x <- tan(pi * u / 4)  
fg <- g(x) / (4 / ((1 + x^2) * pi))  
theta.hat[5] <- mean(fg)  
se[5] <- sd(fg)
```



```
options(width = 60)
rbind(theta.hat, se)
```

```
##           [,1]      [,2]      [,3]      [,4]
## theta.hat 0.5280149 0.5249207 0.5153658 0.52348606
## se        0.2451720 0.4188943 0.9448084 0.09676422
##           [,5]
## theta.hat 0.5229014
## se        0.1410423
```

结论：

- 对于函数 $f_2(x)$ 和 $f_3(x)$ ，由于支撑集远比 $[0, 1]$ 大，从而会导致大量样本 $g(x_i)/f(x_i)I([0, 1])$ 为 0，进而导致方差 $\text{Var}[g(X)/f(X)]$ 过大。
- 函数 $f_4(x)$ 和 $f_5(x)$ 则由于和函数 $g(x) = \frac{e^{-x}}{1+x^2}$ 分别共享了分子与分母，因此形状更为接近，从而缩减了方差 $\text{Var}[g(X)/f(X)]$ 。

1.5 分层抽样法

我们总是可以把一个积分拆分成在不同不相交区间上的积分之和。以积分

$$\theta = \int_0^1 \frac{e^{-x}}{1+x^2} dx$$

为例，该积分可以写成如下形式

$$\begin{aligned}\theta &= \frac{1}{4} \left(4 \int_0^{1/4} \frac{e^{-x}}{1+x^2} dx + 4 \int_{1/4}^{1/2} \frac{e^{-x}}{1+x^2} dx \right. \\ &\quad \left. + 4 \int_{1/2}^{3/4} \frac{e^{-x}}{1+x^2} dx + 4 \int_{3/4}^1 \frac{e^{-x}}{1+x^2} dx \right) \\ &= \frac{1}{4} (\theta_1 + \theta_2 + \theta_3 + \theta_4).\end{aligned}$$

- 如果分层抽样来分别估计 $\theta_1, \theta_2, \theta_3, \theta_4$, 则

$$\theta_1 = E(g(U^{(1)})), \quad U^{(1)} \sim \text{Unif}(0, 1/4),$$

$$\theta_2 = E(g(U^{(2)})), \quad U^{(2)} \sim \text{Unif}(1/4, 1/2),$$

$$\theta_3 = E(g(U^{(3)})), \quad U^{(3)} \sim \text{Unif}(1/2, 3/4),$$

$$\theta_4 = E(g(U^{(4)})), \quad U^{(4)} \sim \text{Unif}(3/4, 1).$$

对于每层, 生成 $m' = m/4$ 个样本:

$$U_i^{(1)} \sim \text{Unif}(0, 1/4), \quad U_i^{(2)} \sim \text{Unif}(1/4, 1/2),$$

$$U_i^{(3)} \sim \text{Unif}(1/2, 3/4), \quad U_i^{(4)} \sim \text{Unif}(3/4, 1),$$

这里 $i = 1, \dots, m'$.

- 相应的 Monte Carlo 估计量为

$$\begin{aligned}\hat{\theta}_1 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(1)}), & \hat{\theta}_2 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(2)}), \\ \hat{\theta}_3 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(3)}), & \hat{\theta}_4 &= \frac{1}{m'} \sum_{i=1}^{m'} g(U_i^{(4)}).\end{aligned}$$

- 通过分层抽样得到的 θ 的估计量为 $\hat{\theta}' = \frac{1}{4} \sum_{k=1}^4 \hat{\theta}_k$.

- 如果直接估计 θ , 则 $\theta = E(g(U))$, 这里 $U \sim \text{Unif}(0, 1)$, $g(x) = e^{-x}/(1+x^2)$ 。则 Monte Carlo 估计量为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m g(U_i), \quad U_i \sim \text{Unif}(0, 1), \quad i = 1, \dots, m.$$

- 比较两种 Monte Carlo 估计量的期望和方差

- 期望:

$$E(\hat{\theta}) = \theta, \quad E(\hat{\theta}') = \frac{1}{4} \sum_{k=1}^4 E(\hat{\theta}^{(k)}) = \frac{1}{4} \sum_{k=1}^4 \theta_k = \theta.$$

- 方差:

$$\text{Var}(\hat{\theta}) = \frac{1}{m} \text{Var}(g(U_i)), \quad \text{Var}(\hat{\theta}') = \frac{1}{16} \sum_{k=1}^4 \text{Var}(\hat{\theta}_k),$$

由于对于每个 k ,

$$\text{Var}(\hat{\theta}_k) = \frac{4}{m} \text{Var}(g(U_i^{(k)})),$$

则

$$\text{Var}(\hat{\theta}') = \frac{1}{4m} \sum_{k=1}^4 \text{Var}(g(U_i^{(k)})).$$

- 由于我们进行了分层抽样, 相比于 U_i , $U_i^{(k)}$ 是在更小的区间 (层) 上进行抽样, 则 $\text{Var}(g(U_i^{(k)})) \leq \text{Var}(g(U_i))$, 因此

$$\text{Var}(\hat{\theta}') \leq \frac{1}{4m} \sum_{k=1}^4 \text{Var}(g(U_i)) = \text{Var}(\hat{\theta}).$$

- 通过这个直观的例子, 我们可以看出通过将积分分割成多个区间上的小积分, 并进行分层抽样对每个小积分做 Monte Carlo 估计, 可以降低 Monte Carlo 估计量的方差。


```
n <- 500 # sample size
m <- 1000 # number of Monte Carlo
T2 <- numeric(4)
estimates <- matrix(0, m, 2)
g <- function(x) {exp(-x - log(1+x^2))}
for (i in 1:m) {
  estimates[i, 1] <- mean(g(runif(n)))
  T2[1] <- mean(g(runif(n/4, 0, .25)))
  T2[2] <- mean(g(runif(n/4, .25, .5)))
  T2[3] <- mean(g(runif(n/4, .5, .75)))
  T2[4] <- mean(g(runif(n/4, .75, 1)))
  estimates[i, 2] <- mean(T2)
}
apply(estimates, 2, mean)
```

```
## [1] 0.5249950 0.5247453
```

```
apply(estimates, 2, var)
```

```
## [1] 1.249068e-04 8.032615e-06
```

解释

- 本质上分层抽样就是把参数 $\theta = E(g(X))$ 写成 $\theta = E\{E(g(X) | I)\}$ ，再进行两步 Monte Carlo 估计。
 - 第一步：在每一层 ($I = k$) 中，给出 $E(g(X) | I = k)$ 的 Monte Carlo 估计；
 - 第二步：将 $E(g(X) | I)$ 记为 $h(I)$ ，则 $\theta = E(h(I))$ ，给出 $E(h(I))$ 的 Monte Carlo 估计。
- 如下定理给出更严谨的解释（证明见《统计计算使用 R》5.7 节）：

Theorem 4. 考虑参数 $\theta = E(g(X))$ 的 Monte Carlo 估计。记 $\hat{\theta}^m$ 为基于 m 个独立同分布样本的简单 Monte Carlo 估计量， $\hat{\theta}_k$ 为第 k 层参数 $\theta_k = E(g(X) | I = k)$ 的 Monte Carlo 估计量，这里 $k = 1, \dots, K$ 。假设每层估计样本量相等，即 $m_k = m/K$ 。记分层估计量为 $\hat{\theta}^s = \frac{1}{K} \sum_{k=1}^K \hat{\theta}_k$ 。则

$$\text{Var}(\hat{\theta}^s) \leq \text{Var}(\hat{\theta}^m).$$

- 回顾混合模型的知识, 我们可以将均匀分布变量 $U \sim \text{Unif}(0, 1)$ 写成一个混合模型, 即

$$U \sim \frac{1}{4}U^{(1)} + \frac{1}{4}U^{(2)} + \frac{1}{4}U^{(3)} + \frac{1}{4}U^{(4)},$$

这里 $U^{(1)} \sim \text{Unif}(0, \frac{1}{4})$, $U^{(2)} \sim \text{Unif}(\frac{1}{4}, \frac{1}{2})$, $U^{(3)} \sim \text{Unif}(\frac{1}{2}, \frac{3}{4})$, $U^{(4)} \sim \text{Unif}(\frac{3}{4}, 1)$ 。记潜变量 I 为在 $\{1, 2, 3, 4\}$ 上的均匀分布, 指示 U 具体服从那个分布, 即如果 $I = k$, 则 $U \sim U^{(k)}$ 。根据 U 的混合模型, 我们知道

$$\begin{aligned} U \mid (I = 1) &\sim \text{Unif}(0, 1/4), & U \mid (I = 2) &\sim \text{Unif}(1/4, 1/2), \\ U \mid (I = 3) &\sim \text{Unif}(1/2, 3/4), & U \mid (I = 4) &\sim \text{Unif}(3/4, 1). \end{aligned}$$

- 根据 Theorem 4 可知 $\hat{\theta}'$ 的方差比 $\hat{\theta}$ 小。