

STAT3003: 统计算法基础*

第 7 讲: 优化问题 (1)

曾靖

2026 年 9 月 1 日

目录

学习目标	2
1 最大似然估计	2
1.1 最大似然估计 (MLE)	2
2 Expectation-maximization (EM) 算法	2
2.1 应用: 聚类问题 (clustering)	4
2.2 EM 算法的收敛性	8
2.3 EM 算法的变种	8
3 小结	9

学习目标

学习后应能够：

- 理解并掌握“最大似然估计”的核心思想与计算方法；
- 理解并掌握“Expectation–maximization (EM) 算法”的核心思想与计算方法。

1 最大似然估计

1.1 最大似然估计 (MLE)

- 在参数估计中，一类重要的方法是最大似然估计 (MLE)。记随机变量 X 的密度函数为 $f(x | \theta)$ ，其中未知参数为 $\theta \in \mathbb{R}^p$ 。当给定样本 $x_1, \dots, x_n$ ，似然函数为

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta).$$

- 为了计算方便，我们通常考虑对数似然函数：

$$\ell(\theta) = \sum_{i=1}^n \ln f(x_i | \theta).$$

- MLE 通过求解最大化对数似然函数来估计参数 θ ：

$$\hat{\theta} = \max_{\theta \in \mathbb{R}^p} \ell(\theta).$$

- MLE 问题等价于如下的最小值问题：

$$\hat{\theta} = \min_{\theta} -\ell(\theta).$$

- 事实上，MLE 问题只是优化问题中的一个特例。一般地，前面所有的优化方法都可以用来求解 MLE 问题。而由于似然函数的特殊性（具有统计解释），我们可以采取一些特殊的方法去处理 MLE 问题。

2 Expectation–maximization (EM) 算法

- EM 算法主要用于求解 MLE 问题：

$$\hat{\theta} = \max_{\theta} \ell(\theta).$$

- 通常这些问题有如下组成部分：

Latent data + observed data + unknown parameters.

我们的任务是从可观测数据 (observed data) 中估计出未知参数。

- 潜在数据 (latent data) 通常包括两种情况：

- 缺失数据：数据在记录中丢失。
- 辅助数据：潜在数据包含一些重要信息，拥有这些信息会大大降低问题难度。比如在聚类问题中 (clustering)，我们假设数据本来是带有标签信息的，但是标签信息丢失了。如果已知样本的标签信息，会简化问题。
- 记观测数据为 X_{obs} ，缺失数据为 X_{miss} ，参数为 θ 。
- 在具有完整数据情况下的 MLE 问题为：

$$\arg \max_{\theta} \ell(\theta \mid X_{\text{obs}}, X_{\text{miss}}).$$

- 需要求解的 MLE 问题为：

$$\arg \max_{\theta} \ell(\theta \mid X_{\text{obs}}).$$

通常，该问题比具有完整数据的 MLE 问题要复杂的多。

- 直观的说，EM 算法的想法如下：
 1. 希望近似得到具有完整数据的对数似然函数 $\ell(\theta \mid X_{\text{obs}}, X_{\text{miss}})$ (E-step);
 2. 基于对数似然函数 $\ell(\theta \mid X_{\text{obs}}, X_{\text{miss}})$ 的近视估计得到 MLE 估计 (M-Step)。

EM 算法包含如下 E-step 和 M-step：

1. *Expectation step (E-step)* 如果已知缺失数据的条件分布 $f(X_{\text{miss}} \mid X_{\text{obs}}, \theta)$ ，并且已知 θ 的近似估计 $\theta^{(t)}$ ，那么可以通过期望的方式来估计具有完整数据的对数似然函数 $\ell(X_{\text{obs}}, X_{\text{miss}} \mid \theta)$ ，即

$$Q(\theta; \theta^{(t)}) = E\{\ell(\theta \mid X_{\text{obs}}, X_{\text{miss}})\},$$

这里期望是关于分布 $X_{\text{miss}} \mid (X_{\text{obs}}, \theta^{(t)})$ 的期望。

2. *Maximization step (M-step)* Q 函数 $Q(\theta; \theta^{(t)})$ 是关于具有完整数据的对数似然函数 $\ell(\theta \mid X_{\text{obs}}, X_{\text{miss}})$ 的近似。我们求解 $Q(\theta; \theta^{(t)})$ 的最大值来更新 θ ：

$$\theta_{t+1} = \max_{\theta} Q(\theta; \theta^{(t)}).$$

EM 算法：

1. Initialization: θ_0 .
2. For iteration $t = 0, 1, 2, \dots$,
3. E-step:

$$\begin{aligned} Q(\theta; \theta^{(t)}) &= E_{X_{\text{miss}} \mid (X_{\text{obs}}, \theta^{(t)})} \{\ell(\theta \mid X_{\text{obs}}, X_{\text{miss}})\} \\ &= \int \ell(\theta \mid X_{\text{obs}}, x_{\text{miss}}) f(x_{\text{miss}} \mid X_{\text{obs}}, \theta^{(t)}) dx_{\text{miss}}. \end{aligned}$$

4. M-step:

$$\theta_{t+1} = \max_{\theta} Q(\theta; \theta^{(t)}).$$

2.1 应用：聚类问题 (clustering)

- 假设随机变量 X 来自如下正态混合分布：

$$f(x | \theta) = \sum_{k=1}^K \pi_k f_k(x),$$

其中 $\pi_k > 0$, $\sum_{k=1}^K \pi_k = 1$, $f_k(x) \sim N(\mu_k, \sigma^2)$, 记参数

$$\theta = (\pi_1, \dots, \pi_K, \mu_1, \dots, \mu_K, \sigma^2).$$

- 若直接考虑 θ 的 MLE 分布，即求解

$$\hat{\theta} = \max_{\theta} \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k f_k(x_i) \right).$$

直接求解该 MLE 问题非常具有挑战性。

- 假设每个样本具有一个潜变量 $J_i \in \{1, \dots, K\}$, $\Pr(J_i = k) = \pi_k$, 并且 $x_i | (J_i = k) \sim N(\mu_k, \sigma^2)$ 。记 (x_i, J_i) 为完整数据。则完整数据的似然函数为

$$\begin{aligned} \ell(\theta | x_i, J_i, i = 1, \dots, n) &= \sum_{k=1}^K \sum_{i=1}^n I(J_i = k) \log\{\pi_k f_k(x_i)\} \\ &= \sum_{k=1}^K \sum_{i=1}^n I(J_i = k) \log(\pi_k) \\ &\quad - \frac{1}{2} \sum_{k=1}^K \sum_{i=1}^n I(J_i = k) \{\log \sigma^2 + (x_i - \mu_k)^2 / \sigma^2\} + \text{constant}. \end{aligned}$$

- 基于完整数据的 MLE 问题要简单得多。
- E-step: 由于

$$\begin{aligned} E(I(J_i = k) | x_i, \theta^{(t)}) &= \Pr(J_i = k | x_i, \theta^{(t)}) \\ &= \frac{\pi_k^{(t)} f_k^{(t)}(x_i)}{\sum_{k=1}^K \pi_k^{(t)} f_k^{(t)}(x_i)} := p_{ik}^{(t)}. \end{aligned}$$

则 Q 函数为：

$$\begin{aligned} Q(\theta | \theta^{(t)}) &= \sum_{k=1}^K \sum_{i=1}^n p_{ik}^{(t)} \log(\pi_k) \\ &\quad - \frac{1}{2} \sum_{k=1}^K \sum_{i=1}^n p_{ik}^{(t)} \{\log \sigma^2 + (x_i - \mu_k)^2 / \sigma^2\} + \text{constant}. \end{aligned}$$

- M step: 最大化 $Q(\theta | \theta^{(t)})$ 得到

$$\pi_k^{(t+1)} = \frac{1}{n} \sum_{i=1}^n p_{ik}^{(t)}, \quad \mu_k^{(t+1)} = \frac{\sum_{i=1}^n p_{ik}^{(t)} x_i}{\sum_{i=1}^n p_{ik}^{(t)}},$$

$$(\sigma^2)^{(t+1)} = \sum_{k=1}^K \sum_{i=1}^n p_{ik}^{(t)} (x_i - \mu_k^{(t+1)})^2 / n.$$

- 假设收集到一组样本 $x_1, \dots, x_n \sim X$. 如果参数 θ 已知, 则我们给每个样本赋标签

$$\phi(x_i) = \arg \max_{k \in \{1, \dots, K\}} \Pr(J_i = k \mid x_i, \theta^{(t)}).$$

- 注意, 在 EM 算法进行过程中, 每个样本 X_i 属于每个类别 k 的概率也在不断更新:

$$p_{ik}^{(t)} = \Pr(J_i = k \mid X_i, \theta^{(t)}),$$

因此, 样本的聚类结果也在不断更新. 第 t 步的聚类结果:

$$\phi^{(t)}(x_i) = \arg \max_{k \in \{1, \dots, K\}} p_{ik}^{(t)}.$$

例 2.1: 混合分布参数估计

考虑混合模型

$$X \sim \frac{1}{3} \text{Gamma}(\frac{1}{2}, \frac{1}{2\lambda_1}) + \frac{1}{3} \text{Gamma}(\frac{1}{2}, \frac{1}{2\lambda_2}) + \frac{1}{3} \text{Gamma}(\frac{1}{2}, \frac{1}{2\lambda_3}).$$

假设存在一个潜变量 $J \in \{1, 2, 3\}$, 使得 $\Pr(J = k) = 1/3, k = 1, 2, 3$, 且

$$X \mid J \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2\lambda_J}).$$

这里, 给定参数 $\alpha, \beta > 0$, Gamma 分布 $\text{Gamma}(\alpha, \beta)$ 的密度函数为

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0.$$

- 对于给定样本 $x_1, \dots, x_n$, 以及上一个迭代中的参数 $(\lambda_1^{(t)}, \lambda_2^{(t)}, \lambda_3^{(t)})$, 变量 J_i 的条件分布为

$$\Pr(J_i = k \mid x_i, \lambda^{(t)}) = \frac{\frac{1}{3} f_k(x_i; \lambda^{(t)})}{\sum_{j=1}^3 \frac{1}{3} f_j(x_i; \lambda^{(t)})}, \quad k = 1, 2, 3,$$

这里 f_j 为 $X \mid (J = j)$ 的密度函数。

- 定义

$$p_{ik}^{(t)} = \Pr(J_i = k \mid x_i, \lambda^{(t)}).$$

- Q 函数为

$$Q(\lambda \mid \lambda^{(t)}) = \sum_{i=1}^n \sum_{k=1}^3 \log f_k(x_i) p_{ik}^{(t)} + \text{constant}.$$

- Q 函数的解为

$$\lambda_k^{(t+1)} = \frac{\sum_{i=1}^n x_i p_{ik}^{(t)}}{\sum_{i=1}^n p_{ik}^{(t)}}, \quad k = 1, 2, 3.$$

```

set.seed(1)
m <- 3000
lambda <- c(.6, .25, .15)
lam <- sample(lambda, size = m, replace = TRUE)
x <- rgamma(m, shape = .5, rate = 1/(2*lam))

N <- 10000
L <- c(.5, .4, .1) # initialization
tol <- .Machine$double.eps^0.5
L.old <- L + 1

for (j in 1:N) {
  f1 <- dgamma(x, shape=1/2, rate=1/(2*L[1]))
  f2 <- dgamma(x, shape=1/2, rate=1/(2*L[2]))
  f3 <- dgamma(x, shape=1/2, rate=1/(2*L[3]))
  px <- f1 / (f1 + f2 + f3) #posterior prob x from 1
  qx <- f2 / (f1 + f2 + f3) #posterior prob x from 2
  rx <- f3 / (f1 + f2 + f3) #posterior prob x from 3
  lambda1 <- sum(x * px) / sum(px) #update means
  lambda2 <- sum(x * qx) / sum(qx)
  lambda3 <- sum(x * rx) / sum(rx)
  L <- c(lambda1, lambda2, lambda3) #update lambdas
  L <- L / sum(L)
  if (sum(abs(L - L.old)/L.old) < tol) break
  L.old <- L
}

print(list(lambda = L/sum(L), iter = j))

```

```

## $lambda
## [1] 0.6057854 0.2486534 0.1455612
##
## $iter
## [1] 470

```

例 2.2: Bayes 后验众数

- 考虑多项分布 $x = (x_1, x_2, x_3) \sim \text{Multinomial}(n, (2 + \theta)/4, (1 - \theta)/2, \theta/4)$, 参数 $\theta \sim \text{Beta}(a, b)$, $a, b > 0$ 是固定常数。

- 考虑后验分布众数

$$\begin{aligned}\hat{\theta} &= \max_{\theta} \ell(\theta|x) \\ &\propto \max_{\theta} \{\log f(x|\theta) + \log \pi(\theta)\}.\end{aligned}$$

- 给定参数 $\alpha, \beta > 0$, Beta 分布 $\text{Beta}(\alpha, \beta)$ 的密度函数为

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)},$$

这里 $B(\alpha, \beta)$ 为 Beta 函数。

- 相比于 MLE, 后验分布众数估计只是多了一项对数先验函数 $\log \pi(\theta)$.
- 对数后验函数为

$$\ell(\theta|x) = x_1 \log(2 + \theta) + (x_2 + b - 1) \log(1 - \theta) + (x_3 + a - 1) \log \theta.$$

- 分解 $x_1 = z_{11} + z_{12}$, 并记 z_{11} 为潜变量且服从二项分布 $z_{11} \sim \text{Binom}(x_1, 2/(2 + \theta))$ 。则 $(z_{11}, z_{12}, x_2, x_3) \sim \text{Multinomial}(n, 1/2, \theta/4, (1 - \theta)/2, \theta/4)$.
- 则基于数据 $y = (z_{11}, z_{12}, x_2, x_3)$ 的对数似然函数 $\ell(\theta|y) = (z_{12} + x_3 + a - 1) \log \theta + (x_2 + b - 1) \log(1 - \theta) + C$
- 计算 $E(z_{12} | x_1, \theta^{(t)}) = x_1 \theta^{(t)} / (2 + \theta^{(t)})$
- E-step: Q 函数为

$$\begin{aligned}Q(\theta | \theta^{(t)}) &= \{E(z_{12} | x_1, \theta^{(t)}) + x_3 + a - 1\} \log \theta \\ &\quad + (x_2 + b - 1) \log(1 - \theta) + C \\ &= \left(\frac{x_1 \theta^{(t)}}{2 + \theta^{(t)}} + x_3 + a - 1 \right) \log \theta + (x_2 + b - 1) \log(1 - \theta)\end{aligned}$$

- M-step:

$$\theta_{t+1} = \frac{\left(\frac{x_1 \theta^{(t)}}{2 + \theta^{(t)}} + x_3 + a - 1 \right)}{\left(\frac{x_1 \theta^{(t)}}{2 + \theta^{(t)}} + x_3 + a - 1 \right) + (x_2 + b - 1)}.$$

```
set.seed(1)
theta <- 0.5
n <- 100
x <- c(rmultinom(1,n,c((2+theta)/4,(1-theta)/2,theta/4)))
# prior paramters
a <- .01
b <- .01
theta <- rep(0,20)
theta[1] <- 0.2
```

```

for(t in 2:1000){
  num <- x[1] * theta[t-1]/(2 + theta[t-1])
  + x[3] + a - 1
  den <- x[1] * theta[t-1]/(2 + theta[t-1])
  + x[2] + x[3] + a + b - 2
  theta[t] <- num/den
}
theta[1000]

## [1] 1

```

2.2 EM 算法的收敛性

Theorem 1. 假设 $\theta^{(t)}$ 为 EM 算法中的迭代变量序列, 似然函数序列 $\ell(\theta^{(t)} | x)$ 关于 t 单调非减。

Key points:

1.

$$Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}) \leq \ell(\theta | X) - \ell(\theta^{(t)} | X).$$

2.

$$Q(\theta^{(t)} | \theta^{(t)}) \leq Q(\theta_{t+1} | \theta^{(t)}).$$

Conclusion:

$$\ell(\theta_{t+1} | X) \geq \ell(\theta^{(t)} | X).$$

- 由于似然函数序列 $\ell(\theta^{(t)} | x)$ 的单调性, $\ell(\theta^{(t)} | x)$ 总能收敛到极大似然函数的局部最大值点。但是不能保证收敛到全局最优解。

2.3 EM 算法的变种

广义 EM 算法

为了保证 $\ell(\theta^{(t)} | x)$ 的单调性, M-step 中求解最大值并不是必要的。事实上, 由于

$$Q(\theta | \theta^{(t)}) - Q(\theta^{(t)} | \theta^{(t)}) \leq \ell(\theta | X) - \ell(\theta^{(t)} | X)$$

恒成立, 只需要在 M-step 中找到 $\theta^{(t+1)}$ 使得

$$Q(\theta^{(t+1)} | \theta^{(t)}) \geq Q(\theta^{(t)} | \theta^{(t)}),$$

即可保证 $\ell(\theta^{(t)} | x)$ 的单调性。

这种 EM 算法称为广义 EM (generalized EM) 算法。

E-step 的 Monte Carlo 近似 (Monte Carlo EM)

- 在 E-step, 我们需要计算给定 $(X_{\text{obs}}, \theta^{(t)})$, $\ell(\theta | X_{\text{obs}}, X_{\text{miss}})$ 关于 X_{miss} 的条件期望, 即

$$Q(\theta | \theta^{(t)}) = E_{X_{\text{miss}} | (X_{\text{obs}}, \theta^{(t)})} \{ \ell(\theta | X_{\text{obs}}, X_{\text{miss}}) \}.$$

在有些情况下, 即使我们已知 $X_{\text{miss}} | (X_{\text{obs}}, \theta^{(t)})$ 的分布函数 $f(X_{\text{miss}} | X_{\text{obs}}, \theta^{(t)})$, E-step 中的条件期望仍然很难求出。

- 因此, 我们可以采用 Monte Carlo 方法近似估计条件期望。具体来说, 在第 t 步迭代中, 从分布 $f(X_{\text{miss}} | X_{\text{obs}}, \theta^{(t)})$ 中抽取 m_t 组缺失值样本 $X_{\text{miss}}^{(1)}, \dots, X_{\text{miss}}^{(m_t)}$, 从而估计 $Q(\theta | \theta^{(t)})$ 如下

$$\widehat{Q}(\theta | \theta^{(t)}) = \frac{1}{m_t} \sum_{i=1}^{m_t} \ell(\theta | X_{\text{obs}}, X_{\text{miss}}^{(i)})$$

Q -step 的梯度下降 (Gradient EM)

- 有些情况下, 即使 E-step 中的 Q 函数容易算出, 但是 M-step 中的最大值问题不容易计算。一种近似方法是使用一步 Newton 迭代:

$$\begin{aligned} \theta_{t+1} &= \theta^{(t)} - (Q''(\theta | \theta^{(t)})|_{\theta=\theta^{(t)}})^{-1} (Q'(\theta | \theta^{(t)})|_{\theta=\theta^{(t)}}) \\ &= \theta^{(t)} - (Q''(\theta | \theta^{(t)})|_{\theta=\theta^{(t)}})^{-1} (\ell'(\theta | X)|_{\theta=\theta^{(t)}}) \end{aligned}$$

3 小结

本讲的主要内容包括:

- 最大似然估计。
- Expectation-maximization (EM) 算法。