

STAT3003: 统计算法基础

自助法与交叉验证

曾靖

中国科学技术大学管理学院

大纲

1. 自助法
2. 交叉验证

本节内容来自于《统计计算使用 R 》第 7 章,《统计计算》第 3 章。

1 自助法 (Bootstrap)

1.1 自助法 (Bootstrap)

- Bootstrap 方法是一类非参数 *Monte Carlo* 方法，通过重抽样对总体分布进行估计。
- Bootstrap 的哲学思想是“让数据自己告诉我们答案”。
- Bootstrap 方法常用于目标总体分布未知的情况下。此时，通过反复从样本中（有放回地）重新抽样，产生大量伪样本，进而对实现对参数的估计。

- 回顾：如果抽样的概率分布非常明确，从概率分布中抽样的方法即为 Monte Carlo 方法。
- 记随机变量 $X \sim F(x)$, $x_1, \dots, x_n \sim X$ 为 n 个样本。记 $\theta = \theta(F)$ 为某个参数。
 - 统计量 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 用来估计参数 θ 。
 - 参数 $\psi = \psi(\hat{\theta}_n, F)$ 为统计量 $\hat{\theta}_n$ 的某个分布特征。
 - 例: $\theta = E(X)$, $\hat{\theta}_n = \sum_{i=1}^n x_i/n$, $\psi = \text{Var}(\hat{\theta}_n)$.

◦ 假定我们可以从已知分布 F 中重复抽样, 则我们可以用 Monte Carlo 方法估计 $\psi = \text{Var}(\hat{\theta}_n)$ 。估计的具体流程如下:

1. 根据 X 的分布生成 n 个样本 $\{x_1, \dots, x_n\}$, 得到估计量 $\hat{\theta} = \sum_{i=1}^n x_i/n$;
2. 独立重复上述过程 m 次, 并记每次得到的估计量为 $\hat{\theta}_1, \dots, \hat{\theta}_m$ 。
3. 估计 $E(\hat{\theta})$: $\bar{\hat{\theta}} = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$ 。
4. 计算 $\frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i - \bar{\hat{\theta}})^2$ 。

Question: 如果我们无法获得分布 F 的信息, 只有来自 F 分布的一组样本 $x_1, \dots, x_n$, 该如何去做?

- 当分布 F 未知, 通过用某个近似分布 $\widehat{F}$ 来替换 F , 估计 $\psi(\widehat{\theta}_n, \widehat{F})$ 。
- 在 **Bootstrap** 中, 我们通过一组样本 $x_1, \dots, x_n$ 估计 F , 得到 $\widehat{F}$ 。

$$\{x_1, \dots, x_n\} \longrightarrow \widehat{F},$$

并从 $\widehat{F}$ 中重复抽样。

- 在 **Bootstrap** 中, 可以采用参数模型, 也可以采用经验分布函数 (**edf**) 来估计 F 。如果采用采用经验分布函数来近似 F , 则相当于从原观测样本中有放回地重抽样。
- 给定 n 个样本 $\{X_1, \dots, X_n\}$, 经验分布函数 **edf** 为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i).$$

- **Glivenko–Cantelli** 定理告诉我们经验分布函数一致收敛到分布函数 (*a.s.*)

Bootstrap 估计 $\text{Var}(\hat{\theta})$ 的具体流程

1. 对于 $b = 1, \dots, B$, 从观测样本 $\{x_1, \dots, x_n\}$ 中有放回地抽出 n 个样本, 得到一组 **bootstrap** 样本 $x^{(b)} = \{x_1^{(b)}, \dots, x_n^{(b)}\}$;
2. 基于 **bootstrap** 样本 $x^{(b)}$ 得到估计量 $\hat{\theta}^{(b)}$;
3. 独立重复上述过程 B 次, 并记每次得到的估计量为 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)}$ 。
4. 估计 $E(\hat{\theta})$: $\bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{(b)}$.
5. 计算 $\frac{1}{B} \sum_{b=1}^B (\hat{\theta}^{(b)} - \bar{\hat{\theta}})^2$.

小结:

- 在现实生活中, 收集到的数据往往无法重复生成。Bootstrap 是帮助我们分析统计方法在真实数据上表现的重要工具。
- 由于 Bootstrap 方法的目标是 $\psi(\hat{\theta}_n, \hat{F})$, 当我们增大 Bootstrap 抽样次数, 只能保证估计 $\psi(\hat{\theta}_n, \hat{F})$ 的精度增加 (估计量的方差减小)。
- 然而, $\psi(\hat{\theta}_n, \hat{F})$ 和 $\psi(\hat{\theta}_n, F)$ 之间的误差始终存在。因此增大 Bootstrap 抽样次数也无法保证可以很好估计 $\psi(\hat{\theta}_n, F)$ 。
- 若观测样本本身可以很好反应总体分布, 即 $\hat{F} \approx F$, 那么 Bootstrap 方法可以提供 $\psi(\hat{\theta}_n, F)$ 的较好估计。

1.2 标准误差的 Bootstrap 估计

一个估计量 $\hat{\theta}_n$ 的标准误差的自助法估计是指重复试验 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(B)}$ 的样本标准误差

$$\hat{se}_B(\hat{\theta}_n) = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{(b)} - \bar{\hat{\theta}})^2}.$$

例 1.1

- `law82` 数据包含了美国 82 个法学院的入学测试成绩 (LSAT) 和 GPA 成绩的平均值。
- `law` 数据包含了美国 82 个法学院中随机抽取的 15 个法学院的入学测试成绩 (LSAT) 和 GPA 成绩的平均值。

Question: 基于样本 `law` 求样本相关系数的标准误差的 Bootstrap 估计。

- 对于 $b = 1, \dots, B$,
 1. 通过有放回的从 $x_1, \dots, x_n$ 中抽样得到再抽样样本 $x^{(b)} = \{x_1^{(b)}, \dots, x_n^{(b)}\}$
 2. 根据 $x^{(b)}$ 计算相关系数 $\rho^{(b)}$.
 3. 通过 $\rho^{(b)}, b = 1, \dots, B$, 计算标准误差。


```
options(width = 50)
data("law")
law$LSAT
```

```
## [1] 576 635 558 578 666 580 555 661 651 605 653
## [12] 575 545 572 594
```

```
law$GPA
```

```
## [1] 3.39 3.30 2.81 3.03 3.44 3.07 3.00 3.43 3.36
## [10] 3.13 3.12 2.74 2.76 2.88 2.96
```

```
law_data <- data.frame(LSAT = law$LSAT, GPA = law$GPA)
ggplot(law_data, aes(x = LSAT, y = GPA)) +
  geom_point() + theme_bw()
```



```
# Set up the bootstrap
B <- 200 # Number of bootstrapping
n <- nrow(law) # Sample size
R <- numeric(B)

for(b in 1:B){
  i <- sample(1:n, size=n, replace = TRUE)
  LSAT <- law$LSAT[i]
  GPA <- law$GPA[i]
  R[b] <- cor(LSAT, GPA)
}
print(se.R <- sd(R))
```

```
## [1] 0.1359863
```


- 也可以使用现成的函数，来自于 R 包 `boot` 和 `bootstrap`:

```
library(boot)
library(bootstrap)
r <- function(x, i) cor(x[i,1], x[i,2])
obj <- boot(data = law, statistic = r, R = 200)
sd(obj$t)
```

```
## [1] 0.1374336
```

```
obj
```

```
##  
## ORDINARY NONPARAMETRIC BOOTSTRAP  
##  
##  
## Call:  
## boot(data = law, statistic = r, R = 200)  
##  
##  
## Bootstrap Statistics :  
##      original      bias    std. error  
## t1* 0.7763745 -0.00443255  0.1374336
```

```
theta <- function(x,xdata){cor(xdata[x,1],xdata[x,2])}  
obj2 <- bootstrap(1:n, nboot = 200, theta = theta, law)  
sd(obj2$thetastar)
```

```
## [1] 0.1366922
```

1.3 偏差的自助法估计

- 一个估计量 $\hat{\theta}_n$ 的偏差为

$$bias(\hat{\theta}_n) = E(\hat{\theta}_n) - \theta.$$

- 由于现实生活中 θ 是未知的，我们考虑偏差的一个近似

$$bias_B(\hat{\theta}) = E_n(\hat{\theta}_n) - \hat{\theta}_n,$$

其中 E_n 是关于 $\hat{F}$ 的期望。

- 那么当重复 Bootstrap 抽样并计算 Bootstrap 估计量 $\hat{\theta}^{(b)}$, $b = 1, \dots, B$, 其均值 $E_n(\hat{\theta}_n)$ 是无偏估计。因此偏差的 Bootstrap 估计为

$$\widehat{bias}_B(\hat{\theta}_n) = \bar{\hat{\theta}} - \hat{\theta}_n,$$

其中 $\bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^{(b)}$ 。

例 1.2

```
R.hat <- cor(law$LSAT, law$GPA)
bias <- mean(R - R.hat)
bias
```

```
## [1] 0.01355344
```

```
mean(obj$t) - obj$t0 # boot 函数
```

```
## [1] -0.00443255
```

```
mean(obj2$thetastar) - R.hat
```

```
## [1] -0.0119045
```

例 1.3

比值参数估计的偏差的 *Bootstrap* 估计

(R package `bootstrap`: `patch` data) 该数据是测量了 8 个人使用 3 种不同的药物后血液中某种荷尔蒙的含量。这三种药物分别是安慰剂，旧药品（经过 FDA 审批的），新药品（某个新工厂相同的工艺下生产的，按 FDA 规定，新工厂生产的药品也要审批）。研究的目的是比较新药和旧药的等价性。如果可以证明新药和旧药之间的等价性，则对新药就不需要完全重新向 FDA 申请审批了。等价性的标准是对比值参数

$$\theta = \frac{E(new) - E(old)}{E(old) - E(placebo)}$$

若 $|\theta| \leq 0.20$ ，则新药和旧药就等价。估计 θ 的统计量为 $\bar{Y}/\bar{Z}$ 。这两个变量在 `patch` 数据中给出。我们的目标是计算此估计偏差的 *Bootstrap* 估计。

```
data(patch, package = "bootstrap")
n <- nrow(patch) #in bootstrap package
B <- 2000
theta.b <- numeric(B)
theta.hat <- mean(patch$y) / mean(patch$z)
#bootstrap
for (b in 1:B) {
  i <- sample(1:n, size = n, replace = TRUE)
  y <- patch$y[i]
  z <- patch$z[i]
  theta.b[b] <- mean(y) / mean(z)
}

bias <- mean(theta.b) - theta.hat
# se <- sd(theta.b)
print(bias)
```

```
## [1] 0.003696778
```

1.4 Bootstrap 估计在回归模型中的应用

- 考虑如下回归模型

$$y_i = h(x_i, \beta) + \epsilon_i, \quad i = 1, \dots, n,$$

这里 x_i 为给定数据, h 已知, β 为未知回归系数, $\epsilon_i \sim F$ 。

- 给定一组观测数据 $(y_i, x_i), i = 1, \dots, n$, 假设 $\hat{\beta}$ 为最小二乘估计量。如何估计 $\psi = \text{Var}(\hat{\beta})$?
- 由于 $x_i, i = 1, \dots, n$, 给定, 我们需要确定 F 的近似分布。
 - 用给定数据中得到的最小二乘估计量 $\hat{\beta}$ 代替 β ;
 - 从残差样本 $\hat{\epsilon}_i = y_i - h(x_i, \hat{\beta})$ 中估计 ϵ 的总体样本 F 。

回归模型系数标准误差的 *Bootstrap* 估计流程（残差自助法）

- 从样本 $(y_i, x_i), i = 1, \dots, n$, 中估计 $\hat{\beta}$;
- 计算残差样本 $\hat{\epsilon}_i = y_i - h(x_i, \hat{\beta}), i = 1, \dots, n$;
- 从估计残差样本中重复抽样, 得到 **Bootstrap** 样本 $\hat{\epsilon}^{(b)} = \{\hat{\epsilon}_1^{(b)}, \dots, \hat{\epsilon}_n^{(b)}\}$;
- 重新构造样本 $y_i^{(b)} = h(x_i, \hat{\beta}) + \hat{\epsilon}_i^{(b)}, i = 1, \dots, n$;
- 从 **Bootstrap** 样本 $(y_i^{(b)}, x_i), i = 1, \dots, n$, 中估计系数 $\hat{\beta}^{(b)}, b = 1, \dots, B$;
- 利用 **Bootstrap** 估计量 $\hat{\beta}^{(b)}, b = 1, \dots, B$, 来估计 $\text{Var}(\hat{\beta})$.

1.5 置信区间的 Bootstrap 估计

- 考虑某个参数 $\theta = \theta(F)$ 的置信区间。
- 常规做法：记 $(x_1, \dots, x_n)$ 为一组样本，构造 θ 的统计量 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 。假设存在变换 $W = h(\hat{\theta}_n, \theta)$ 使得 W 的分布与未知参数 θ 无关，例如 $W = \hat{\theta}_n - \theta$ 。通过求解 W 的分位数 $w_{\alpha/2}$ 和 $w_{1-\alpha/2}$ ，我们可以构造如下等式：

$$P(w_{\alpha/2} \leq W \leq w_{1-\alpha/2}) = \alpha.$$

反解上式可以构造出 θ 的置信区间。

- 如果 F 未知，我们往往无法得到 W 的准确分布。一个有效的方法就是利用 Bootstrap 来近似 W 的分布。
- 记 $(x_1^{(b)}, \dots, x_n^{(b)})$ 为 Bootstrap 样本， $\hat{\theta}_n^{(b)}$ 为第 b 个 Bootstrap 估计，那么当 $W = \hat{\theta}_n - \theta$ 时， $V = \hat{\theta}_n^{(b)} - \hat{\theta}_n$ 与 W 的分布可以近似 W 的分布。

- 置信区间的 **Bootstrap** 估计步骤如下：
 - 从样本 $x_i, i = 1, \dots, n$, 中估计 $\hat{\theta}_n$;
 - 从样本 $x_i, i = 1, \dots, n$, 中重复抽样, 得到 **Bootstrap** 样本 $x^{(b)} = \{x_1^{(b)}, \dots, x_n^{(b)}\}, b = 1, \dots, B$;
 - 基于 **Bootstrap** 样本得到 **Bootstrap** 估计量 $\hat{\theta}_n^{(b)}, b = 1, \dots, B$;
 - 计算 $\hat{\theta}_n^{(b)}$ 的样本下 $\alpha/2$ 和 $1 - \alpha/2$ 分位数 $\hat{\theta}_{\alpha/2}^{(b)}$ 和 $\hat{\theta}_{1-\alpha/2}^{(b)}$;
 - 构造 θ 的置信区间 $[2\hat{\theta}_n - \hat{\theta}_{1-\alpha/2}^{(b)}, 2\hat{\theta}_n - \hat{\theta}_{\alpha/2}^{(b)}]$.


2 交叉验证 (Cross Validation)

2.1 模型选择、模型评估

- 模型选择基于模型评估，通过评估模型的效果，来挑选出最适合数据的模型。
 - 例如考虑 m 个 Lasso 回归模型 $\{f_1, \dots, f_m\}$ ，其中每个 f_i 对应不同的 Lasso tuning parameter λ 。我们通过一些评估量来判断哪个模型最好。
- 更一般地，我们其实考虑的是从一系列拟合模型或估计量中选择最好的。
- 如果我们希望一个模型的预测效果好，则一般通过期望预测误差 (EPE; expected prediction error) 来评估模型。对于给定训练集 $T = \{(x_i, y_i), i = 1, \dots, n\}$ ，记 $\hat{f}$ 为从训练集上估计得到的估计量。记 (Y, X) 为一对新的样本，期望预测误差 (EPE; expected prediction error) 定义为：

$$E_T E\{L(Y, \hat{f}(X)) \mid T\}.$$

- EPE 评价模型的泛化能力。



- 红线描述期望预测误差与模型复杂度的关系：模型过于简单或者复杂，会导致 **underfitting** 或者 **overfitting**，都会导致模型泛化能力变差。
- 在 Lasso 回归问题中，模型复杂度对应 tuning parameter λ 。

- 当以预测准确度为目标时，模型选择的目标就是找到泛化能力最强的模型。
- 预测准确度不是所有统计任务的目标，有时候不仅要看预测，也要考虑模型的可解释性。例如，相对于大语言模型这类黑箱模型，传统的分类模型（线性判别、逻辑回归等）更加具有解释性。

如何估计红线，即期望预测误差 $E_T E\{L(Y, \hat{f}(X)) \mid T\}$?

- Monte Carlo 方法:

- 生成一组训练集 $\{(x_1^{(m)}, y_1^{(m)}), \dots, (x_{n_1}^{(m)}, y_{n_1}^{(m)})\}$ 和一组测试集 $\{(\tilde{x}_1^{(m)}, \tilde{y}_1^{(m)}), \dots, (\tilde{x}_{n_2}^{(m)}, \tilde{y}_{n_2}^{(m)})\}$, $m = 1, \dots, M$;
- 从训练集上得到估计量 $\hat{f}$, 并在测试集上估计

$$\text{error}^{(m)} = E\{L(Y, \hat{f}(X)) \mid T\} = \frac{1}{n_2} \sum_{i=1}^{n_2} L(\tilde{y}_i^{(m)}, \hat{f}(\tilde{x}_i^{(m)}))$$

- 估计期望预测误差

$$\frac{1}{M} \sum_{m=1}^M \text{error}^{(m)}.$$

2.2 交叉验证

- 当数据分布 F 未知时，我们无法利用 Monte Carlo 方法进行模型评估。
- 交叉验证 (Cross Validation) 通过分割有限数据来进行模型选择和模型评估。

交叉验证 (*cross-validation*)

- 对数据集做分割，得到训练集和测试集。
- 使用训练集样本进行建模，使用测试集对模型进行评估。近似得到预测误差

$$E\{L(Y, \hat{f}(X)) \mid T\}$$

的一个估计。

- 通过多次分割，并对每次分割得到的预测误差做平均，我们得到 EPE

$$E_T E\{L(Y, \hat{f}(X)) \mid T\}$$

的一个估计。

Holdout 方法

- 只对数据分割一次。其将数据随机分为训练集 (**training set**) 和测试集 (**testing set**) 两个子集。仅使用训练集样本进行建模, 然后通过测试集来对模型进行评估。
- 其优点是 **training/testing** 比例不依赖于重复次数。
- 其缺点是依赖于数据的分割方式, 某些点可能从不进入到测试集中。随机分割不同, 结果会波动。

- *K-fold cross-validation*: 对 holdout 方法的改进, 具体如下:
 - 将数据分割为 K 个不相交子集 (fold);
 - 每次将第 k 个子集被作为测试集, 其余的 $K - 1$ 个子集被作为训练集, 计算预测误差

$$\text{CV}_k(\hat{f}) = \frac{1}{n_k} \sum_{i=1}^{n_k} L(y_i, \hat{f}_k(x_i)),$$

这里 n_k 为第 k 个子集的样本个数, $\hat{f}_k$ 为在对应训练集上得到的估计量, L 为某损失函数。重复 K 次。

- 计算 K 次的平均误差

$$\text{CV}(\hat{f}) = \frac{1}{K} \sum_{k=1}^K \text{CV}_k(\hat{f}).$$

1

2

3

4

5

Train

Train

Testing

Train

Train

- *leave-one-out cross-validation (LOOCV)*: K -fold cross-validation 的一个特例 ($K = n$), 仅使用一个点作为测试集, 其余的点作为训练集。
- LOOCV 在每个 fold 上估计的 bias 很小, 但是由于每个 fold 上估计的相关性很大, 因此 LOOCV 估计的方差较大。相比而言, K -fold cross-validation 以增加 bias 为代价降低估计的 variance。

例 2.1：模型选择


包 DAAG 里的 `ironslag` 数据描述了两种方法 (chemical, magnetic) 测量含铁量的 53 次结果。本例我们使用 LOOCV 来进行模型选择。候选的模型有

1. 线性模型: $Y = \beta_0 + \beta_1 X + e.$
2. 二次模型: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + e.$
3. 指数模型: $\log(Y) = \log(\beta_0) + \beta_1 X + e.$
4. $\log - \log$ 模型: $\log(Y) = \beta_0 + \beta_1 \log(X) + e.$

```
library(DAAG)
data(ironslag)
magnetic <- ironslag$magnetic
chemical <- ironslag$chemical
a <- seq(10, 40, .1) #sequence for plotting fits


L1 <- lm(magnetic ~ chemical)
yhat1 <- L1$coef[1] + L1$coef[2] * a
fit1 <- data.frame(x = a, y = yhat1)
iron_data <- data.frame(chemical = chemical, magnetic = magnetic)
ggplot(iron_data, aes(x = chemical, y = magnetic)) +
  geom_point() +
  geom_line(data = fit1, aes(x = x, y = y), linewidth = 0.8) +
  labs(title = "Linear") + theme_bw()
```


Linear




```
L2 <- lm(magnetic ~ chemical + I(chemical^2))
yhat2 <- L2$coef[1] + L2$coef[2] * a + L2$coef[3] * a^2
fit2 <- data.frame(x = a, y = yhat2)
ggplot(iron_data, aes(x = chemical, y = magnetic)) +
  geom_point() +
  geom_line(data = fit2, aes(x = x, y = y), linewidth = 0.8) +
  labs(title = "Quadratic") + theme_bw()
```

Quadratic




```
L3 <- lm(log(magnetic) ~ chemical)
logyhat3 <- L3$coef[1] + L3$coef[2] * a
yhat3 <- exp(logyhat3)
fit3 <- data.frame(x = a, y = yhat3)
ggplot(iron_data, aes(x = chemical, y = magnetic)) +
  geom_point() +
  geom_line(data = fit3, aes(x = x, y = y), linewidth = 0.8) +
  labs(title = "Exponential") + theme_bw()
```

Exponential



```
L4 <- lm(log(magnetic) ~ log(chemical))
logyhat4 <- L4$coef[1] + L4$coef[2] * log(a)
fit4 <- data.frame(x = log(a), y = logyhat4)
iron_log_data <- data.frame(
  chemical = log(chemical), magnetic = log(magnetic)
)
ggplot(iron_log_data, aes(x = chemical, y = magnetic)) +
  geom_point() +
  geom_line(data = fit4, aes(x = x, y = y), linewidth = 0.8) +
  labs(title = "Log-Log") + theme_bw()
```

Log-Log



```
n <- length(magnetic)
e1 <- e2 <- e3 <- e4 <- numeric(n)
for (k in 1:n) {
  y <- magnetic[-k]; x <- chemical[-k]
  J1 <- lm(y ~ x)
  yhat1 <- J1$coef[1] + J1$coef[2] * chemical[k]
  e1[k] <- magnetic[k] - yhat1
  J2 <- lm(y ~ x + I(x^2))
  yhat2 <- J2$coef[1] + J2$coef[2] * chemical[k] +
    J2$coef[3] * chemical[k]^2
  e2[k] <- magnetic[k] - yhat2
  J3 <- lm(log(y) ~ x)
  logyhat3 <- J3$coef[1] + J3$coef[2] * chemical[k]
  yhat3 <- exp(logyhat3)
  e3[k] <- magnetic[k] - yhat3
  J4 <- lm(log(y) ~ log(x))
  logyhat4 <- J4$coef[1] + J4$coef[2] * log(chemical[k])
  yhat4 <- exp(logyhat4)
  e4[k] <- magnetic[k] - yhat4
}
```



```
c(mean(e1^2), mean(e2^2), mean(e3^2), mean(e4^2))
```

```
## [1] 19.55644 17.85248 18.44188 20.45424
```