ASTA6002
回归分析与数据思维

变量选择与结构化正则化

曾靖

中国科学技术大学

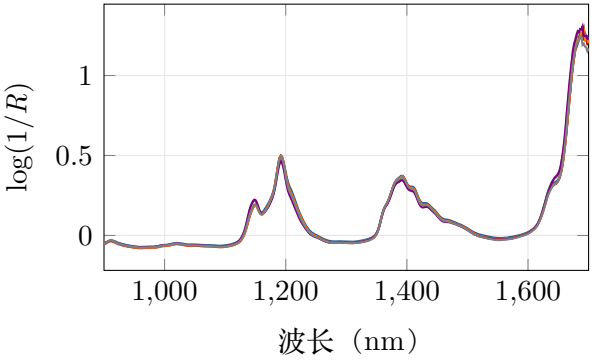
管理学院统计与金融系

学习目标

- 根据相关性、分组和变量顺序选择合适的惩罚。
- 比较 Elastic Net、Adaptive Lasso 与结构化变量选择方法。
- 用可复现的数值例子比较不同惩罚的作用。
- 运用软阈值、组软阈值与坐标更新计算系数。

1 Elastic Net

1.1 真实案例：用近红外光谱预测汽油辛烷值

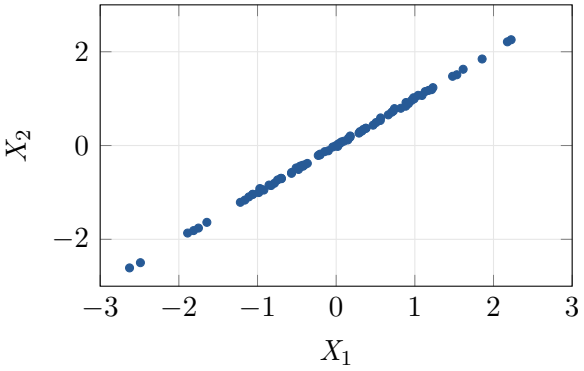


六个真实样本的近红外光谱

- 公开 gasoline 数据：60 个汽油样本，401 个波长特征。
- 响应：辛烷值；特征：不同波长处的光谱测量值。
- 相邻波长的信号变化相似，提供的信息可能高度重叠。

思考：若多个波长包含相似信息，Lasso 会稳定地选出同一批波长吗?

1.2 例子：高度相关的两个变量，Lasso 选谁?



- 模拟 $n = 80, p = 10$; $\beta^* = (1, 1, 0, \ldots, 0)^\top$。
- 固定设计 X，X_1 与 X_2 的样本相关系数约 0.9998。
- Monte Carlo 重复 60 次：仅重新生成响应噪声。
- 固定 $\lambda = 0.2$，有 45 次只选中这两个变量中的一个。

思考：预测信息相近，为何系数会在两个变量间大幅转移?

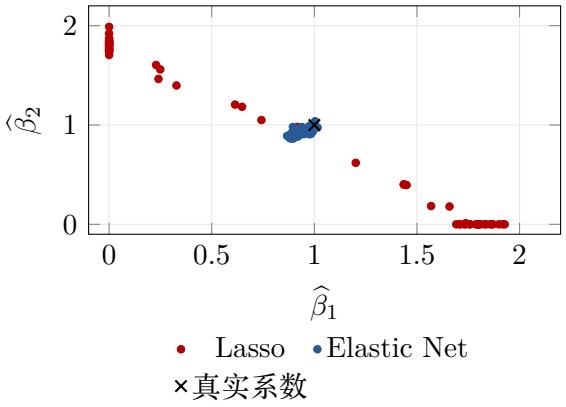
1.3 Elastic Net 联合 ℓ_1 与 ℓ_2 惩罚

- Elastic Net 由 Zou and Hastie (2005) 提出。

$$\widehat{\beta} \in \arg\min_{\beta} \left\{ \frac{\|y - X\beta\|_2^2}{2n} + \lambda \left[\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right] \right\}$$

$$\lambda \geq 0, \qquad 0 \leq \alpha \leq 1.$$

- $\alpha = 1$ 得到 Lasso，$\alpha = 0$ 得到 Ridge。
- 加入 ℓ_2 惩罚可缓和高度相关变量带来的不稳定。
- α 与 λ 共同控制稀疏性和稳定性。



- 同一批 60 组响应、同一 $\lambda = 0.2$；Elastic Net 取 $\alpha = 0.5$。
- 蓝点集中在两个变量共同分担作用的区域。
- $\widehat{\beta}_1$ 的标准差：Lasso 为 0.836，Elastic Net 为 0.034。

思考：ℓ_2 项如何鼓励相似变量分担作用？

1.4 Elastic Net：标准正交设计下的显式解

- 数据中心化，且满足标准正交条件，令

$$\frac{X^\top X}{n} = I_p, \qquad z = \frac{X^\top y}{n} = \widehat{\beta}_{\mathrm{OLS}}.$$

- 展开平方损失并略去常数，目标按坐标分离：

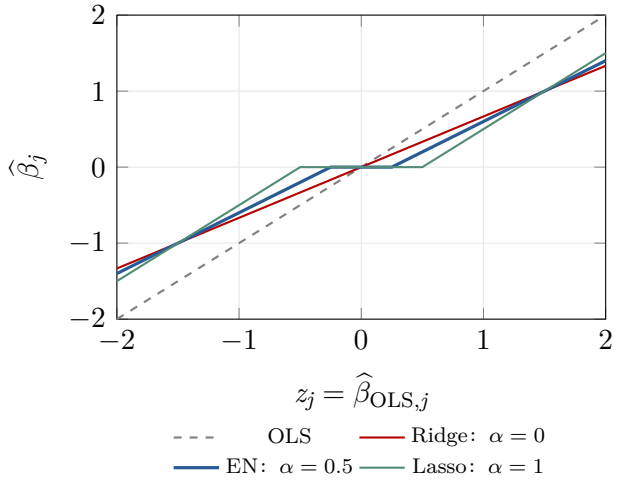
$$\min_{\beta} \sum_{j=1}^{p} \left\{ \frac{1}{2}(\beta_j - z_j)^2 + \frac{\lambda(1-\alpha)}{2}\beta_j^2 + \lambda\alpha|\beta_j| \right\}.$$

- 各坐标的显式解为

$$\boxed{\widehat{\beta}_{\mathrm{EN},j} = \frac{S_{\lambda\alpha}(z_j)}{1+\lambda(1-\alpha)}}, \qquad j = 1, \ldots, p.$$

先软阈值，再按比例收缩；$\alpha = 1$ 得到 Lasso，$\alpha = 0$ 得到 Ridge。

1.5 Elastic Net：系数如何随 OLS 估计变化?

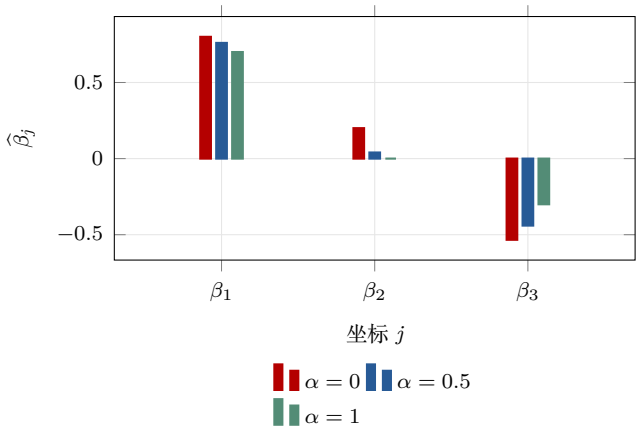


- 标准正交设计，固定 $\lambda = 0.5$。
- 蓝线为 Elastic Net：

$$\widehat{\beta}_{\mathrm{EN},j} = \frac{S_{0.25}(z_j)}{1.25}.$$

- $|z_j| \le 0.25$ 时系数为零；超过阈值后，斜率为 0.8。
- 相比 Lasso，阈值更小；相比 Ridge，比例收缩更弱。

1.6 教学数值：不同 α 对应不同收缩



- 正交设计取 $z = (1.2, 0.3, -0.8)$，固定 $\lambda = 0.5$
- $\alpha = 0$ 保留全部坐标，$\alpha = 1$ 将第二维置零
- 中间 α 同时有阈值和额外缩放

$$\widehat{\beta}_j = \frac{S_{0.5\alpha}(z_j)}{1 + 0.5(1 - \alpha)}$$

1.7 Elastic Net：一般设计矩阵下的坐标更新

- 固定其他系数，定义部分残差及其相关量：

$$r^{(j)} = y - \sum_{k \neq j} x_k \beta_k, \quad a_j = \frac{x_j^\top x_j}{n}, \quad c_j = \frac{x_j^\top r^{(j)}}{n}.$$

- 单坐标目标只保留与 β_j 有关的项：

$$\frac{a_j + \lambda(1-\alpha)}{2}\beta_j^2 - c_j\beta_j + \lambda\alpha|\beta_j|.$$

- 用软阈值（soft-thresholding）得到

$$\boxed{\beta_j \leftarrow \frac{S_{\lambda\alpha}(c_j)}{a_j + \lambda(1-\alpha)}}.$$

- Elastic Net 的目标为

$$\min_{\beta}\left\{\frac{\|y-X\beta\|_2^2}{2n}+\frac{\lambda(1-\alpha)}{2}\|\beta\|_2^2+\lambda\alpha\|\beta\|_1\right\}.$$

- 扩充设计矩阵与响应：

$$X^*=\begin{pmatrix}X\\ \sqrt{n\lambda(1-\alpha)}I_p\end{pmatrix},\qquad y^*=\begin{pmatrix}y\\ 0\end{pmatrix}.$$

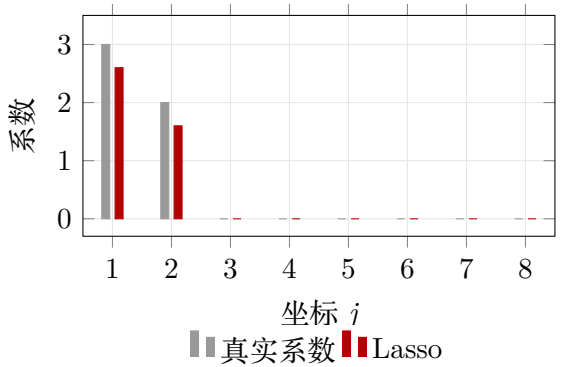
- 二次惩罚吸收到平方损失中，得到等价的 Lasso 问题：

$$\boxed{\min_{\beta}\left\{\frac{\|y^*-X^*\beta\|_2^2}{2n}+\lambda\alpha\|\beta\|_1\right\}.}$$

可直接使用 Lasso 算法，惩罚参数为 $\lambda\alpha$。

2 Adaptive Lasso

2.1 例子：去掉小噪声时，大系数也被压小



- 中心化正交设计，$n = 100, p = 8$；$\beta^* = (3, 2, 0, \ldots, 0)^\top$。
- 图取 $\lambda = 0.4$。去噪所需阈值至少为 0.35，大系数也至少收缩 0.35。

$$\widehat{\beta}_{\text{OLS}} = (3, 2, 0.35, -0.30, 0.25, -0.20, 0.15, -0.10)^\top$$

思考：能否对大系数少罚一些，对小系数多罚一些？

2.2 Adaptive Lasso 使用初始估计形成权重

- Adaptive Lasso 由 Zou (2006) 提出。
- 使用 OLS 初始估计，令 $\widetilde{\beta} = \widehat{\beta}_{\text{OLS}}$。

$$J(\beta) = \frac{\|y - X\beta\|_2^2}{2n} + \lambda \sum_j w_j |\beta_j|, \qquad w_j = |\widetilde{\beta}_j|^{-\gamma}, \quad \gamma > 0.$$

- 初始系数较大时惩罚较小，接近零时惩罚较大。

2.3 Adaptive Lasso：标准正交设计下的显式解

- 数据中心化，且满足

$$\frac{X^\top X}{n} = I_p, \qquad z = \frac{X^\top y}{n} = \widehat{\beta}_{\mathrm{OLS}}.$$

- 略去与 β 无关的常数，目标按坐标分离：

$$\min_{\beta} \sum_{j=1}^{p} \left\{ \frac{1}{2}(\beta_j - z_j)^2 + \lambda w_j |\beta_j| \right\}.$$

- 对每个坐标使用不同的软阈值：

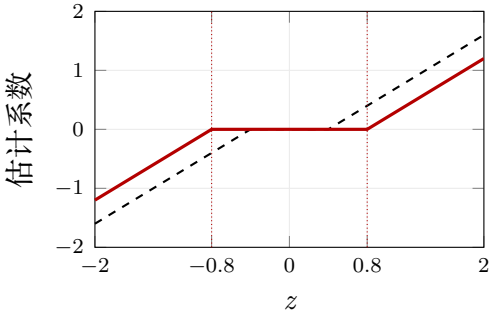
$$\boxed{\widehat{\beta}_{\mathrm{AL},j} = S_{\lambda w_j}(z_j) = \mathrm{sign}(z_j)(|z_j| - \lambda w_j)_+.}$$

2.4 Adaptive Lasso：权重改变软阈值

固定 $\lambda = 0.4$；黑色虚线为无权重的 $S_{0.4}(z)$。

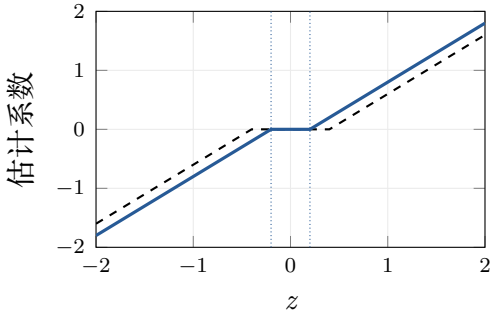
大权重，大阈值

$w = 2, \quad \lambda w = 0.8$

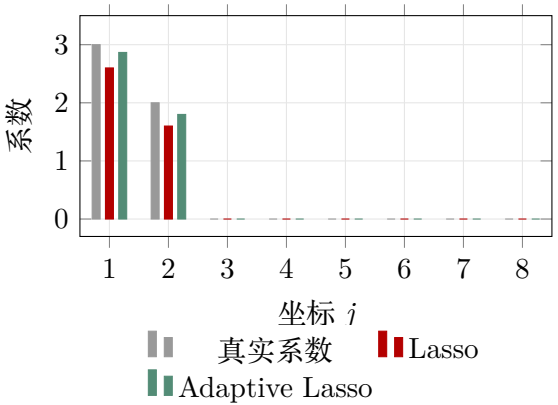


小权重，小阈值

$w = 0.5, \quad \lambda w = 0.2$



权重越大，零区间越宽；两图非零部分的斜率均为 1。



- 用 OLS 初值，取 $w_j = |\widetilde{\beta}_j|^{-1}$。
- 同一 $\lambda = 0.4$ 下：$\widehat{\beta}_{\mathrm{AL}} \approx (2.867, 1.800, 0, \ldots, 0)^\top$
- 小噪声仍被压为零；强信号的收缩减轻。

Remark 权重来自数据；初始估计不可靠时，结果也可能变差。

课堂练习 1：加权 Lasso 的坐标阈值

数据已中心化，设 $X^\top X/n = I_2$，$z = X^\top y/n = (1.2, 0.3)^\top$，$\lambda = 0.2$。*使用 OLS 初值，取* $w_j = |\widehat{\beta}_{\mathrm{OLS},j}|^{-1}$。*目标为* $\|y - X\beta\|_2^2/(2n) + \lambda \sum_j w_j|\beta_j|$。

- 计算 OLS 估计及两个坐标的权重。
- 计算加权软阈值与相应的系数估计。
- 与权重均为一的普通 Lasso 比较。

课堂练习 1：参考答案

- 标准正交设计下，$\widehat{\beta}_{\mathrm{OLS}} = z = (1.2, 0.3)^\top$，因此

$$w = \left(\frac{5}{6}, \frac{10}{3}\right)^\top.$$

- 加权阈值为 $\lambda w = (1/6,\, 2/3)^\top$，故

$$\widehat{\beta}_{\mathrm{AL}} = \big(S_{1/6}(1.2),\, S_{2/3}(0.3)\big)^\top = (1.0\overline{3}, 0)^\top.$$

- 普通 Lasso 的两个阈值均为 0.2：

$$\widehat{\beta}_{\mathrm{Lasso}} = (1.0, 0.1)^\top.$$

Remark 较大的 OLS 系数受到较小惩罚；较小的 OLS 系数受到较大惩罚。

3 Group Lasso

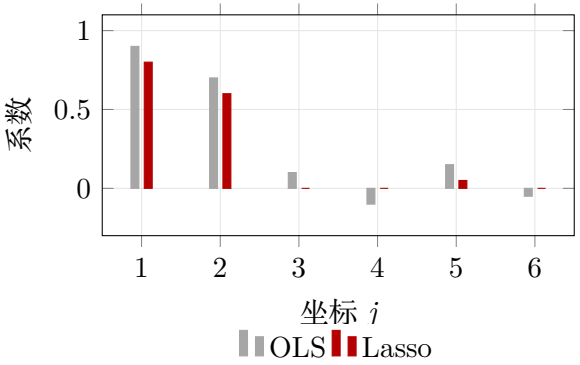
3.1 实例：睡眠监测中，选择哪些设备?

- 预测一晚的睡眠效率；每台设备产生一组特征。
- 若按设备成本决定采集方案，需要把同一设备的特征作为一组考虑：
  - 心率设备：平均心率、心率波动。
  - 活动设备：活动次数、活动强度。
  - 血氧设备：平均血氧、低血氧时长。



真实睡眠场景照片

思考：只删掉一项特征，就能少佩戴一台设备吗?



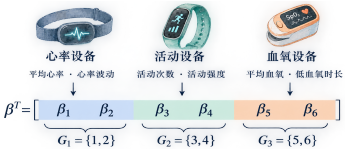
- 模拟 $n = 100, p = 6$，按 $(1,2)$、$(3,4)$、$(5,6)$ 分三组。
- $X^\top X/n = I_6$，OLS 系数为

$$z = \widehat{\beta}_{\text{OLS}} = (0.9, 0.7, 0.1, -0.1, 0.15, -0.05)^\top.$$

- $\lambda = 0.1$ 时：$\widehat{\beta}_{\text{Lasso}} = (0.8, 0.6, 0, 0, 0.05, 0)^\top$

普通 Lasso 按坐标筛选，没有表达“整组取舍”的惩罚结构。

3.2 Group Lasso 按整组选择



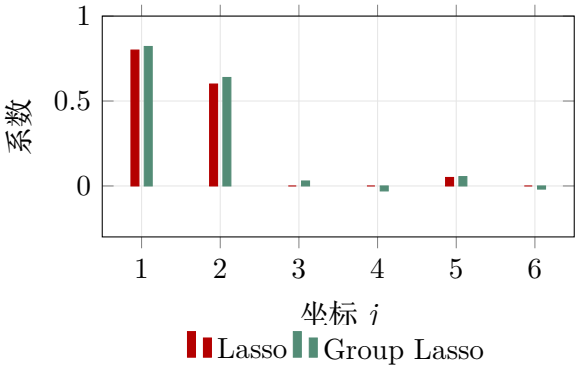
- Yuan and Lin (2006) 提出 Group Lasso；这里采用等权形式。
- 非空组 $G_1, \ldots, G_m$ 满足

$$\bigcup_{g=1}^{m} G_g = \{1, \ldots, p\}, \quad G_g \cap G_h = \varnothing \ (g \neq h).$$

  β_{G_g} 为第 g 组的系数子向量。
- 最小化目标函数

$$\min_{\beta} \left\{ \frac{1}{2n} \left\| y - \sum_{g=1}^{m} X_{G_g} \beta_{G_g} \right\|_2^2 + \lambda \sum_{g=1}^{m} \|\beta_{G_g}\|_2 \right\}.$$

- 组内使用 ℓ_2 范数，组间直接加和（类似 ℓ_1 范数），形成组稀疏性。



- 沿用上例，三组大小相同，取 $\lambda = 0.1$。
- 估计系数为

$$\widehat{\beta}_{\text{Group}} \approx (0.821, 0.639, 0.029, -0.029, 0.055, -0.018)^{\top}.$$

- Lasso 仅保留第三组的一个坐标；Group Lasso 保留该组的两个坐标。

Remark 如果还要筛选组内变量，可进一步考虑 Sparse Group Lasso (Simon et al., 2013)。

3.3 Group Lasso：标准正交设计下的解

- 数据中心化，$X^\top X/n = I_p$，令 $z = X^\top y/n$。
- 略去常数，目标按组分离：

$$\min_{\beta} \sum_{g=1}^{m} \left\{ \frac{1}{2} \|\beta_{G_g} - z_{G_g}\|_2^2 + \lambda \|\beta_{G_g}\|_2 \right\}.$$

- 组软阈值（group soft-thresholding）定义为

$$\mathcal{S}_\lambda(u) = \left(1 - \frac{\lambda}{\|u\|_2}\right)_+ u \qquad \boxed{\widehat{\beta}_{G_g} = \mathcal{S}_\lambda(z_{G_g}).}$$

- 向量长度不超过阈值时整组归零；否则保持方向，将长度缩短 λ。

3.4 Group Lasso：一般设计下的逐组更新

- 固定其他组，用当前系数构造部分残差：

$$r^{(g)} = y - \sum_{h \neq g} X_{G_h} \beta_{G_h}.$$

- 组间允许相关；若组内满足 $X_{G_g}^\top X_{G_g}/n = I_{|G_g|}$，令

$$z_{G_g} = \frac{X_{G_g}^\top r^{(g)}}{n}.$$

- 对第 g 组应用组软阈值：

$$\boxed{\beta_{G_g} \leftarrow \mathcal{S}_\lambda(z_{G_g})}.$$

依次更新 $g = 1, \dots, m$，重复各轮直至收敛。

课堂练习 2：计算三组变量的系数

数据已中心化， $p = 9$，$X^\top X/n = I_9$。*将变量分为三组：*

$$G_1 = \{1, 2, 3\}, \quad G_2 = \{4, 5, 6\}, \quad G_3 = \{7, 8, 9\}.$$

记 $z = X^\top y/n = \widehat{\beta}_{\mathrm{OLS}}$，*已知*

$$z_{G_1} = (1, 2, 2)^\top, \quad z_{G_2} = (0.2, 0.4, 0.4)^\top, \quad z_{G_3} = (0, 1.2, -1.6)^\top.$$

使用 Group Lasso，取 $\lambda = 1$。

- 分别计算 $\|z_{G_g}\|_2$，判断哪些组会被保留。
- 用标准正交设计下的公式计算三组系数 $\widehat{\beta}_{G_g}$，写出完整的 $\widehat{\beta}$。

课堂练习 2：参考答案

- 三组向量的长度为 $3,\ 0.6,\ 2$；取 $\lambda = 1$，保留第一组与第三组。
- 应用组软阈值，得到

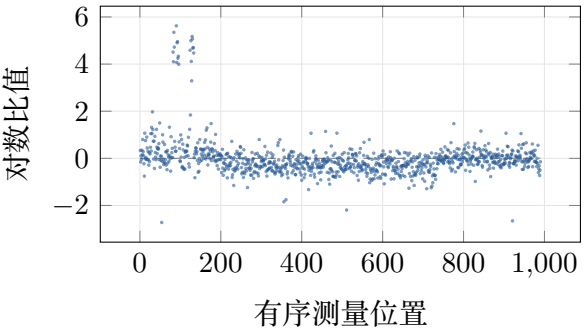
$$\widehat{\beta}_{G_1} = \tfrac{2}{3}(1,2,2)^\top, \quad \widehat{\beta}_{G_2} = 0, \quad \widehat{\beta}_{G_3} = \tfrac{1}{2}(0,1.2,-1.6)^\top.$$

- 完整系数向量为

$$\boxed{\widehat{\beta} = (2/3, 4/3, 4/3, 0, 0, 0, 0, 0.6, -0.8)^\top.}$$

4 Fused Lasso

4.1 真实案例：DNA 拷贝数的连续区段

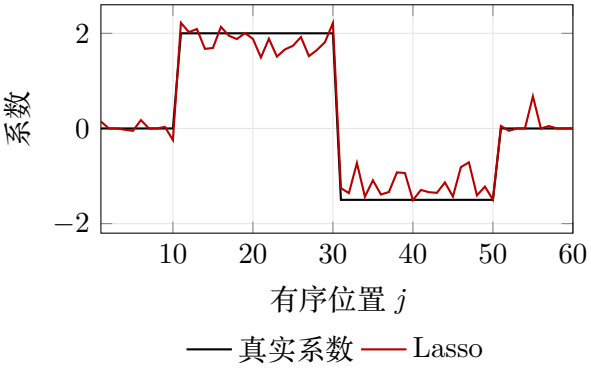


公开 CGH 实测数据：990 个有序测量

- CGH：比较基因组杂交 (comparative genomic hybridization)。
- 比较肿瘤与参考样本，识别 DNA 拷贝数增益或缺失的连续区段。
- 相邻位置的信号可能共享一个平台水平。
- 应用见 Tibshirani and Wang (2008)。

如何在保留区段边界的同时，减少区段内部的噪声波动?

4.2 例子：保留了变量，却没有恢复相邻平台



- 模拟 $p = 60$；四段长度为 $10, 20, 20, 10$，水平为 $0, 2, -1.5, 0$。
- $z_j = \beta_j^* + \varepsilon_j$，$\varepsilon_j \sim N(0, 0.25^2)$；Lasso 阈值 $\lambda_1 = 0.2$。
- Lasso 可以产生零，却没有鼓励相邻非零系数相等。

思考：若关心连续区段，应把怎样的关系加入惩罚？

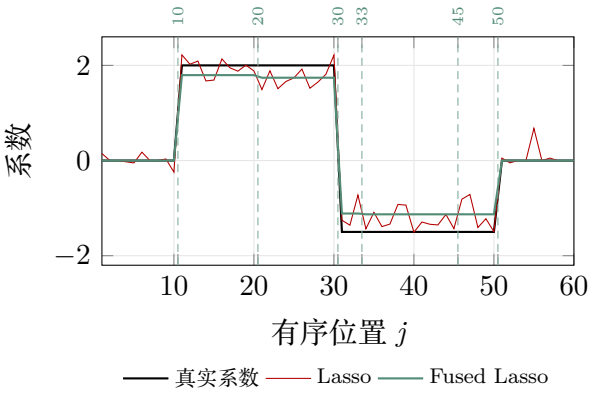
4.3 Fused Lasso 惩罚相邻系数差异

- Fused Lasso 由 Tibshirani et al. (2005) 提出。
- 按科学上明确的顺序排列变量

$$\min_{\beta} \frac{\|y - X\beta\|_2^2}{2n} + \lambda_1 \|\beta\|_1 + \lambda_2 \sum_{j=2}^{p} |\beta_j - \beta_{j-1}|$$

- ℓ_1 项鼓励零值，差分惩罚鼓励相邻系数相等
- 适合分段稳定结构，但会依赖邻接关系

4.4 同一模拟数据：Lasso 与 Fused Lasso



- 加入相邻差分惩罚，取 $\lambda_1 = 0.2$、$\lambda_2 = 0.8$。
- 绿色曲线形成若干平台。

5 非凸惩罚

5.1 为什么改变 Lasso 的惩罚?

- 在标准正交设计下，记 $z_j = \widehat{\beta}_{\mathrm{OLS},j}$：

$$\widehat{\beta}_j = \arg\min_{\beta} \left\{ \frac{1}{2}(\beta - z_j)^2 + p_\lambda(|\beta|) \right\}.$$

- 对非零解 $\widehat{\beta}_j$，若惩罚在 $|\widehat{\beta}_j|$ 处可微，一阶条件为

$$\boxed{z_j - \widehat{\beta}_j = p'_\lambda(|\widehat{\beta}_j|)\,\mathrm{sign}(\widehat{\beta}_j).}$$

  因此，惩罚导数决定非零系数相对 OLS 的收缩量。
- Lasso 使用 $p_\lambda(t) = \lambda t$，因此 $p'_\lambda(t) = \lambda$：

$$z_j - \widehat{\beta}_j = \lambda\,\mathrm{sign}(\widehat{\beta}_j).$$

  即使 $|\widehat{\beta}_j|$ 很大，收缩量仍为 λ。

Comment 希望兼顾两点：小系数能够归零；大系数受到更少收缩。

5.2 SCAD 与 MCP：惩罚导数如何变化?

- Lasso：$p'_\lambda(t) = \lambda$，收缩力保持不变。
- SCAD（smoothly clipped absolute deviation；Fan and Li, 2001）：

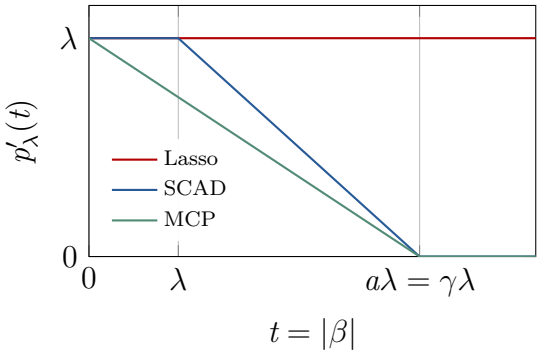
$$p'_{\lambda,a}(t) = \begin{cases} \lambda, & 0 \le t \le \lambda, \\ (a\lambda - t)/(a-1), & \lambda < t \le a\lambda, \\ 0, & t > a\lambda, \end{cases} \qquad a > 2.$$

  先保持 Lasso 的斜率，再逐渐降为零。
- MCP（minimax concave penalty；Zhang, 2010）：

$$p'_{\lambda,\gamma}(t) = (\lambda - t/\gamma)_+, \qquad \gamma > 1.$$

  从原点开始降低斜率，到 $\gamma\lambda$ 后为零。

5.3 从惩罚形状理解收缩



- 取 $a = \gamma$，两者在相同位置停止惩罚。
- 三者在原点都有尖点，可以产生零系数。
- Lasso 对所有非零系数施加相同大小的收缩力。
- SCAD、MCP 对大系数的惩罚逐渐变平；惩罚值不再增长，但并非变为零。

5.4 标准正交设计下：系数如何收缩?

令 $r = |z_j|$，三个估计都保留 z_j 的符号。其绝对值为

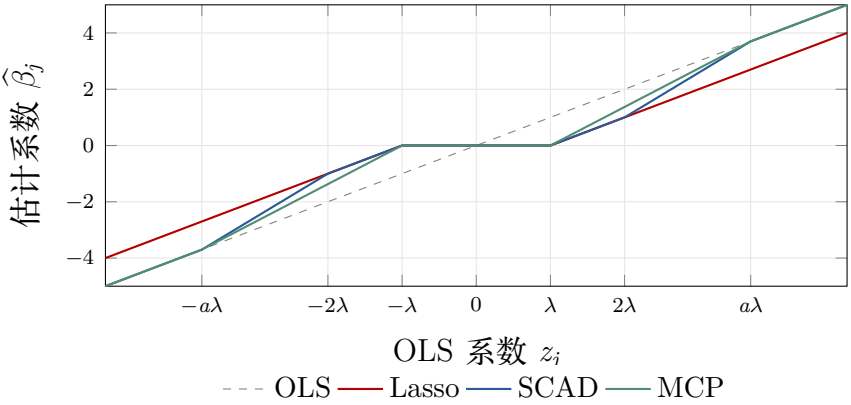
$$|\widehat{\beta}_{\text{Lasso},j}| = (r - \lambda)_+.$$

$$|\widehat{\beta}_{\text{SCAD},j}| = \begin{cases} (r-\lambda)_+, & r \le 2\lambda, \\ \{(a-1)r - a\lambda\}/(a-2), & 2\lambda < r \le a\lambda, \\ r, & r > a\lambda. \end{cases}$$

$$|\widehat{\beta}_{\text{MCP},j}| = \begin{cases} (r-\lambda)_+/(1-1/\gamma), & r \le \gamma\lambda, \\ r, & r > \gamma\lambda. \end{cases}$$

- 都在 $r \le \lambda$ 时归零；SCAD、MCP 在大信号区间恢复为 OLS。

5.5 标准正交设计下：三种系数估计函数



$a = \gamma$；当 $|z_j| \leq \lambda$ 时，三种估计均为零。

5.6 一个数值对比：同一阈值，不同收缩量

- 取 $\lambda = 1$、$a = \gamma = 3.7$，标准正交设计下：

z_j	Lasso	SCAD	MCP
0.5	0	0	0
1.5	0.5	0.5	0.685
2.5	1.5	1.794	2.056
4	3	4	4

- 当 $|z_j| \le 2\lambda$ 时，SCAD 与 Lasso 相同。
- 当 $\lambda < |z_j| < \gamma\lambda$ 时，MCP 的收缩量小于 Lasso。
- 当 $|z_j| \ge a\lambda$（SCAD）或 $|z_j| \ge \gamma\lambda$（MCP）时，估计等于 OLS。本例两者的界点均为 3.7。

5.7 减少收缩的代价：非凸优化

- Lasso：凸损失加凸惩罚，满足最优性条件即可确认全局最优解。
- SCAD、MCP：惩罚关于 β 非凸，一般设计下目标可能有多个局部极小点；结果可能依赖初值与求解路径。
- a 或 γ 越大，斜率下降越慢，越接近 Lasso；越小，越快停止收缩，但非凸性更强。

思考

- 在设计矩阵 X 中两列完全相同的情形下，为什么 Lasso 的目标函数虽然是凸的，系数估计仍可能不唯一?
- Elastic Net 与 Adaptive Lasso 分别改变了什么?
- 何时选择 Group Lasso，何时选择 Fused Lasso?
- 有序变量采用 Fused Lasso 时，鼓励的是怎样的结构?
- SCAD 与 MCP 如何减轻大系数的收缩? 它们与 Lasso 的估计在哪些区间相同?
- 使用非凸惩罚时，不同初值可能得到不同结果，原因是什么? 如何比较这些解?

参考文献

Zou, H. and Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320.

Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429.

Yuan, M. and Lin, Y. (2006). Model selection and estimation in regression with grouped variables. *JRSS B*, 68(1), 49–67.

Simon, N., Friedman, J., Hastie, T. and Tibshirani, R. (2013). A sparse-group lasso. *JCGS*, 22(2), 231–245.

Tibshirani, R. and Wang, P. (2008). Spatial smoothing and hot spot detection for CGH data using the fused lasso. *Biostatistics*, 9(1), 18–29.

参考文献

Tibshirani, R., Saunders, M., Rosset, S., Zhu, J. and Knight, K. (2005). Sparsity and smoothness via the fused lasso. *JRSS B*, 67(1), 91–108.

Fan, J. and Li, R. (2001). Variable selection via nonconcave penalized likelihood and its oracle properties. *JASA*, 96(456), 1348–1360.

Zhang, C.-H. (2010). Nearly unbiased variable selection under minimax concave penalty. *Annals of Statistics*, 38(2), 894–942.

Zou, H. and Li, R. (2008). One-step sparse estimates in nonconcave penalized likelihood models. *Annals of Statistics*, 36(4), 1509–1533.