

STAT3003: 统计算法基础

蒙特卡洛方法 (1)

曾靖

中国科学技术大学管理学院

大纲

大纲

1. 蒙特卡洛方法
2. 蒙特卡洛积分

本节内容来自于《统计计算使用 R 》第 5 章,《统计方法》3.2 小节

1 蒙特卡洛方法

1.1 蒙特卡洛方法

- Monte Carlo 方法又称随机模拟方法



- *Monte Carlo methods*, or *Monte Carlo experiments*, are a broad class of computational algorithms that rely on repeated random sampling to obtain numerical results.
- The underlying concept is to use *randomness* to solve problems that might be *deterministic* in principle.¹

¹https://en.wikipedia.org/wiki/Monte_Carlo_method

1.2 历史²

- In the late 1940s, *Stanislaw Ulam* invented the modern version of the Markov Chain Monte Carlo method while he was working on *nuclear weapons projects* at the *Los Alamos National Laboratory*. In 1946, nuclear weapons physicists at Los Alamos were investigating *neutron diffusion* in the core of a nuclear weapon. Despite having most of the necessary data, ..., the Los Alamos physicists were unable to solve the problem using conventional, deterministic mathematical methods. Ulam proposed using random experiments.
- Being secret, the work of *von Neumann* and Ulam required a code name. A colleague of von Neumann and Ulam, *Nicholas Metropolis*, suggested using the name Monte Carlo, which refers to the Monte Carlo Casino in Monaco where Ulam's uncle would borrow money from relatives to gamble.

²https://en.wikipedia.org/wiki/Monte_Carlo_method



图 1: Stanislaw Ulam

- In March 1947 he (John von Neumann) proposed a statistical approach to the problem of *neutron diffusion in fissionable material*. Because Ulam had often mentioned his uncle, Michal Ulam, “who just had to go to Monte Carlo” to gamble, Metropolis dubbed the statistical approach “The Monte Carlo method”
- Monte Carlo methods were central to the simulations required for the *Manhattan Project* ... In the 1950s Monte Carlo methods were used at Los Alamos for the development of the *hydrogen bomb*, and became popularized in the fields of physics, physical chemistry, and operations research.




图 2: Movie "Oppenheimer"

1.3 蒲丰投针问题 (Buffon's needle problem)

- Monte Carlo 最早起可用于蒲丰投针问题来近似估计 π :

(Buffon's needle problem) Suppose we have a floor made of parallel strips of wood, each the same width t , and we drop a needle with length ℓ onto the floor. What is the probability that the needle will lie across a line between two strips?



1.4 蒙特卡洛方法流程


- Monte Carlo 方法的主要流程如下：

1. 把某问题转化为求解概率模型问题；
2. 产生大量符合概率模型的随机样本；
3. 对产生的随机样本进行分析从而解决问题。

核心思想是利用随机方法解决非随机的问题，而这些问题往往很难用其他方法求解。

例 1.1: 圆周率 π 的估计

$$\begin{aligned} & \Pr(\text{A randomly dropped point is located in the sector}) \\ &= \frac{\text{Area of the sector}}{\text{Area of the square}} = \frac{\pi^2}{4}. \end{aligned}$$



1.5 应用

- 积分：积分往往可以表示成某个随机变量的期望，因此积分求解问题往往可以转化为对期望的估计。通过利用大数定律，可以得到该期望的无偏估计。
- 参数估计的均方误差：对于某个参数 θ 的估计统计量 $\hat{\theta}$ ，如何得到该统计量的均方误差 $E(\hat{\theta} - \theta)^2$ ？
 - 通过大量重复随机试验，可以得到 $\hat{\theta}$ 的大量样本 $\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(m)}$ ，通过

$$\frac{1}{m} \sum_{i=1}^m (\hat{\theta}^{(i)} - \theta)^2$$

来估计 $E(\hat{\theta} - \theta)^2$ 。

1.5 应用

- 置信水平估计：对于某个参数 θ 的置信区间 $\widehat{C} = [\widehat{L}_n, \widehat{U}_n]$ ，如何确定其置信水平 $P(\theta \in \widehat{C})$ ？
 - 通过大量重复随机试验，可以得到关于置信区间的大量样本 $\widehat{C}^{(1)}, \dots, \widehat{C}^{(m)}$ ，通过

$$\frac{1}{m} \sum_{i=1}^m I(\theta \in \widehat{C}^{(i)})$$

来估计置信水平 $P(\theta \in \widehat{C})$ 。

1.5 应用

- 假设检验中的一类错误率估计：原假设 $H_0 : \theta = \theta_0$ ，对立假设 $H_1 : \theta = \theta_1$ ，则一类错误率为 $\alpha = P_{\theta_0}(\text{reject } H_0)$ ，功效为 $\beta = P_{\theta_1}(\text{reject } H_0)$ 。如何确定一个假设检验的一类错误率和功效？
 - 在原假设 H_0 成立的情况下通过大量重复随机试验，可以得到检验结果的大量样本 $I_{H_0}^{(1)}(\text{reject } H_0), \dots, I_{H_0}^{(m)}(\text{reject } H_0)$ 。
通过

$$\frac{1}{m} \sum_{i=1}^m I_{H_0}^{(i)}(\text{reject } H_0)$$

可以估计一类错误率。

1.5 应用

- 假设检验中的功效估计：如何确定一个假设检验的功效？
 - 在对立假设 H_1 成立的情况下通过大量重复随机试验，可以得到检验结果的大量样本 $I_{H_1}^{(1)}(\text{reject } H_0), \dots, I_{H_1}^{(m)}(\text{reject } H_0)$ 。通过

$$\frac{1}{m} \sum_{i=1}^m I_{H_1}^{(i)}(\text{reject } H_0)$$

可以估计功效。

1.5 应用

- MCMC (Markov-Chain Monte-Carlo): 马尔可夫链蒙特卡洛主要应用在贝叶斯推断中, 主要关心的问题是: 如何从后验分布中抽样。对于观测值 $x = \{x_1, \dots, x_n\}$ 以及参数 θ , 参数的后验分布为

$$f(\theta|x) = \frac{f_{x|\theta}(x)f_{\theta}(\theta)}{f_x(x)}.$$

然而如何从后验分布中抽样往往比较困难。MCMC 为解决该类问题提供了思路。其主要组成部分为

- Markov – Chain $\rightarrow$ Generate samples from $f(\theta|x)$
- Monte – Carlo $\rightarrow$
Repeatedly generate samples from Markov Chain

通过生成大量满足分布 $f(\theta|x)$ 的样本 $\theta^{(1)}, \dots, \theta^{(n)}$, 我们可以进一步进行贝叶斯推断。

1.5 统计文章中的应用

大多数统计文章的结构如下：

1. *Introduction/Background*: 问题背景：问题重要性如何；该问题研究现状；已有方法的缺陷
2. *Model*: 考虑某特定的统计模型；
3. *Methodology*: 文章提出的新方法；
4. *Theory*: 理论证明；
5. *Simulation results*: 通过随机模拟 (Monte Carlo) 说明提出的统计方法的有效性（上帝视角）。
6. *Real data analysis*: 通过将已有方法用到实际数据中来进行进一步说明统计方法在现实世界中是有用的。

2 Monte Carlo 积分

2.1 Monte Carlo 积分

Question: 对于函数 $g(x)$, 如果积分 $\theta = \int_A g(x)dx$ 存在, 如何通过数值方法计算该积分?

1. 假设我们可以找到一个随机变量 X , 其密度函数为 $f(x)$, 支撑集为 A , 使得

$$\theta \propto E(g(X)) = \int_A g(x)f(x)dx.$$

2. 利用蒙特卡罗方法 (Monte-Carlo) 估计 $E(g(X))$, 进而得到积分 θ 的估计。

算法流程:

- 生成 X 的 i.i.d. 样本 $x_1, \dots, x_m$;
- 计算样本均值

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m g(x_i).$$

根据大数定律可知, $\hat{\theta}$ 是积分 θ 的无偏估计。

2.2 简单 Monte Carlo 积分

简单 Monte Carlo 积分是基于均匀分布的 Monte Carlo 积分方法。

- 考虑积分 $\theta = \int_a^b g(x)dx$.
- 令 $X \sim \text{Unif}(a, b)$, 则 $g(X)$ 的期望为

$$E(g(X)) = \frac{1}{b-a} \int_a^b g(x)dx,$$

即

$$\theta = (b-a)E(g(X)).$$

- 设 $x_1, \dots, x_m$ 服从均匀分布 $\text{Unif}(a, b)$, 那么 Monte Carlo 估计量为

$$\hat{\theta} = (b-a) \frac{1}{m} \sum_{i=1}^m g(x_i).$$

例 2.1

计算

$$\theta = \int_2^4 e^{-x} dx$$

```
m <- 10000  
x <- runif(m, min=2, max=4)  
theta.hat <- mean(exp(-x)) * 2  
print(theta.hat)
```

```
## [1] 0.117247
```

```
print(exp(-2) - exp(-4))
```

```
## [1] 0.1170196
```

例 2.1 (续)

利用指数分布直接生成样本

```
m <- 10000
x <- rexp(m)
theta.hat <- mean((x >= 2) & (x <= 4))
print(theta.hat)
```

```
## [1] 0.1165
```

```
print(exp(-2) - exp(-4))
```

```
## [1] 0.1170196
```


例 2.2

Exercise: 基于如下分布，使用 Monte Carlo 方法计算积分

$$\theta = \int_0^1 \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

- 均匀分布
- 正态分布

Question: 对于不同的样本生成方法和积分估计方法，如何评估哪种方法更好？

2.3 方差和效率

方差是比较两种无偏统计量优劣的评判标准之一。

- 对于两个 θ 的无偏估计量 $\hat{\theta}_1, \hat{\theta}_2$, 如果

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2),$$

我们称 $\hat{\theta}_1$ 更有效率.

Question: 假设 $g(x)$ 为随机变量的密度函数, 且容易抽样, 考虑积分 $\theta = \int_a^b g(x)dx$ 的估计。

(方法 1) 利用均匀分布的积分估计

1. $x_1, \dots, x_m$ 服从均匀分布 $\text{Unif}(a, b)$;

2. 估计量

$$\hat{\theta}_U = (b - a) \frac{1}{m} \sum_{i=1}^m g(x_i).$$

◦ 估计量 $\hat{\theta}_U$ 的方差:

$$\text{Var}(\hat{\theta}_U) = \frac{(b - a)^2}{m} \text{Var}(g(X)).$$

◦ 根据中心极限定理 (假设 $\text{Var}(g(X))$ 存在),

$$\sqrt{m}(\hat{\theta}_U - \theta) \rightarrow N(0, (b - a)^2 \text{Var}(g(X))).$$

(方法 2) 直接从 $g(x)$ 中抽样

1. $x_1, \dots, x_m$ 服从均匀分布 $g(x)$;
2. 估计量

$$\hat{\theta}_g = \frac{1}{m} \sum_{i=1}^m I(a \leq x_i \leq b).$$

- 估计量 $\hat{\theta}_g$ 的方差:

$$\text{Var}(\hat{\theta}_g) = \frac{\theta(1-\theta)}{m}.$$

- 根据中心极限定理,

$$\sqrt{m}(\hat{\theta}_g - \theta) \rightarrow N(0, \theta(1-\theta)).$$

2.4 方差估计

(方法 1) 如果估计量为平均值统计量, 可以结合平均值的方差公式用 Monte Carlo 方法来估计方差:

- 对于 $\hat{\theta}_U$, 方差为 $\text{Var}(\hat{\theta}_U) = \frac{(b-a)^2}{m} \text{Var}(g(X))$. 令 $y_i = g(x_i)$, $i = 1, \dots, n$, 则 $\text{Var}(g(X))$ 的 Monte Carlo 估计为

$$\widehat{\text{Var}}(g(X)) = \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2, \quad \bar{y} = \frac{1}{m} \sum_{i=1}^m y_i,$$

$\hat{\theta}_U$ 的方差为

$$\text{Var}(\hat{\theta}_U) = \frac{(b-a)^2}{m} \widehat{\text{Var}}(g(X)).$$

- 对于 $\hat{\theta}_g$, 方差为 $\text{Var}(\hat{\theta}_g) = \frac{\theta(1-\theta)}{m}$. 可以直接带入 $\hat{\theta}_g$, 即

$$\widehat{\text{Var}}(\hat{\theta}_g) = \frac{\hat{\theta}_g(1 - \hat{\theta}_g)}{m}.$$

(方法 2) 直接估计方差 (以 $\hat{\theta}_U$ 为例):

- 生成变量 $x_1, \dots, x_m \sim \text{Unif}(a, b)$;
- 得到估计量 $\hat{\theta}_U^{(m)}$;
- 重复上述过程 m' 次, 得到 m' 个估计量样本 $\{\hat{\theta}_U^{(1)}, \dots, \hat{\theta}_U^{(m')}\}$;
- 计算估计量样本 $\{\hat{\theta}_U^{(1)}, \dots, \hat{\theta}_U^{(m')}\}$ 的样本方差, 即为 $\hat{\theta}_U$ 的方差估计。

- 两种方法对比：
 - 方法 1 的好处在于可以直接利用 m 个样本，减少计算量。而方法 2 则需要更多的样本 (mm')
 - 方法 2 更加直接，可以处理方法 1 无法处理的情况，即统计量不是样本均值的情况。
- 对于 Monte Carlo 估计，一个重要的问题是如何如何降低 Monte Carlo 估计量的方差，从而提升效率。