

STAT3003: 统计算法基础

蒙特卡洛方法 (2)

曾靖

中国科学技术大学管理学院

大纲

大纲

1. 估计中的蒙特卡罗方法
2. 假设检验中的蒙特卡罗方法

本节内容来自于《统计计算使用 R 》第 6 章

1 估计中的蒙特卡罗方法

1.1 回顾

- 上一节中我们讨论了如何将非随机的求解积分问题转化为求解期望问题，并通过 Monte Carlo 方法求解。
- 这一节我们将讨论统计推断问题中的 Monte Carlo 方法，包括
 - 参数估计量的标准误差 (standard error) 和均方误差 (mean squared error) 的估计；
 - 置信区间的置信水平 (Confidence interval)，假设检验的 I 型错误 (Type-I error) 和功效 (Power) 估计。

1.2 参数估计

- 设 $x_1, \dots, x_n$ 是随机变量 X 的 i.i.d. 样本, 记参数 $\theta = \theta(X)$ 的估计量为:

$$\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n).$$

- 我们通常感兴趣 $\hat{\theta}_n$ 的某些评估量, 假设评估量可以被记为 $\xi = E(h(\hat{\theta}_n))$, 这里 h 是某个函数。
 - 若 $h(\hat{\theta}_n) = (\hat{\theta}_n - \theta)^2$, 则 ξ 为估计量的均方误差 (MSE), 即

$$\xi = E(\hat{\theta}_n - \theta)^2.$$

- 若 $h(\hat{\theta}_n) = (\hat{\theta}_n - E(\hat{\theta}_n))^2$, 则 ξ 为估计量的方差, 即

$$\xi = \text{Var}(\hat{\theta}_n) = E(\hat{\theta}_n - E(\hat{\theta}_n))^2.$$

Monte Carlo 的一般过程：对于 $j = 1, \dots, m$,

1. 记第 j 次实验得到一个关于参数 θ 估计 $\hat{\theta}^{(j)}$, 计算 $h(\hat{\theta}^{(j)})$;
2. 参数 $\xi = E(h(\hat{\theta}_n))$ 的 Monte Carlo 估计为

$$\hat{\theta} = \frac{1}{m} \sum_{i=1}^m h(\theta^{(j)}).$$

例 1.1 正态分布差的绝对值

Q: 设 X_1, X_2 相互独立且服从标准正态分布, 试估计平均差 $\theta = E|X_1 - X_2|$ 。

- 基于 m 次重复试验的 Monte Carlo 估计, 每次生成独立分布的样本 $(x_1^{(j)}, x_2^{(j)})$, $j = 1, \dots, m$;
- 重复计算估计量 $|x_1^{(j)} - x_2^{(j)}|$, $j = 1, \dots, m$;
- 参数 θ 的 Monte Carlo 估计为

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^m |x_1^{(j)} - x_2^{(j)}|.$$


```
set.seed(100)
m <- 1000
g <- numeric(m)
for(i in 1:m){
  x <- rnorm(2)
  g[i] <- abs(x[1] - x[2])
}

mean(g)
```

```
## [1] 1.126048
```

- 通过积分可知

$$E|X_1 - X_2| = \frac{2}{\sqrt{\pi}} \approx 1.128379.$$

```
mean(g) - 2/sqrt(pi)
```

```
## [1] -0.002331062
```

1.3 均方误差估计

- 参数 θ 的估计量 $\hat{\theta}$ 的均方误差定义为

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

- 记第 j 次 Monte Carlo 估计为 $\hat{\theta}^{(j)}$, 则均方误差 $\text{MSE}(\hat{\theta})$ 的 Monte Carlo 估计为

$$\widehat{\text{MSE}}(\hat{\theta}) = \frac{1}{m} \sum_{j=1}^m (\hat{\theta}^{(j)} - \theta)^2.$$

例 1.2. 估计切尾均值的均方误差

- 估计非正态的连续对称随机变量 X 的中心 $\theta = E(X) = 0$.
- 切尾均值可以减小异常值对均值估计的影响。
- 记 $X_{(i)}$ 为第 i 个次序统计量，则第 k 层切尾均值定义为

$$\hat{\theta}_{[-k]} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} X_{(i)}.$$

- 估计 $\hat{\theta}_{[-k]}$ 的 MSE: $\xi = E(\hat{\theta}_{[-k]}^2)$.

◦ 均方误差 $\xi = E(\hat{\theta}_{[-k]}^2)$ 的 Monte Carlo 估计步骤如下：对于 $j = 1, \dots, m$,

1. 生成服从 X 分布的独立样本 $x_1^{(j)}, \dots, x_n^{(j)}$;
2. 将 n 个独立样本按升序排列, 得到有序样本 $x_{(1)}^{(j)}, \dots, x_{(n)}^{(j)}$;
3. 计算第 k 层切尾均值估计

$$\hat{\theta}_{[-k]}^{(j)} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}^{(j)}$$

4. 估计第 k 层切尾均值的均方误差:

$$\widehat{\text{MSE}} = \frac{1}{m} \sum_{j=1}^m (\hat{\theta}_{[-k]}^{(j)})^2.$$

- 正态分布

```
n <- 20
m <- 1000
k <- 1 # trimmed number
tmean <- replicate(m,
                    mean(sort(rnorm(n))[(k+1):(n-k)]))
mean(tmean^2) # MSE

## [1] 0.04786689
```

- t 分布

```
tmean <- nmean <- numeric(m)
for(i in 1:m){
  x <- sort(rt(n, 3))
  nmean[i] <- mean(x)
  tmean[i] <- mean(x[(k+1):(n-k)])
}
cat("Normal mean: ", mean(nmean^2),
    "Trimmed mean: ", mean(tmean^2))  # MSE
```

```
## Normal mean: 0.146524 Trimmed mean: 0.0940842
```

- “污染” 正态分布 (Contaminated normal)

考虑“污染”正态分布如下（混合高斯模型 GMM 的特例）

$$X \sim pN(0, 1) + (1 - p)N(0, 10^2)$$

```
rnorm_con <- function(n, p){  
  sigma <- sample(c(1,10), size = n, replace = TRUE,  
                  prob = c(p, 1-p))  
  rnorm(n, 0, sigma)  
}  
trimmed.mse <- function(n, m, k, p){  
  tmean <- replicate(m,  
                     mean(sort(rnorm_con(n, p))  
                           [(k+1):(n-k)]))  
  mean(tmean^2)  
}
```


考虑不同的 k 和 p 对切尾均值的 MSE 的影响。

```
n <- 20
K <- n/2 - 1
m <- 1000
mse <- matrix(0, n/2, 3)

for(k in 0:K){
  mse[k+1, 1] <- trimmed.mse(n,m,k, p=1.0)
  mse[k+1, 2] <- trimmed.mse(n,m,k, p=0.95)
  mse[k+1, 3] <- trimmed.mse(n,m,k, p=0.9)
}
```

```
mse <- data.frame(mse)
colnames(mse) <- c("p=1", "p=0.95", "p=0.9")
rownames(mse) <- 0:9
round(mse,3)
```

##		p=1	p=0.95	p=0.9
##	0	0.052	0.320	0.544
##	1	0.052	0.093	0.214
##	2	0.050	0.062	0.106
##	3	0.056	0.062	0.074
##	4	0.052	0.064	0.070
##	5	0.062	0.065	0.076
##	6	0.062	0.074	0.073
##	7	0.065	0.072	0.078
##	8	0.072	0.074	0.085
##	9	0.074	0.076	0.091

1.4 标准误差

- Monte Carlo 估计 $\hat{\theta}$ 的标准误差为

$$\text{se}(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}.$$

(方法一) 记 $\hat{\theta}^{(j)}$ 为第 j 次 Monte Carlo 估计量, $j = 1, \dots, m$, 则标准误差 $\text{se}(\hat{\theta})$ 的 Monte Carlo 估计为

$$\widehat{\text{se}}(\hat{\theta}) = \left\{ \frac{1}{m} \sum_{j=1}^m (\hat{\theta}^{(j)} - \bar{\hat{\theta}})^2 \right\}^{1/2}.$$

这里 $\bar{\hat{\theta}} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}^{(j)}$.

(方法二) 当 $\hat{\theta}$ 是样本均值, 则 $\hat{\theta}$ 的标准误差估计可以重复利用改 Monte Carlo 实验中的数据, 减小计算量。

- 例 1.1 中, 参数 θ 为正态分布差的绝对值, 其 Monte Carlo 估计为

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^m |x_1^{(j)} - x_2^{(j)}|.$$

- 则 $\hat{\theta}$ 的标准误差为

$$\text{se}(\hat{\theta}) = \left(\frac{1}{m} \text{Var}(|X_1 - X_2|) \right)^{1/2}.$$

- 该标准误差 $\text{se}(\hat{\theta})$ 对应的估计为

$$\widehat{\text{se}}(\hat{\theta}) = \left(\frac{1}{m} \widehat{\text{Var}}(|X_1 - X_2|) \right)^{1/2}.$$

例 1.1(续). 绝对差估计的标准误差

- 理论标准误差为

$$\text{se}(\hat{\theta}) = \sqrt{\frac{1}{m} \text{Var}(|X_1 - X_2|)} = \sqrt{\frac{1}{m} (2 - \frac{4}{\pi})} \approx 0.02695850.$$

方法一

```
m1 <- 1000
```

```
m2 <- 1000
```

```
h <- numeric(m1)
```

```
g <- numeric(m2)
```

```
for(i in 1:m1){
```

```
  for(j in 1:m2){
```

```
    x <- rnorm(2)
```

```
    g[j] <- abs(x[1] - x[2])
```

```
  }
```

```
  h[i] <- mean(g)
```

```
}
```

```
sqrt(mean((h - mean(h))^2)) # s.e.
```

```
## [1] 0.02698409
```

方法二

```
sqrt(mean((g-mean(g))^2)/m)
```

```
## [1] 0.02609768
```

1.5 置信水平估计

- 考虑参数 θ 的置信区间估计 $\widehat{C} = \widehat{C}(x_1, \dots, x_n)$, 则置信水平 (Confidence interval) 定义为

$$\Pr(\theta \in \widehat{C}) = E(I(\theta \in \widehat{C})).$$

- 对于简单的问题, 我们通常可以构造出一个简单的置信区间 $\widehat{C}$ 估计使得其置信水平可以直接算出 (例如正态分布的均值的置信区间估计)。然而对于一般情况 (例如 X 的分布非正态), 该置信区间估计的置信水平是不易求出的。
- 我们将置信水平的估计转化为对于期望 $E(I(\theta \in \widehat{C}))$ 的估计, 则可利用 **Monte Carlo** 方法近似估计。

◦ 置信水平 $\beta = E(I(\theta \in \widehat{C}))$ 的 Monte Carlo 估计步骤如下：
对第 j 次重复试验, $j = 1, \dots, m$:

1. 生成独立的随机样本 $x_1^{(j)}, \dots, x_n^{(j)}$;
2. 根据随机样本计算置信区间 $\widehat{C}^{(j)}$;
3. 计算 $\beta_j = I(\theta \in \widehat{C}^{(j)})$;
4. 计算经验置信水平 $\hat{\beta} = \frac{1}{m} \sum_{j=1}^m \beta_j$ 。

- 由于每次 Monte Carlo 试验得到一个服从 Bernoulli 分布的独立变量 $\beta_j = I(\theta \in \widehat{C}^{(j)}) \sim \text{Bernoulli}(\beta)$, 则置信水平估计 $\hat{\beta}$ 的标准误差为

$$\text{se}(\hat{\beta}) = \sqrt{\frac{\beta(1 - \beta)}{m}},$$

- 该标准误差的估计为

$$\widehat{\text{se}}(\hat{\beta}) = \sqrt{\frac{\hat{\beta}(1 - \hat{\beta})}{m}},$$

例 1.4 方差的置信水平

- 设 $X_1, \dots, X_n$ 是服从正态分布 $N(\mu, \sigma^2)$ 的随机样本, 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$;
- 则方差 σ^2 的 $100(1 - \alpha)\%$ 的置信区间为

$$\left(0, \frac{(n-1)S^2}{\chi_{n-1}^2(\alpha)} \right),$$

其中 $\chi_{n-1}^2(\alpha)$ 是卡方分布 χ_{n-1}^2 的下 α 分位数。可以证明该区间包含 σ^2 的概率为 $1 - \alpha$ 。

- 然而, 如果分布不是正态, 则置信水平可能远小于 $1 - \alpha$ 。

- 正态分布 $X \sim N(0, 4)$

```
n <- 20
alpha <- 0.05

UCL <- replicate(1000, expr = {
  x <- rnorm(n, 0, 2)
  (n-1) * var(x) / qchisq(alpha, df = n-1)
})

# 计算经验置信水平
mean(UCL > 4)

## [1] 0.941
```

- 卡方分布 $X \sim \chi_2^2$ (满足 $\text{Var}(X) = 4$)

```
UCL <- replicate(1000, expr = {  
  x <- rchisq(n, df = 2) # Var(X) = 4  
  (n-1) * var(x) / qchisq(alpha, df = n-1)  
})
```

```
# 计算经验置信水平
```

```
mean(UCL > 4)
```

```
## [1] 0.803
```

2 假设检验中的蒙特卡罗方法

2.1 I 型错误的估计

- 考虑关于参数 $\theta \in \Theta$ 的假设检验问题, Θ 为参数空间。该问题具有如下的零假设与对立假设:

$$H_0 : \{\theta \in \Theta_0\}, \quad H_1 : \{\theta \in \Theta_1\},$$

其中 $\Theta = \Theta_0 \cup \Theta_1$ 。

- 对于一个给定的检验方法, 记 π_θ 为假设参数为 θ 时的 I 型错误, 即

$$\pi(\theta) = \Pr_{\theta}(\text{Reject } H_0) = E_{\theta}(I(\text{Reject } H_0)).$$

- 显著性水平 (significance level) 表示为

$$\alpha = \sup_{\theta \in \Theta_0} \pi(\theta).$$

- 类似置信水平的估计，对于简单的假设检验问题，我们通常可以构造一个简单的检验统计量使得 I 型错误可以直接算出，这通常依赖于数据 X 的分布假设。当 X 不满足该分布假设时，I 型错误往往难以直接求出。
 - 参考《统计计算使用 R》6.4 节：应用：“Count Five” 等方差检验。
- 另外，检验统计量通常优先控制 I 型错误，II 型错误或功效 (Power) 通常难以直接求出。
- I 型错误的估计可以转化为对于参数 $\pi_\theta = E_\theta\{I(\text{Reject } H_0)\}$ 的 Monte Carlo 估计。
- 等价地，如果显著性水平为 α ， $\pi_\theta = E_\theta\{I(p\text{-value} \leq \alpha)\}$

- Monte Carlo 估计步骤如下：选定零假设中一个特定的参数值 $\theta \in \Theta_0$ 。对第 j 次重复试验, $j = 1, \dots, m$:
 1. 在参数为 θ 的情况下生成第 j 个随机样本集 $x_1^{(j)}, \dots, x_n^{(j)}$;
 2. 对第 j 个随机样本计算检验统计量 T_j ;
 3. 如果 H_0 在显著性水平 α 下被拒绝, 那么令检验决策 $I_j = 1$, 否则令 $I_j = 0$;
 4. 计算 I 型错误 $\hat{\pi}_\theta = \frac{1}{m} \sum_{j=1}^m I_j$ 。

- 每次 Monte Carlo 重复试验得到一个服从 Bernoulli 分布的独立变量 $I_j = I(\text{Reject } H_0) \sim \text{Bernoulli}(\pi_\theta)$.
- I 型错误估计 $\hat{\pi}_\theta$ 的标准误差为

$$\text{se}(\hat{\pi}_\theta) = \sqrt{\frac{\pi_\theta(1 - \pi_\theta)}{m}},$$

- 则标准误差的估计为

$$\widehat{\text{se}}(\hat{\pi}_\theta) = \sqrt{\frac{\hat{\pi}_\theta(1 - \hat{\pi}_\theta)}{m}}.$$

例 2.1. t 检验

- 设 $x_1, \dots, x_n$, $n = 20$ 是服从 $N(\mu, \sigma^2)$ 分布的随机样本。在 $\alpha = 0.05$ 的显著水平下检验

$$H_0 : \mu = 500 \quad vs. \quad H_1 : \mu > 500.$$

- 记 $\bar{x}$ 和 S 为样本均值和样本方差, t_{19} 为自由度为 19 的 t 分布。在零假设下

$$T = \frac{\bar{x} - 500}{S/\sqrt{20}} \sim t_{19}.$$

- 构造拒绝域: $R_1 := \{T \geq t_{19}(0.95)\}$ 。
- 定义 $p\text{-value} = \Pr(t_{19} \geq T)$, 则拒绝域的另一种定义为 $R_2 := \{p\text{-value} \leq 0.05\}$ 。可以证明 (1) $R_1 = R_2$; (2) 在零假设下, $p\text{-value}$ 服从均匀分布 $Unif(0, 1)$ 。
- 用蒙特卡罗方法验证 $\sigma = 100$ 时 I 类错误的经验概率约为 $\alpha = 0.05$ 。

```
n <- 200
alpha <- 0.05
mu0 <- 500
sigma <- 100

m <- 1000
p <- numeric(m)
for (j in 1:m){
  x <- rnorm(n, mu0, sigma)
  ttest <- t.test(x, alternative = "greater",
                  mu = mu0)
  p[j] <- ttest$p.value
}

p.hat <- mean(p < alpha)
se.hat <- sqrt(p.hat*(1-p.hat) / m)
print(c(p.hat, se.hat))
```

```
## [1] 0.042000000 0.006343185
```

2.2 检验功效的估计

- 给定 $\theta_1 \in \Theta_1$, II 型错误为

$$1 - \pi_{\theta_1} = \Pr(\text{Accept } \Theta_0 \mid \theta_1).$$

- 对应的功效为

$$\pi_{\theta_1} = \Pr(\text{Reject } \Theta_0 \mid \theta_1).$$


- 在假设检验中, 我们一般控制 I 型错误, 并且尽量使其功效较大。

- Monte Carlo 估计步骤如下：选定对立假设中一个特定的参数值 $\theta_1 \in \Theta_1$ 。对第 j 次重复试验， $j = 1, \dots, m$ ：
 1. 在参数为 θ_1 的情况下生成第 j 个随机样本集 $x_1^{(j)}, \dots, x_n^{(j)}$ ；
 2. 对第 j 个随机样本计算检验统计量 T_j ；
 3. 如果 H_0 在显著性水平 α 下被拒绝，那么令检验决策 $I_j = 1$ ，否则令 $I_j = 0$ ；
 4. 计算功效 $\hat{\pi}_{\theta_1} = \frac{1}{m} \sum_{j=1}^m I_j$

例 2.2. t 检验的功效

```
m <- 1000
alpha <- 0.05
mu <- seq(450, 650, 10)
M <- length(mu)
power <- numeric(M)
for (i in 1:M){
  mu1 <- mu[i]
  pvalues <- replicate(m, expr = {
    x <- rnorm(n, mu1, sigma)
    ttest <- t.test(x, alternative = "greater",
                    mu = mu0)
    ttest$p.value
  })
  power[i] <- mean(pvalues < alpha)
}
se <- sqrt(power*(1-power) / m)
```

```
power_data <- data.frame(mu = mu, power = power)
ggplot(power_data, aes(x = mu, y = power)) +
  geom_point() + geom_line(linetype = 3) +
  geom_vline(xintercept = mu0, linetype = 2) +
  geom_hline(yintercept = alpha, linetype = 2) +
  labs(x = expression(theta), y = "Power") +
  theme_bw()
```

例 2.3. “污染” 正态分布

考虑“污染”正态分布:

$$X \sim pN(\mu, 1) + (1 - p)N(\mu, 10^2)$$

原假设和对立假设为


$$H_0 : \mu = 0 \quad vs. \quad H_1 : \mu > 0.$$

比较该假设检验问题下 t 检验和 $Wilcox$ 检验的检验功效

```
rnorm_con <- function(n, p, mu){  
  sigma <- sample(c(1,10), size = n, replace = TRUE,  
                  prob = c(p, 1-p))  
  rnorm(n, mu, sigma)  
}
```

```
m <- 1000 # Monte Carlo 次数
n <- 200 # 样本数
alpha <- 0.05
mu0 <- 0 # 原假设
mu <- seq(-1, 6, 0.2) # 不同的对立假设
M <- length(mu)
power <- matrix(0, M, 2)
for (i in 1:M){
  mu1 <- mu[i]
  pvalues <- replicate(m, expr = {
    x <- rnorm_con(n, 0.9, mu1)
    ttest <-
      t.test(x, alternative = "greater", mu = mu0)
    wtest <-
      wilcox.test(x, alternative = "greater", mu = mu0)
    c(ttest$p.value, wtest$p.value)
  })
  power[i,] <- apply(pvalues < alpha, 1, mean)
}
```

```
library(reshape2)
data <- data.frame(x = mu, t = power[,1],
                   wilcoxon = power[,2])
data <- melt(data, id = "x", variable.name = "Method")
ggplot(data, aes(x = x, y = value, color = Method))+
  geom_line()+
  labs(x = TeX("$\\mu$"), y = "Power")+
  theme_bw()+
  theme(legend.position = "bottom")
```



Method — t — wilcoxon