

STAT3003: 统计算法基础

蒙特卡洛方法 (2)

曾靖

中国科学技术大学管理学院

大纲

大纲

1. 参数估计中的蒙特卡罗方法

- 均方误差 (MSE)
- 标准误差 (SE)

2. 区间估计和假设检验中的蒙特卡罗方法

- 置信区间的覆盖率
- 假设检验的 I 型错误率和功效

本节内容来自于《统计计算使用 *R*》第 6 章

1 参数估计中的蒙特卡罗方法

1.1 均方误差

- 设 $x_1, \dots, x_n$ 是随机变量 X 的 i.i.d. 样本, 记参数 $\theta = \theta(X)$ 的估计量为:

$$\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n).$$

- 衡量估计量精度的一个常用指标是均方误差 (MSE):

$$\text{MSE}(\hat{\theta}_n) = E [(\hat{\theta}_n - \theta)^2].$$

- 接下来介绍如何通过 Monte Carlo 重复抽样估计这一期望。
- 记号约定: n 表示每份数据样本的观测数; m 表示单次 Monte Carlo 估计的重复次数; m' 表示将整个估计过程独立重复的外层次数。

例 1. 估计切尾均值的均方误差

设 X 为非正态的连续对称随机变量，中心为 $\theta = E(X) = 0$ 。对样本 $x_1, \dots, x_n$ ，记次序统计量为 $x_{(1)} \leq \dots \leq x_{(n)}$ 。

对切尾层数 k ，定义第 k 层切尾均值估计量

$$\hat{\theta}_{[-k]} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}.$$

Question: 如何用 *Monte Carlo* 方法估计 $\hat{\theta}_{[-k]}$ 的 *MSE*?

- 切尾均值舍弃两端的极端观测，可以减弱异常值的影响。

◦ 均方误差 $\xi = E(\hat{\theta}_{[-k]}^2)$ 的 Monte Carlo 估计步骤如下：对于 $j = 1, \dots, m$,

1. 生成服从 X 分布的独立样本 $x_1^{(j)}, \dots, x_n^{(j)}$;
2. 将 n 个独立样本按升序排列, 得到有序样本 $x_{(1)}^{(j)}, \dots, x_{(n)}^{(j)}$;
3. 计算第 k 层切尾均值估计

$$\hat{\theta}_{[-k]}^{(j)} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}^{(j)}$$

4. 估计第 k 层切尾均值的均方误差:

$$\widehat{\text{MSE}} = \frac{1}{m} \sum_{j=1}^m (\hat{\theta}_{[-k]}^{(j)})^2.$$

- 正态分布

```
n <- 20
m <- 1000
k <- 1 # trimmed number
tmean <- replicate(m,
                    mean(sort(rnorm(n))[(k+1):(n-k)]))
mean(tmean^2) # MSE

## [1] 0.04763241
```

- t 分布

```
tmean <- nmean <- numeric(m)
for(i in 1:m){
  x <- sort(rt(n, 3))
  nmean[i] <- mean(x)
  tmean[i] <- mean(x[(k+1):(n-k)])
}
cat("Normal mean: ", mean(nmean^2),
    "Trimmed mean: ", mean(tmean^2))  # MSE

## Normal mean:  0.1411215 Trimmed mean:  0.09969
```

- “污染” 正态分布 (Contaminated normal)

考虑“污染”正态分布如下（混合高斯模型 GMM 的特例）

$$X \sim pN(0, 1) + (1 - p)N(0, 10^2)$$

```
rnorm_con <- function(n, p){  
  sigma <- sample(c(1,10), size = n, replace = TRUE,  
                  prob = c(p, 1-p))  
  rnorm(n, 0, sigma)  
}  
trimmed.mse <- function(n, m, k, p){  
  tmean <- replicate(m,  
                     mean(sort(rnorm_con(n, p))  
                           [(k+1):(n-k)]))  
  mean(tmean^2)  
}
```

考虑不同的 k 和 p 对切尾均值的 MSE 的影响。

```
n <- 20
K <- n/2 - 1
m <- 1000
mse <- matrix(0, n/2, 3)

for(k in 0:K){
  mse[k+1, 1] <- trimmed.mse(n,m,k, p=1.0)
  mse[k+1, 2] <- trimmed.mse(n,m,k, p=0.95)
  mse[k+1, 3] <- trimmed.mse(n,m,k, p=0.9)
}
```

```
mse <- data.frame(mse)
colnames(mse) <- c("p=1", "p=0.95", "p=0.9")
rownames(mse) <- 0:9
round(mse,3)
```

##		p=1	p=0.95	p=0.9
##	0	0.050	0.266	0.568
##	1	0.052	0.099	0.183
##	2	0.052	0.062	0.093
##	3	0.053	0.059	0.075
##	4	0.057	0.069	0.074
##	5	0.055	0.068	0.075
##	6	0.058	0.068	0.076
##	7	0.062	0.076	0.083
##	8	0.070	0.075	0.084
##	9	0.069	0.080	0.087

1.3 标准误差

- 估计量 $\hat{\theta}$ 的标准误差为

$$\text{se}(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}.$$

(方法一) 将整个 Monte Carlo 估计过程独立重复 m' 次, 每次使用 m 次抽样。记第 j 次估计为 $\hat{\theta}^{(j)}$, $j = 1, \dots, m'$, 则标准误差的估计为

$$\widehat{\text{se}}(\hat{\theta}) = \left\{ \frac{1}{m' - 1} \sum_{j=1}^{m'} (\hat{\theta}^{(j)} - \bar{\hat{\theta}})^2 \right\}^{1/2}, \quad \bar{\hat{\theta}} = \frac{1}{m'} \sum_{j=1}^{m'} \hat{\theta}^{(j)}.$$

(方法二) 当 $\hat{\theta}$ 是均值估计量, 则 $\hat{\theta}$ 的标准误差估计可以重复利用改 Monte Carlo 实验中的数据, 减小计算量。

- 例如, 考虑 X_1, X_2 独立且服从标准正态分布, 目标参数为 $\theta = E|X_1 - X_2|$, 其 Monte Carlo 估计为

$$\hat{\theta} = \frac{1}{m} \sum_{j=1}^m |x_1^{(j)} - x_2^{(j)}|.$$

- 则 $\hat{\theta}$ 的标准误差为

$$\text{se}(\hat{\theta}) = \left(\frac{1}{m} \text{Var}(|X_1 - X_2|) \right)^{1/2}.$$

- 该标准误差 $\text{se}(\hat{\theta})$ 对应的估计为

$$\widehat{\text{se}}(\hat{\theta}) = \left(\frac{1}{m} \widehat{\text{Var}}(|X_1 - X_2|) \right)^{1/2}.$$

例 2. 绝对差估计的标准误差

- 理论标准误差为

$$\text{se}(\hat{\theta}) = \sqrt{\frac{1}{m} \text{Var}(|X_1 - X_2|)} = \sqrt{\frac{1}{m} (2 - \frac{4}{\pi})} \approx 0.02695850.$$

```
# 方法一：每次估计使用  $m$  次抽样，外层独立重复  $m\_prime$  次
m <- 1000
m_prime <- 1000
theta_hat_outer <- numeric(m_prime)
for(i in seq_len(m_prime)){
  g <- replicate(m, {
    x <- rnorm(2)
    abs(x[1] - x[2])
  })
  theta_hat_outer[i] <- mean(g)
}

sd(theta_hat_outer) # outer Monte Carlo estimate of s.e.

## [1] 0.02635541
```

方法二：单次估计使用 m 次抽样

```
m <- 1000
```

```
g <- replicate(m, {
```

```
  x <- rnorm(2)
```

```
  abs(x[1] - x[2])
```

```
})
```

```
sqrt(mean((g-mean(g))^2)/m)
```

```
## [1] 0.02796293
```

思考：每次估计均使用 m 个 *Monte Carlo* 样本时，两种方法分别需要多少个样本？

2 区间估计和假设检验中的蒙特卡罗方法

2.1 置信水平估计

- 给定由样本构造的置信区间 $\widehat{C}$ ，其实际覆盖率为

$$\beta = \Pr_{\theta}(\theta \in \widehat{C}) = E_{\theta}[I(\theta \in \widehat{C})].$$

- 难点：复杂分布下，覆盖率通常难以直接计算。
- Monte Carlo* 思路：重复生成样本并构造区间，以覆盖真参数的频率估计 β 。

- 置信水平 $\beta = E_{\theta}[I(\theta \in \widehat{C})]$ 的 Monte Carlo 估计步骤如下:
对第 j 次重复试验, $j = 1, \dots, m$:
 1. 生成独立的随机样本 $x_1^{(j)}, \dots, x_n^{(j)}$;
 2. 根据随机样本计算置信区间 $\widehat{C}^{(j)}$;
 3. 计算 $\beta_j = I(\theta \in \widehat{C}^{(j)})$;
 4. 计算经验置信水平 $\hat{\beta} = \frac{1}{m} \sum_{j=1}^m \beta_j$ 。

- 由于每次 Monte Carlo 试验得到一个服从 Bernoulli 分布的独立变量 $\beta_j = I(\theta \in \widehat{C}^{(j)}) \sim \text{Bernoulli}(\beta)$ ，则置信水平估计 $\hat{\beta}$ 的标准误差为

$$\text{se}(\hat{\beta}) = \sqrt{\frac{\beta(1-\beta)}{m}},$$

- 该标准误差的估计为

$$\widehat{\text{se}}(\hat{\beta}) = \sqrt{\frac{\hat{\beta}(1-\hat{\beta})}{m}},$$

思考：若每次估计使用 m 次 Monte Carlo 试验，并将整个过程独立重复 m' 次，总共需要多少次模拟？

例 3. 方差的置信水平

设 $X_1, \dots, X_n$ 是服从正态分布 $N(\mu, \sigma^2)$ 的随机样本, 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。

则方差 σ^2 的 $100(1 - \alpha)\%$ 的置信区间为

$$\left(0, \frac{(n-1)S^2}{\chi_{n-1}^2(\alpha)} \right),$$

其中 $\chi_{n-1}^2(\alpha)$ 是卡方分布 χ_{n-1}^2 的下 α 分位数。可以证明该区间包含 σ^2 的概率为 $1 - \alpha$ 。

如果分布不是正态, 则置信水平可能远小于 $1 - \alpha$ 。

- 正态分布 $X \sim N(0, 4)$

```
n <- 20
m <- 1000
alpha <- 0.05

UCL <- replicate(m, expr = {
  x <- rnorm(n, 0, 2)
  (n-1) * var(x) / qchisq(alpha, df = n-1)
})

# 计算经验置信水平
mean(UCL > 4)

## [1] 0.941
```

- 卡方分布 $X \sim \chi_2^2$ (满足 $\text{Var}(X) = 4$)

```
UCL <- replicate(m, expr = {  
  x <- rchisq(n, df = 2) # Var(X) = 4  
  (n-1) * var(x) / qchisq(alpha, df = n-1)  
})
```

计算经验置信水平

```
mean(UCL > 4)
```

```
## [1] 0.769
```

2.2 I 型错误的估计

- 考虑关于参数 $\theta \in \Theta$ 的假设检验问题, Θ 为参数空间。该问题具有如下的零假设与对立假设:

$$H_0 : \{\theta \in \Theta_0\}, \quad H_1 : \{\theta \in \Theta_1\},$$

其中 $\Theta = \Theta_0 \cup \Theta_1$ 。

- 对于给定的检验方法, 记 π_θ 为参数值 θ 下拒绝 H_0 的概率:

$$\pi_\theta = \Pr(\text{Reject } H_0) = E_\theta(I(\text{Reject } H_0)).$$

- 当 $\theta \in \Theta_0$ 时, π_θ 是点态 I 型错误概率; 当 $\theta \in \Theta_1$ 时, 它是检验功效。

- 计算难点：I 型错误率和检验功效取决于抽样分布；模型复杂或分布假设不适用时，通常难以直接计算。
- *Monte Carlo* 思路：在给定参数值 θ 下重复生成样本并进行检验，以拒绝 H_0 的频率估计 π_θ 。

- Monte Carlo 估计步骤如下：选定零假设中一个特定的参数值 $\theta \in \Theta_0$ 。对第 j 次重复试验, $j = 1, \dots, m$:
 1. 在参数为 θ 的情况下生成第 j 个随机样本集 $x_1^{(j)}, \dots, x_n^{(j)}$;
 2. 对第 j 个随机样本计算检验统计量 T_j ;
 3. 如果 H_0 在显著性水平 α 下被拒绝, 那么令检验决策 $I_j = 1$, 否则令 $I_j = 0$;
 4. 计算 I 型错误 $\hat{\pi}_\theta = \frac{1}{m} \sum_{j=1}^m I_j$ 。

- 每次 Monte Carlo 重复试验得到一个服从 Bernoulli 分布的独立变量 $I_j = I(\text{Reject } H_0) \sim \text{Bernoulli}(\pi_\theta)$.
- I 型错误估计 $\hat{\pi}_\theta$ 的标准误差为

$$\text{se}(\hat{\pi}_\theta) = \sqrt{\frac{\pi_\theta(1 - \pi_\theta)}{m}},$$

- 则标准误差的估计为

$$\widehat{\text{se}}(\hat{\pi}_\theta) = \sqrt{\frac{\hat{\pi}_\theta(1 - \hat{\pi}_\theta)}{m}}.$$

例 4. t 检验

设 $x_1, \dots, x_n$, $n = 20$ 是服从 $N(\mu, \sigma^2)$ 分布的随机样本。在 $\alpha = 0.05$ 的显著水平下检验

$$H_0 : \mu = 500 \quad vs. \quad H_1 : \mu > 500.$$

- 记 $\bar{x}$ 和 S 为样本均值和样本方差, t_{19} 为自由度为 19 的 t 分布。在零假设下

$$T = \frac{\bar{x} - 500}{S/\sqrt{20}} \sim t_{19}.$$

- 构造拒绝域: $R_1 := \{T \geq t_{19}(0.95)\}$ 。
- 观测到的统计量取值为 t 时, 右尾 $p\text{-value} = 1 - F_{t_{19}}(t)$ 。由于 $F_{t_{19}}$ 连续严格递增, $p\text{-value} \leq 0.05$ 等价于 $t \geq t_{19}(0.95)$, 故 $R_1 = R_2$, 这一等价关系不要求 H_0 为真。
- 若 H_0 成立, 则 $T \sim t_{19}$, 从而 $p\text{-value} \sim \text{Unif}(0, 1)$ 。

```
n <- 20
alpha <- 0.05
mu0 <- 500
sigma <- 100

m <- 1000
p <- numeric(m)
for (j in 1:m){
  x <- rnorm(n, mu0, sigma)
  ttest <- t.test(x, alternative = "greater",
                  mu = mu0)
  p[j] <- ttest$p.value
}

p.hat <- mean(p < alpha)
se.hat <- sqrt(p.hat*(1-p.hat) / m)
print(c(p.hat, se.hat))
```

```
## [1] 0.056000000 0.007270763
```

2.4 检验功效的估计

- 给定 $\theta_1 \in \Theta_1$, II 型错误为

$$1 - \pi_{\theta_1} = \Pr(\text{Accept } \Theta_0 \mid \theta_1).$$

- 对应的功效为

$$\pi_{\theta_1} = \Pr_{\theta_1}(\text{Reject } \Theta_0).$$

- 在假设检验中, 我们一般控制 I 型错误, 并且尽量使其功效较大。


- Monte Carlo 估计步骤如下：选定对立假设中一个特定的参数值 $\theta_1 \in \Theta_1$ 。对第 j 次重复试验， $j = 1, \dots, m$ ：
 1. 在参数为 θ_1 的情况下生成第 j 个随机样本集 $x_1^{(j)}, \dots, x_n^{(j)}$ ；
 2. 对第 j 个随机样本计算检验统计量 T_j ；
 3. 如果 H_0 在显著性水平 α 下被拒绝，那么令检验决策 $I_j = 1$ ，否则令 $I_j = 0$ ；
 4. 计算功效 $\hat{\pi}_{\theta_1} = \frac{1}{m} \sum_{j=1}^m I_j$

例 5. t 检验的功效

```
m <- 1000 # 每个参数值下的 Monte Carlo 重复次数
alpha <- 0.05
mu <- seq(450, 650, 10)
power <- numeric(length(mu))
for (i in seq_along(mu)){
  mu1 <- mu[i]
  pvalues <- replicate(m, expr = {
    x <- rnorm(n, mu1, sigma)
    ttest <- t.test(x, alternative = "greater",
                    mu = mu0)

    ttest$p.value
  })
  power[i] <- mean(pvalues < alpha)
}
```

```
power_data <- data.frame(mu = mu, power = power)
ggplot(power_data, aes(x = mu, y = power)) +
  geom_point() + geom_line(linetype = 3) +
  geom_vline(xintercept = mu0, linetype = 2) +
  geom_hline(yintercept = alpha, linetype = 2) +
  labs(x = expression(theta), y = "Power") +
  theme_bw()
```



例 6. “污染” 正态分布

考虑“污染”正态分布:

$$X \sim pN(\mu, 1) + (1 - p)N(\mu, 10^2)$$

原假设和对立假设为


$$H_0 : \mu = 0 \quad vs. \quad H_1 : \mu > 0.$$

比较该假设检验问题下 t 检验和 $Wilcox$ 检验的检验功效

```
rnorm_con <- function(n, p, mu){  
  sigma <- sample(c(1,10), size = n, replace = TRUE,  
                  prob = c(p, 1-p))  
  rnorm(n, mu, sigma)  
}
```

```
n <- 200 # 每份数据样本的观测数
m <- 1000 # Monte Carlo 重复次数
alpha <- 0.05
mu0 <- 0 # 原假设
mu <- seq(-1, 6, 0.2) # 不同的对立假设
power <- matrix(0, length(mu), 2)
for (i in seq_along(mu)){
  mu1 <- mu[i]
  pvalues <- replicate(m, expr = {
    x <- rnorm_con(n, 0.9, mu1)
    ttest <-
      t.test(x, alternative = "greater", mu = mu0)
    wtest <-
      wilcox.test(x, alternative = "greater", mu = mu0)
    c(ttest$p.value, wtest$p.value)
  })
  power[i,] <- apply(pvalues < alpha, 1, mean)
}
```

```
library(reshape2)
data <- data.frame(x = mu, t = power[,1],
                   wilcoxon = power[,2])
data <- melt(data, id = "x", variable.name = "Method")
ggplot(data, aes(x = x, y = value, color = Method))+
  geom_line()+
  labs(x = TeX("$\\mu$"), y = "Power")+
  theme_bw()+
  theme(legend.position = "bottom")
```



Method — t — wilcoxon