

STAT3003: 统计算法基础

优化问题 (3)

曾靖

中国科学技术大学管理学院

大纲

大纲

1. MM 算法
2. ADMM 算法

1 MM 算法

1.1 MM 算法

- 在最大值问题中，MM 表示 minorize-maximize。在最小值问题中，MM 表示 majorize-minimize。
- 以最小值问题为例，MM 算法的核心思想是造出一个处处大于目标函数的替代函数。当我们最小化替代函数，那么目标函数值也会跟着减小。在迭代过程中不断地构造替代函数，从而使得目标函数值不断减小，进而逼近目标函数的最小值。
- MM 算法在非凸优化问题中尤为有用。

- 考虑优化问题:

$$\min_{\theta \in \mathbb{R}^p} f(\theta).$$


- 函数 $\varphi(\theta \mid \theta_t)$ 在点 θ_t 处 **majorizes** 目标函数 $f(\theta)$ 如果

$$\begin{aligned} f(\theta) &\leq \varphi(\theta \mid \theta_t), \quad \forall \theta \in \mathbb{R}^p \\ f(\theta_t) &= \varphi(\theta_t \mid \theta_t) \end{aligned}$$

最小化问题中的 MM 算法:

- 在点 θ_t 出构造替代函数 $\varphi(\theta \mid \theta_t)$, 使得其 majorizes 目标函数 $f(\theta)$
- 最小化替代函数,

$$\theta_{t+1} = \arg \min_{\theta \in \mathbb{R}^p} \varphi(\theta \mid \theta_t).$$



- 我们有

$$f(\theta_t) = \varphi(\theta_t \mid \theta_t) \geq \varphi(\theta_{t+1} \mid \theta_t) \geq f(\theta_{t+1}).$$

因此，MM 算法可以保证目标函数的单调非增。

- 我们希望找到更容易解决的替代函数。

1.2 特例（一）：EM 算法

- 在 EM 算法中，我们已知

$$Q(\theta \mid \theta_t) - Q(\theta_t \mid \theta_t) \leq l(\theta \mid X) - l(\theta_t \mid X).$$

- 记函数

$$\varphi(\theta \mid \theta_t) = Q(\theta \mid \theta_t) - Q(\theta_t \mid \theta_t) + l(\theta_t \mid X),$$

则

$$\begin{aligned} l(\theta \mid X) &\geq \varphi(\theta \mid \theta_t), \quad \forall \theta \in \mathbb{R}^p \\ l(\theta_t \mid X) &= \varphi(\theta_t \mid \theta_t). \end{aligned}$$

因此，替代函数 $\varphi(\theta \mid \theta_t)$ 在点 θ_t 处 **minorizes** 目标函数 $l(\theta \mid X)$.

- 最大化替代函数 $\varphi(\theta \mid \theta_t)$, 可得

$$\theta_{t+1} = \arg \max_{\theta \in \mathbb{R}^p} \varphi(\theta \mid \theta_t) = \arg \max_{\theta \in \mathbb{R}^p} Q(\theta \mid \theta_t).$$

这一步等价于 EM 算法中的 M-step。

- 由此可知, EM 算法是 MM 算法的一个特例。

1.3 特例（二）：近端梯度法

- 近端梯度算法考虑如下优化问题:

$$\min_x f(x) = \min_x g(x) + h(x),$$

这里 $g(x)$ 为可微凸函数, $h(x)$ 为不可微凸函数。

- 假设 $\nabla g(x)$ 满足 Lipschitz 连续, 即

$$\|\nabla g(x) - \nabla g(x')\|_2 \leq L\|x - x'\|_2, \quad \forall x, x' \in \mathbb{R}^p.$$

则 $\nabla^2 g(x') \preceq L\mathbf{I}_p$.

- 对 $g(x)$ 在点 x_t 处进行二阶 Taylor 展开, 得

$$g(x) = g(x_t) + \langle \nabla g(x_t), x - x_t \rangle + \frac{1}{2}(x - x_t)^\top \nabla^2 g(x')(x - x_t),$$

这里 $x' = sx + (1 - s)x_t$, $0 \leq s \leq 1$. 因此,

$$g(x) \leq g(x_t) + \langle \nabla g(x_t), x - x_t \rangle + \frac{L}{2}\|x - x_t\|_2^2,$$

所以,

$$f(x) \leq g(x_t) + \langle \nabla g(x_t), x - x_t \rangle + \frac{L}{2}\|x - x_t\|_2^2 + h(x).$$

- 令函数

$$\varphi(x \mid x_t) = g(x_t) + \langle \nabla g(x_t), x - x_t \rangle + \frac{L}{2} \|x - x_t\|_2^2 + h(x),$$

则

$$\begin{aligned} f(x) &\leq \varphi(x \mid x_t), \quad \forall x \in \mathbb{R}^p \\ f(x_t) &= \varphi(x_t \mid x_t). \end{aligned}$$

因此, $\varphi(x \mid x_t)$ 在点 x_t 处 majorizes $f(x)$.

- 最小化 $\varphi(x \mid x_t)$, 可得

$$\begin{aligned} x_{t+1} &= \arg \min_{x \in \mathbb{R}^p} \varphi(x \mid x_t) \\ &= \arg \min_{x \in \mathbb{R}^p} \left\{ g(x_t) + \langle \nabla g(x_t), x - x_t \rangle + \frac{L}{2} \|x - x_t\|_2^2 + h(x) \right\} \end{aligned}$$

这正是近端梯度法的一步迭代。

- 由此可知, 近端梯度法是 MM 算法的一个特例。

1.4 MM 算法收敛性

- 如果目标函数是凸或凹函数，则 MM 算法会收敛到全局最优解。
- 否则，收敛点可能为局部最优解或者鞍点。

例 1.1: sample quantiles

- 考虑一维样本 $x_1, \dots, x_n \in \mathbb{R}$. τ 分位数定义为

$$q_\tau = \arg \min_{\theta} f(\theta), \quad f(\theta) = \sum_{i=1}^n \rho_\tau(x_i - \theta),$$


这里 $\rho_\tau(z) = z\{\tau - I(z < 0)\}$.

- 记

$$\varphi(\theta \mid \theta_t) = \frac{1}{4} \left\{ \frac{\theta^2}{|\theta_t|} + (4\tau - 2)\theta + |\theta_t| \right\}$$

在点 $\pm\theta_t$ 处, $\varphi(\theta \mid \theta_t)$ majorizes $\rho_\tau(\theta)$.

(a)



- 因此, 函数

$$\psi(\theta \mid \theta_t) = \sum_{i=1}^b \varphi(x_i - \theta \mid x_i - \theta_t)$$

在点 θ_t 处 majorizes 目标函数 $f(\theta)$.

- 最小化替代函数 $\psi(\theta \mid \theta_t)$, 可得

$$\theta_{t+1} = \arg \min_{\theta} \psi(\theta \mid \theta_t) = \frac{n(2\tau - 1) + \sum_{i=1}^n |x_i - \theta_t|^{-1} x_i}{\sum_{i=1}^n |x_i - \theta_t|^{-1}}.$$

- 我们发现, θ_{t+1} 也就是 $\psi(\theta \mid \theta_t)$ 的一步 Newton 迭代:

$$\theta_{t+1} = \theta_t - (\psi''(\theta_t \mid \theta_t))^{-1}(\psi'(\theta_t \mid \theta_t)).$$

因此, 我们又可以称该问题中的 MM 算法为 gradient MM 算法。

- 相比较 Newton's method, MM 算法收敛速度更慢，通常是线性收敛速率，即

$$\lim_{t \rightarrow \infty} \frac{\|\theta_{t+1} - \theta^*\|}{\|\theta_t - \theta^*\|} = c < 1.$$

而 Newton's method 是平方收敛速率, 即

$$\lim_{t \rightarrow \infty} \frac{\|\theta_{t+1} - \theta^*\|}{\|\theta_t - \theta^*\|^2} = c.$$

- 然而，当算法构造恰当时, MM 算法往往每次迭代要比 Newton's method 要更容易，更快。
- 因此，虽然达到同样收敛精度，MM 算法需要更多迭代次数，但是由于每次迭代中计算时间更少，往往总时间比 Newton's method 更短。

2 ADMM 算法

2.1 简介

ADMM 算法一般用来处理如下优化问题:

$$\begin{aligned} \min_{x \in \mathbb{R}^p, y \in \mathbb{R}^q} \quad & f(x) + g(y), \\ \text{subject to} \quad & Ax + By = c, \end{aligned} \tag{1}$$

这里 $f: \mathbb{R}^m \rightarrow \mathbb{R}$, $g: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, $A \in \mathbb{R}^{d \times m}$ 和 $B \in \mathbb{R}^{d \times n}$ 是已知的矩阵, $c \in \mathbb{R}^d$ 是常数向量。

- 有些问题本身并不满足优化问题 (1) 的形式，但是可以转化成 (1) 的形式。往往这种形式的转化可以大大简化问题。

一些例子：

1. $\min_x I_C(x) + I_D(x)$ 可改写为：

$$\begin{aligned} \min_{x, z \in \mathbb{R}^p} \quad & I_C(x) + I_D(z) \\ \text{subject to} \quad & x - z = 0. \end{aligned}$$

2. $\min_{x \in \mathbb{R}^p} \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$. 可改写为：

$$\begin{aligned} \min_{x, z \in \mathbb{R}^p} \quad & \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|z\|_1 \\ \text{subject to} \quad & x - z = 0 \end{aligned}$$

2.2 Dual gradient method

- 在介绍 ADMM 算法之前，我们先介绍 dual gradient method.
- 考虑一个很一般的优化问题 (Q1) :

$$\begin{aligned} \min_{x \in \mathbb{R}^p} \quad & f(x), \\ \text{subject to} \quad & h_i(x) \leq 0, i = 1, \dots, m, \\ & l_j(x) = 0, j = 1, \dots, n. \end{aligned}$$

假设 $f(x)$ 和 $h_i(x)$ 为凸函数的情况。

- 定义优化问题 (Q1) 中 **primal feasible set** 为

$$\mathcal{C} := \{x \mid h_i(x) \leq 0, l_j(x) = 0, i = 1, \dots, m, j = 1, \dots, n\}$$

并记 (Q1) 的 **primal optimal value** 为

$$f^* = \min_{x \in \mathcal{C}} f(x).$$

- 定义 **Lagrangian** 为

$$L(x, u, v) = f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^n v_j l_j(x).$$

记 $u = (u_1, \dots, u_m)^\top$, $v = (v_1, \dots, v_n)$, 这里 $u_i > 0$, $i = 1, \dots, m$, $v_i \in \mathbb{R}$. 参数 u_i 和 v_i 被称为 **dual variables** 或者 **Lagrange multipliers**.

- 定义 **Lagrange dual function** 为

$$g(u, v) = \min_{x \in \mathbb{R}^p} L(x, u, v)$$

- 则问题 (Q1) 对应的 **dual problem** 为

$$(u^*, v^*) = \arg \max_{u \geq 0, v \in \mathbb{R}^n} g(u, v).$$

- 对于任意 $x \in \mathcal{C}, u_i \geq 0, v_i \in \mathbb{R}$, 我们有

$$f(x) \geq L(x, u, v).$$

- 因此,

$$f^* = \min_{x \in \mathcal{C}} f(x) \geq \min_{x \in \mathcal{C}} L(x, u, v) \geq \min_{x \in \mathbb{R}^p} L(x, u, v) = g(u, v).$$

- 并且

$$f^* \geq g^* := \max_{u \geq 0, v \in \mathbb{R}^n} g(u, v).$$

注意这里无论问题是否为凸优化问题，不等式始终成立。

- 如果 $f^* = g^*$, 那么我们称优化问题具有 **strong duality**.

特例：等式约束下的凸优化问题

考虑只有等式约束的凸优化问题 (Q2):

$$\begin{aligned} \min_{x \in \mathbb{R}^p} \quad & f(x), \\ \text{subject to} \quad & Ax = b, \end{aligned}$$

这里 $f(x)$ 是凸函数, $A \in \mathbb{R}^{d \times p}$.

- 这个问题的 Lagrangian 为

$$L(x, u) = f(x) + u^\top (Ax - b), \quad u \in \mathbb{R}^d.$$

- Dual problem 为

$$\max_{u \in \mathbb{R}^d} g(u),$$

这里 $g(u) = \min_{x \in \mathbb{R}^p} L(x, u) = \min_{x \in \mathbb{R}^p} f(x) + u^\top (Ax - b)$.

- **Conjugate function:** 对于任意一个函数 $f : \mathbb{R}^p \rightarrow \mathbb{R}$, 定义其 conjugate function 为

$$f^*(y) = \max_{x \in \mathbb{R}^p} y^\top x - f(x), \quad y \in \mathbb{R}^p.$$

- 则

$$g(u) = \min_{x \in \mathbb{R}^p} f(x) + u^\top (Ax - b) = -f^*(-A^\top u) - b^\top u.$$

(why?)

- 因此, dual problem 变为如下问题 (Q3):

$$\max_{u \in \mathbb{R}^d} -f^*(-A^\top u) - b^\top u.$$

- 问题 (Q2) 转化为求解 dual problem (Q3)。

- Dual gradient method 即是对 dual problem 做 gradient ascent (因为这里我们是求最大值), 每一步迭代为:

$$u_{t+1} = u_t + s_t \nabla g(u_t) = u_t + s_t (A \nabla f^*(-A^\top u_t) - b)$$

- 计算 $\nabla f^*(-A^\top u_t)$ 需要用到如下性质: 如果 f 是凸函数,

$$\begin{aligned} x = \nabla f^*(-A^\top u) &\Leftrightarrow -A^\top u = \nabla f(x) \\ &\Leftrightarrow x = \arg \min_{z \in \mathbb{R}^p} f(z) + u^\top A z. \end{aligned}$$

- 因此, dual gradient method 的每一步迭代可以进一步写成:

$$\begin{aligned} x_t &= \arg \min_{x \in \mathbb{R}^p} f(x) + u_t^\top A x = \arg \min_{x \in \mathbb{R}^p} L(x, u_t) \\ u_{t+1} &= u_t + s_t (A x_t - b). \end{aligned}$$

2.3 Method of multipliers

- Method of multipliers 方法又称作 augment Lagrangian methods.
- Dual gradient method 的缺点：收敛性需要较强的条件。
- Method of multipliers 在更弱的条件下有收敛性质。
- 考虑问题 (Q2) 的一个等价形式

$$\begin{aligned} \min_{x \in \mathbb{R}^p} f(x), \\ \text{subject to } Ax = b. \end{aligned}$$

我们添加一个增加项 (augmentation) $\|A\beta - b\|_2^2$, 则该问题的等价形式为

$$\min_{\beta \in \mathbb{R}^m, \theta \in \mathbb{R}^n} f(x) + \frac{\rho}{2} \|Ax - b\|_2^2, \quad \text{subject to } Ax = b,$$

这里 $\rho > 0$ 为 tuning parameter。

- 定义 **augmented Lagrangian** 为

$$L(x, u) = f(x) + \frac{\rho}{2} \|Ax - b\|_2^2 + u^\top (Ax - b).$$

则 dual problem 为

$$\max_{u \in \mathbb{R}^d} \{-h^*(-A^\top u) - b^\top u\},$$

这里 $h(x) = f(x) + \rho/2 \|Ax - b\|_2^2$.

- 类似地, **dual gradient method** 的迭代公式为:

$$x_t = \arg \min_{x \in \mathbb{R}^p} f(x) + \frac{\rho}{2} \|Ax - b\|_2^2 + u_t^\top Ax = \arg \min_{x \in \mathbb{R}^p} L(x, u_t)$$

$$u_{t+1} = u_t + s_t (Ax_t - b),$$

并且我们通常选取步长 $s_t = \rho$ 来保证 **method of multipliers** 方法的收敛性。

2.4 可分性优化问题

- 假设目标函数有如下可分性质 $f(x) = \sum_{b=1}^B f_b(x_b)$, 这里 $x = (x_1^\top, \dots, x_B^\top)^\top$, $x_b \in \mathbb{R}^{p_b}$, $b = 1, \dots, B$. 那么问题 (Q2)

$$\begin{aligned} \min_{x \in \mathbb{R}^p} \quad & f(x), \\ \text{subject to} \quad & Ax = c, \end{aligned}$$

可以写成如下形式 (Q4)

$$\begin{aligned} \min_{x \in \mathbb{R}^p} \quad & \sum_{b=1}^B f_b(x_b), \\ \text{subject to} \quad & \sum_{b=1}^B A_b x_b = c, \end{aligned}$$

这里矩阵 A 可以相应地划分为 B 块如下

$$A = [A_1 \dots A_B], \text{ where } A_b \in \mathbb{R}^{d \times p_b}.$$

- 那么该问题的 Lagrangian 为

$$L(x, u) = \sum_{b=1}^B f_b(x_b) + u^T \left(\sum_{b=1}^B A_b x_b - c \right).$$

- 则 dual gradient method 的迭代公式为

$$x_{b,t+1} = \arg \min_{x_b} f_b(x_b) + u_t^\top A_b x_b, \quad b = 1, \dots, B,$$

$$u_{t+1} = u_t + s_t \left(\sum_{b=1}^B A_b x_{b,t+1} - c \right).$$

可以看出，每次迭代 x_t 时，可以并行地迭代每一块 $x_{b,t}$ 。因此在可分性优化问题下 dual gradient method 算法具有可分性。

- 问题：如果在可分性优化问题中使用 method of multipliers 方法，算法还具有可分性吗？

2.5 ADMM 算法

- 参考文献: *Boyd, Stephen, et al. "Distributed optimization and statistical learning via the alternating direction method of multipliers." Foundations and Trends® in Machine learning 3.1 (2011): 1-122.*
- 考虑如下优化问题 (Q5) :

$$\begin{aligned} \min_{x \in \mathbb{R}^p, y \in \mathbb{R}^q} \quad & f(x) + g(y), \\ \text{subject to} \quad & Ax + By = c, \end{aligned}$$

这里 $f: \mathbb{R}^m \rightarrow \mathbb{R}, g: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸函数, $A \in \mathbb{R}^{d \times m}$ 和 $B \in \mathbb{R}^{d \times n}$ 是已知的矩阵, $c \in \mathbb{R}^d$ 是常数向量。

- 如果直接使用 **method of multipliers**, 问题将会变得极具挑战性, 因为无法利用目标函数的可分性 (decomposability).
- 在这种情况下我们需要借助 **alternating direction method of multipliers (ADMM)** 算法。

- 问题 (Q5) 的 augmented Lagrangian 为

$$L(x, y, u) = f(x) + g(y) + u^\top (Ax + By - c) + \frac{\rho}{2} \|Ax + By - c\|_2^2.$$

- 使用 Method of multipliers 方法的迭代算法为:

$$(x_t, y_t) = \arg \min_{x, y \in \mathbb{R}^p} L(x, y, u_t)$$

$$u_{t+1} = u_t + \rho(Ax_t + By_t - c).$$

- 然而, 在 method of multipliers 的第一步中, 同时 update (x, y) 具有挑战性。ADMM 算法提出 alternatively update x and y 。迭代算法如下:

$$x_{t+1} = \arg \min_{x \in \mathbb{R}^p} L(x, y_t, u_t),$$

$$y_{t+1} = \arg \min_{y \in \mathbb{R}^p} L(x_{t+1}, y, u_t),$$

$$u_{t+1} = u_t + \rho(Ax_{t+1} + By_{t+1} - c).$$

2.6 ADMM 算法的收敛性

- ADMM 可以很快收敛到适中精度。
- 如果收敛精度较高，则 ADMM 算法需要更多迭代次数。
- 在很多统计问题中，算法的高收敛精度其实对于统计预测带来的帮助十分有限。因此，我们在实际问题中并不一定需要高精度的算法收敛性。在这种意义下，ADMM 算法可以满足统计问题的大多数需求。

2.7 ADMM 的应用 (1): Alternating projections.

考虑找两个凸集 $C, D \subseteq \mathbb{R}^n$ 交集中的某一点, 也即解如下问题

$$\min_x I_C(x) + I_D(x),$$

这里指示函数 $I_C(x)$ 定义为

$$I_C(x) = \begin{cases} 0 & x \in C, \\ \infty & x \notin C. \end{cases}$$

将其改写为:

$$\begin{aligned} & \min_{x, z \in \mathbb{R}^p} I_C(x) + I_D(z) \\ & \text{subject to} \quad x - z = 0. \end{aligned}$$

- 该问题的 augmented Lagrangian 为

$$L_{\rho}(x, z, u) = I_C(x) + I_D(z) + u^T(x - z) + \frac{\rho}{2}\|x - z\|_2^2.$$

- ADMM 算法的迭代公式为

$$x^{(k)} = \arg \min_{x \in \mathbb{R}^p} I_C(x) + \frac{\rho}{2}\|x - z^{(k-1)} + w^{(k-1)}\|_2^2,$$

$$z^{(k)} = \arg \min_{z \in \mathbb{R}^p} I_D(z) + \frac{\rho}{2}\|x^{(k)} - z + w^{(k-1)}\|_2^2,$$

$$w^{(k)} = w^{(k-1)} + x^{(k)} - z^{(k)},$$

这里 $w^{(k)} = u^{(k)}/\rho$. 等价形式为

$$x^{(k)} = \text{prox}_{I_C}(z^{(k-1)} - w^{(k-1)})$$

$$z^{(k)} = \text{prox}_{I_D}(x^{(k)} + w^{(k-1)})$$

$$w^{(k)} = w^{(k-1)} + x^{(k)} - z^{(k)}.$$

(回忆投影算子的定义 $\text{prox}_{I_C}(\cdot)$)

2.7 ADMM 的应用 (2): Lasso problem

- 考虑如下的 Lasso 问题

$$\min_{x \in \mathbb{R}^p} \quad \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1.$$

- 将其改写为

$$\begin{aligned} \min_{x, z \in \mathbb{R}^p} \quad & \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|z\|_1 \\ \text{subject to} \quad & x - z = 0 \end{aligned}$$

- 该问题的 augmented Lagrangian 为

$$L_\rho(x, z, u) = \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|z\|_1 + u^T(x - z) + \frac{\rho}{2} \|x - z\|_2^2.$$

- ADMM 算法的迭代公式为

$$x^{(k)} = \arg \min_x \quad \frac{1}{2} \|Ax - b\|_2^2 + \frac{\rho}{2} \|x - z^{(k-1)} + w^{(k-1)}\|_2^2$$

$$z^{(k)} = \arg \min_z \quad \lambda \|z\|_1 + \frac{\rho}{2} \|x^{(k)} - z + w^{(k-1)}\|_2^2$$

$$w^{(k)} = w^{(k-1)} + x^{(k)} - z^{(k)},$$

这里 $w^{(k)} = u^{(k)}/\rho$. 等价形式为

$$x^{(k)} = (A^T A + \rho I)^{-1} (A^T b + \rho(z^{(k-1)} - u^{(k-1)}))$$

$$z^{(k)} = S_{\lambda/\rho}(x^{(k)} + u^{(k-1)})$$

$$w^{(k)} = w^{(k-1)} + x^{(k)} - z^{(k)}$$